

Methoden en Statistiek 1

true

Versie gecompileerd op 12 Sep 2020

Contents

| | |
|---|---------------|
| Voorwoord | 7 |
| Notatie | 8 |
| Licentie | 8 |
| Over de auteurs | 8 |
| Deel I: Methodologie | 11 |
| 1 Inleiding | 11 |
| 1.1 Wetenschappelijk onderzoek | 11 |
| 1.2 Paradigmata | 13 |
| 1.3 Instrumentatie-onderzoek | 14 |
| 1.4 Beschrijvend onderzoek | 15 |
| 1.5 Experimenteel onderzoek | 16 |
| 1.6 Vooruitblik | 19 |
| 2 Hypothese-toetsend onderzoek | 21 |
| 2.1 Inleiding | 21 |
| 2.2 Variabelen | 22 |
| 2.3 Onafhankelijke en afhankelijke variabelen | 23 |
| 2.4 Falsificatie en nul-hypothese | 24 |
| 2.5 De empirische cyclus | 26 |
| 2.6 Keuzemomenten | 33 |

| | | |
|----------|---|-----------|
| 3 | Integriteit | 37 |
| 3.1 | Inleiding | 37 |
| 3.2 | Ontwerp | 38 |
| 3.3 | Proefpersonen en informanten | 41 |
| 3.4 | Gegevens | 42 |
| 3.5 | Teksten | 44 |
| 4 | Meetniveau | 47 |
| 4.1 | Inleiding | 47 |
| 4.2 | Nominaal | 47 |
| 4.3 | Ordinaal | 48 |
| 4.4 | Interval | 48 |
| 4.5 | Ratio | 49 |
| 4.6 | Ordering van meetniveaus | 49 |
| 5 | Validiteit | 51 |
| 5.1 | Inleiding | 51 |
| 5.2 | Causaliteit | 51 |
| 5.3 | Validiteit | 52 |
| 5.4 | Interne validiteit | 53 |
| 5.5 | Constructvaliditeit | 61 |
| 5.6 | Externe validiteit | 70 |
| 6 | Ontwerp | 73 |
| 6.1 | Inleiding | 73 |
| 6.2 | Tussen of binnen ? | 74 |
| 6.3 | Het one-shot single-case-ontwerp | 75 |
| 6.4 | Het één-groep-voormeting-nameting-ontwerp | 76 |
| 6.5 | Het voormeting-nameting-controlegroep-ontwerp | 77 |
| 6.6 | Het Solomon-vier-groepen-ontwerp | 79 |
| 6.7 | Het nameting-controlegroep-ontwerp | 80 |
| 6.8 | Factoriële ontwerpen | 82 |

| | |
|---|----------------|
| <i>CONTENTS</i> | 5 |
| 6.9 Afhankelijke- en onafhankelijke-groepen-ontwerp | 85 |
| 6.10 Onderzoek ontwerpen | 86 |
| 6.11 Tenslotte | 87 |
| 7 Steekproeven | 91 |
| 7.1 Gelegenheidssteekproeven | 91 |
| 7.2 Systematische steekproeven | 93 |
| 7.3 Aselecte steekproeven | 94 |
| 7.4 Steekproefgrootte | 97 |
| Deel II: Beschrijvende statistiek | 101 |
| 8 Frequenties | 101 |
| 8.1 Inleiding | 101 |
| 8.2 Frequenties | 101 |
| 8.3 Staafdiagrammen | 105 |
| 8.4 Histogrammen | 105 |
| 9 Centrum en spreiding | 109 |
| 9.1 Inleiding | 109 |
| 9.2 Symbolen | 109 |
| 9.3 Centrummaten | 110 |
| 9.4 Kwartielen en boxplots | 115 |
| 9.5 Spreidingsmaten | 119 |
| 9.6 Over significante cijfers | 121 |
| 9.7 Keuzemoment | 124 |
| 9.8 Standaardcores | 125 |
| 9.9 SPSS | 125 |
| 9.10 R | 126 |

| | |
|---|------------|
| 10 Kansverdelingen | 129 |
| 10.1 Kansen | 129 |
| 10.2 Binomiale kansverdeling | 131 |
| 10.3 Normale kansverdeling | 136 |
| 10.4 Heeft mijn variabele een normale kansverdeling? | 140 |
| 10.5 Wat als mijn variabele niet normaal verdeeld is? | 142 |
| 10.6 Kansverdeling van gemiddelde | 143 |
| 10.7 Betrouwbaarheidsinterval van het gemiddelde | 145 |
| 11 Samenhang | 149 |
| 11.1 Inleiding | 149 |
| 11.2 Pearson product-moment-correlatie | 151 |
| 11.3 Regressie | 154 |
| 11.4 Invloedrijke observaties | 159 |
| 11.5 Spearmans rangorde-correlatie | 160 |
| 11.6 Phi | 162 |
| 11.7 Tenslotte | 165 |
| 12 Betrouwbaarheid | 167 |
| 12.1 Inleiding | 167 |
| 12.2 Wat is betrouwbaarheid? | 167 |
| 12.3 Testtheorie | 170 |
| 12.4 Interpretaties | 172 |
| 12.5 Methoden om betrouwbaarheid te schatten | 174 |
| 12.6 Betrouwbaarheid tussen beoordelaars | 175 |
| 12.7 Betrouwbaarheid en constructvaliditeit | 177 |
| 12.8 SPSS | 178 |
| 12.9 R | 179 |
| A Willekeurige getallen | 181 |
| B Standaard-normale kansverdeling | 183 |

Voorwoord

Data spelen een steeds belangrijker rol, ook in de geesteswetenschappen. De beschikbaarheid van digitale gegevens (o.a. tekst, spraak, video, en gedragsregistraties) leidt tot nieuwe onderzoeksvragen, die vooral met kwantitatieve methoden beantwoord worden. Dit boek biedt onderzoekers en studenten een overzicht en inleiding van de belangrijkste kwantitatieve methoden en statistische technieken in de geesteswetenschappen. Het boek geeft de lezer een stevig methodologisch fundament voor kwantitatief onderzoek, en biedt een inleiding in de meest gebruikte statistische technieken om gegevens te beschrijven en om hypothesen te toetsen. Daarmee is de lezer ook in staat om kwantitatief onderzoek kritisch te beoordelen.

Dit tekstboek wordt gebruikt als leesstof bij de cursus *Methoden en Statistiek 1* aan de Universiteit Utrecht. Het boek is tevens bruikbaar voor zelfstudie op inleidend niveau, voor iedereen die meer wil weten over methoden en statistiek.

De hoofdtekst is gevrijwaard van wiskundige afleidingen en formules, die voor geesteswetenschappers immers weinig bruikbaar zijn. De uitleg is vooral conceptueel, en rijk aan voorbeelden van geesteswetenschappelijk onderzoek. Waar nodig worden formules aangeboden in een aparte paragraaf.

Dit boek bevat ook aanwijzingen over hoe de besproken statistische analyses en visualisaties uitgevoerd kunnen worden in twee veelgebruikte programma's, nl. SPSS (versie 22 en later) en R (versie 3.0 en later). Ook deze aanwijzingen staan los van de hoofdtekst, in afzonderlijke paragrafen.

Graag willen we onze mede-docenten danken voor de vele discussies en voorbeelden die op enige wijze verwerkt zijn in dit tekstboek. Onze studenten danken we voor hun nieuwsgierigheid en nauwkeurigheid die geleid heeft tot deze versie van dit tekstboek.

Ook betonen wij grote dank aan Willemijn Heeren, Gerrit Bloothoof, Marijn Struiksmā, Margot van den Berg, Els Rose, Tobias Quen  en Kirsten Schutter voor hun adviezen, data, en/of commentaar bij eerdere versies.

Utrecht, december 2016 - september 2020

Hugo Quen , <https://www.hugoquene.nl>

Huub van den Bergh

Notatie

In aansluiting op het internationale gebruik en op de conventies van Engelstalige tijdschriften gebruiken we de punt als decimaalteken; we schrijven dus $\frac{3}{2} = 1.5$. Hierbij is een waarschuwing op zijn plaats: het decimale symbool kan verschillen tussen computers, en zelfs tussen programma's op dezelfde computer. Controleer dus welk decimaal symbool gebruikt wordt door (elk programma op) jouw computer.

Licentie

This document is licensed under the *GNU GPL 3* license (for details see <https://www.gnu.org/licenses/gpl-3.0.en.html>). It was created with the `bookdown` package (Xie, 2020) in Rstudio.

Over de auteurs

Beide auteurs zijn verbonden aan de Faculteit Geesteswetenschappen van de Universiteit Utrecht. HQ is hoogleraar Kwantitatieve Methoden van Empirisch Onderzoek in de Geesteswetenschappen, en geeft daarnaast leiding aan het Centre for Digital Humanities. HvdB is hoogleraar Didactiek en Toetsing van het Taalvaardigheidsonderwijs, en is daarnaast vaksectievoorzitter Nederlands bij het College voor Toetsen en Examens (CvTE).

Deel I: Methodologie

Chapter 1

Inleiding

In dit tekstboek worden de grondbeginselen, methoden en technieken van empirisch wetenschappelijk onderzoek besproken, zowel in algemene zin als toegespitst op het brede domein van taal en communicatie. We zullen ons bezighouden met vragen als: Wat is een goede onderzoeksvraag? Welke methode is de beste om de onderzoeksvraag te beantwoorden? Hoe kunnen onderzoekers zinnige en valide conclusies trekken uit (statistische analyses van) hun gegevens? In dit tekstboek beperken we ons tot de belangrijkste grondbeginselen, en tot de belangrijkste methoden en technieken. In dit eerste hoofdstuk zullen we een overzicht geven van verschillende typen en vormen van wetenschappelijk onderzoek. In het vervolg van dit tekstboek geven we de meeste aandacht aan methoden van wetenschappelijk onderzoek waarbij empirische observaties uitgedrukt worden in de vorm van getallen (kwantitatief), die geanalyseerd worden met behulp van statistische technieken.

1.1 Wetenschappelijk onderzoek

Om te beginnen moeten we een vraag stellen die terugslaat op de allereerste zin hierboven: wat is eigenlijk wetenschappelijk onderzoek? Wat is het verschil tussen wetenschappelijk en niet-wetenschappelijk onderzoek (bijv. door onderzoeksjournalisten)? Onderzoek dat een wetenschapper uitvoert, hoeft nog geen wetenschappelijk onderzoek te zijn. Evenmin is journalistiek onderzoek per definitie onwetenschappelijk omdat het door een journalist wordt uitgevoerd. In dit tekstboek hanteren we de volgende definitie (Kerlinger and Lee, 2000, p.14):

“Scientific research is systematic, controlled, empirical, amoral, public, and critical investigation of natural phenomena. It is guided by theory and hypotheses about the presumed relations among such phenomena.”

Wetenschappelijk onderzoek is systematisch en gecontroleerd. Wetenschappelijk onderzoek is zodanig ontworpen dat we geloof kunnen hechten aan de conclusies, omdat die conclusies goed onderbouwd zijn. Het onderzoek kan door anderen herhaald worden, met (hopelijk) dezelfde resultaten. Deze eis van repliceerbaarheid maakt ook dat wetenschappelijk onderzoek zeer nauwgezet wordt ontworpen en uitgevoerd (zie Hoofdstukken 3 en 6). De sterkste vorm van controle is die van een wetenschappelijk experiment; we besteden daarom in dit tekstboek veel aandacht aan experimenteel onderzoek (§1.5). Mogelijke alternatieve verklaringen voor het onderzochte verschijnsel worden één voor één onderzocht en zo mogelijk uitgesloten, zodat tenslotte slechts één verklaring overblijft (Kerlinger and Lee, 2000). Die verklaring vormt dan onze wetenschappelijk onderbouwde conclusie of theorie over het onderzochte verschijnsel.

Ook wordt in de definitie gesteld dat wetenschappelijk onderzoek *empirisch* van aard is. De conclusies die de onderzoeker trekt moeten uiteindelijk gebaseerd zijn op (systematische en gecontroleerde) waarnemingen of observaties van een verschijnsel in de werkelijkheid — bijvoorbeeld op de waargenomen inhoud van een tekst, of op het waargenomen gedrag van een proefpersoon. Als die waarneming ontbreekt, dan kunnen de eventuele conclusies niet logisch verbonden worden met de werkelijkheid, waardoor ze geen wetenschappelijke waarde hebben. Vertrouwelijke gegevens uit een onbekende bron, of inzichten verkregen in een droom of in een mystieke beleving, zijn niet empirisch onderbouwd, en kunnen dus niet de basis vormen van een wetenschappelijke theorie.

1.1.1 Theorie

Het doel van wetenschappelijk onderzoek is te komen tot een theorie over een deel van de werkelijkheid. Die theorie is te zien als een coherente en consistente verzameling van “justified true beliefs” (Morton, 2003). In deze overtuigingen, en in de theorie, wordt geabstraheerd van de complexe werkelijkheid van de natuurlijke verschijnselen, naar een abstract mentaal *construct*, dat uit zijn aard niet rechtstreeks waarneembaar is. Voorbeelden van dergelijke constructen zijn: leesvaardigheid, intelligentie, activatie-niveau, verstaanbaarheid, omvang van iemands actieve woordenschat, schoenmaat, woon-werk-afstand, introvertheid, etc.

Een onderzoeker definieert in een theorie niet alleen verschillende constructen, maar ook specificeert hij de *verbanden* of relaties tussen deze constructen. Pas wanneer zowel de constructen gedefinieerd zijn als de relaties tussen de constructen gespecificeerd zijn, kan een onderzoeker komen tot een systematische verklaring van het onderzochte verschijnsel. Deze verklaring of theorie kan weer de basis zijn van een *voorspelling* over het onderzochte verschijnsel: het aantal gesproken talen op de wereld zal verminderen in de 21e eeuw; teksten zonder voegwoorden zullen moeilijker te begrijpen zijn dan teksten met voegwoorden; kinderen die tweetalig opgroeien zullen niet slechter presteren op school dan eentalige kinderen.

Wetenschappelijk onderzoek is er in vele verschillende typen en vormen, die op verschillende manieren ingedeeld kunnen worden. In de volgende sectie 1.2 bespreken we een indeling op basis van paradigma, de manier waarop de onderzoeker tegen de werkelijkheid aankijkt. Onderzoek kan ook ingedeeld worden op een continuüm van ‘zuiver theoretisch’ naar ‘toegepast’. Een derde manier om onderzoek in te delen is gericht op het type onderzoek, bijvoorbeeld instrumentatieonderzoek (§1.3), beschrijvend onderzoek (§1.4), en experimenteel onderzoek (§1.5).

1.2 Paradigmata

Eén criterium om typen onderzoek te onderscheiden is op basis van het gebruikte paradigma, de manier waarop de onderzoeker tegen de werkelijkheid aankijkt. In dit tekstboek besteden we nagenoeg alleen aandacht aan het empirisch-analytisch paradigma, omdat dit het meest uitgewerkte en meest invloedrijke paradigma is. Heden ten dage kan deze benadering opgevat worden als ‘de’ standaardopvatting, waar andere paradigma’s zich min of meer tegen afzetten.

Binnen het *empirisch-analytische paradigma* onderscheiden we twee varianten: het positivisme en het kritisch-rationalisme. Beide stromingen hebben gemeen dat er aangenomen wordt dat er wetmatigheden zijn die ‘ontdekt’ kunnen worden: verschijnselen kunnen beschreven en verklaard worden in abstracte termen (constructen). Het verschil tussen beide stromingen binnen de empirisch-analytische traditie is gelegen in de pretentie van de uitspraken die gedaan worden. Volgens de positivisten is het mogelijk om uitspraken te doen vanuit feitelijke waarnemingen naar een theorie. Op basis van de observaties kunnen we generaliseren naar een algemeen geldende regel, door middel van inductie. (De vogels die ik zie, die hoor ik ook fluiten, dus alle vogels fluiten.)

De tweede stroming is het kritisch-rationalisme. De aanhangers van deze stroming keren zich tegen bovengenoemde inducties: al hoor ik talloze vogels ook fluiten, dan nog kan ik geen zekerheid verkrijgen over de veronderstelde algemene regel. Maar we kunnen het wel omkeren, en proberen aan te tonen dat de veronderstelde algemene regel of hypothese *niet* juist is. Hoe werkt dat? Op basis van de algemeen geldende regel kunnen we voorspellingen afleiden voor specifieke observaties, door middel van deductie. (Als alle vogels fluiten, dan moet het zo zijn dat alle vogels in mijn steekproef fluiten.) Als niet alle vogels in mijn steekproef fluiten, dan is de algemene regel blijkbaar onjuist. Dit wordt het falsificatie-principe genoemd; we bespreken dat uitgebreider in sectie 2.4.

Ook aan het kritisch-rationalisme kleven echter tenminste twee bezwaren. Met het falsificatieprincipe kunnen waarnemingen (empirische feiten, observaties, onderzoeksresultaten) gebruikt worden om theoretische uitspraken te doen (met betrekking tot hypothesen). Strikt genomen moet een veronderstelde algemene regel meteen verworpen worden na één geslaagde falsificatie (een van de vogels in mijn steekproef fluit niet): als theorie en observatie niet overeenstemmen,

dan faalt de theorie, volgens de kritisch-rationalisten. Maar om te komen tot een observatie moet een onderzoeker vele keuzes maken (bijv.: hoe maak ik een goede steekproef, wat is een vogel, hoe bepaal ik of een vogel fluit?), die de geldigheid van de observaties onzeker kunnen maken. Er kan dus ook iets mis zijn met de waarnemingen zelf (horen), of met de operationalisaties van de gebruikte constructen (vogels, fluiten).

Een tweede probleem is dat er in de praktijk eigenlijk zeer weinig theorieën zijn die werkelijk iets uitsluiten. Wanneer er discrepanties waargenomen worden tussen theorie en observaties, dan wordt de theorie bijgeschaafd, zodat de nieuwe observaties toch weer binnen de theorie passen. Theorieën worden dan ook zelden volledig verworpen.

Een tweede paradigma is de kritische benadering. Het *kritische paradigma* onderscheidt zich van andere paradigmata in de nadruk op maatschappelijke bepaaldheden; ‘de’ werkelijkheid bestaat niet, ons beeld ervan is een voorlopige, door maatschappelijke oorzaken bepaalde werkelijkheid. Inzicht in de maatschappelijke verhoudingen heeft zelf dus ook invloed op die werkelijkheid. Onze wetenschapsopvatting zoals verwoord in bovengenoemde definities van onderzoek en theorie wordt in het kritische paradigma dan ook afgewezen. Kritische onderzoekers menen dat onderzoeksprocessen niet los gezien kunnen worden van de maatschappelijke context waarin het onderzoek is verricht. Deze laatste visie wordt overigens overgenomen door steeds meer onderzoekers, ook door hen die andere paradigmata aanhangen.

1.3 Instrumentatie-onderzoek

Onderzoek is, zoals gezegd, een gesystematiseerde en gecontroleerde wijze om empirische gegevens te verzamelen en te interpreteren. Onderzoekers streven naar inzicht in natuurlijke verschijnselen, en in de wijze waarop (de constructen van) die verschijnselen met elkaar samenhangen. Een voorwaarde hiervoor is dat de onderzoeker deze verschijnselen daadwerkelijk kan meten, d.i. uitdrukken in een observatie (bij voorkeur in de vorm van een getal). Instrumentatieonderzoek is voornamelijk gericht op de constructie van instrumenten of methoden om verschijnselen, gedrag, vaardigheden, attitudes, etc. meetbaar te maken. De ontwikkeling van goede meetinstrumenten is bepaald geen sinecure: het is ambachtelijk handwerk, waarbij de constructeur vele valkuilen moet zien te vermijden. Het meetbaar maken van verschijnselen, van gedrag of van constructen noemen we de *operationalisatie*. Een concrete leestoets is bijvoorbeeld op te vatten als een operationalisatie van het abstracte construct ‘leesvaardigheid’.

We kunnen een nuttig onderscheid maken tussen het abstracte theoretische construct en het gemeten construct, ofwel een onderscheid tussen: het begrip-zaals-bedoeld en het begrip-zaals-bepaald. Het is uiteraard de bedoeling dat het begrip-zaals-bepaald (de toets, de vragenlijst, de observatie) het begrip-zaals-bedoeld (het theoretische construct) zo goed mogelijk benadert. Indien het

theoretische construct goed wordt benaderd, dan spreken we van een adequate of valide meting.

Bij operationalisatie van een begrip-zoals-bedoeld moeten talloze keuzen gemaakt worden. Zo moet het CITO (Centraal instituut voor toetsontwikkeling) elk jaar tekstbegripstoetsen construeren om de leesvaardigheid van eindexamenkandidaten te meten. Daarvoor moet allereerst een tekst gekozen of geredigeerd worden. Deze tekst mag niet te moeilijk, maar ook niet te makkelijk zijn voor de doelgroep. Voorts mag het onderwerp van de tekst niet al te bekend zijn, omdat anders de bij sommige leerlingen aanwezige algemene kennis kan interfereren met de meningen en standpunten die in de tekst naar voren gebracht worden. Vervolgens moeten de vragen zó ontworpen worden dat de verschillende passages in de tekst aan bod komen. Ook moeten de vragen zó samengesteld zijn dat het theoretische construct ‘leesvaardigheid’ adequaat geoperationaliseerd wordt. Tot slot moet ook nog rekening gehouden worden met de examens uit voorafgaande jaren; het nieuwe examen mag immers niet al te veel afwijken van oude examens.

Een construct moet dus op de juiste wijze geoperationaliseerd zijn, om observaties te verkrijgen die niet alleen valide zijn (een goede benadering van het abstracte construct, zie Hoofdstuk 5) maar die ook betrouwbaar zijn (ongeveer gelijke observaties bij herhaalde meting, zie Hoofdstuk 12). In ieder onderzoek zijn de validiteit en de betrouwbaarheid van een meting cruciaal; we besteden dan ook twee hoofdstukken aan deze begrippen. Maar in instrumentatieonderzoek zijn deze begrippen zelfs essentieel, omdat dit type onderzoek juist beoogt om valide en betrouwbare instrumenten te leveren, die een goede operationalisatie zijn van het abstracte construct-zoals-bedoeld.

1.4 Beschrijvend onderzoek

Met beschrijvend onderzoek bedoelen we onderzoek dat voornamelijk gericht is op de beschrijving van een bepaald natuurlijk verschijnsel in de werkelijkheid. De onderzoeker richt zich dus vooral op een *beschrijving* van het verschijnsel: het huidige vaardigheidsniveau, het verloop van een proces of een discussie, de wijze waarop de lessen Nederlands in het voortgezet onderwijs vorm worden gegeven, de politieke voorkeur van stemmers vlak voor verkiezingen, de samenhang tussen het aantal uren zelfstudie en het eindcijfer dat een student behaalt, etc. Kortom, ook de onderwerpen voor beschrijvend onderzoek kunnen zeer divers zijn.

Voorbeeld 1.1: (Dingemanse et al., 2013) hebben opnames van conversaties gekozen of gemaakt in 10 talen. Uit die opgenomen conversaties zijn woorden genomen waarmee een luisteraar om “open verduidelijking” vraagt: woordjes als *hè* (Nederlands), *huh* (Engels), *ã?*

(Siwu). Van deze woorden is de klankvorm en het toonhoogteverloop vastgesteld, met akoestische metingen en met fonetische transcripties door experts. Een conclusie van dit beschrijvende onderzoek luidt dat deze tussenvoegsels in de verschillende talen veel meer op elkaar lijken (in klankvorm en toonhoogteverloop) dan op grond van toeval te verwachten is.

Dit voorbeeld illustreert dat beschrijvend onderzoek niet ophoudt als de gegevens (klankvormen, toonhoogteverloop) beschreven zijn. Vaak zijn *verbanden* tussen de verzamelde gegevens ook zeer interessant (zie §1.1). Zo wordt in opiniepeilingen naar het stemgedrag bij verkiezingen vaak een verband gelegd tussen het gepeilde stemgedrag enerzijds, en leeftijd, geslacht en opleidingsniveau van de respondent anderzijds. En evenzo wordt in onderwijskundig onderzoek een verband gelegd tussen aantal uren studietijd enerzijds, en studiesucces van de respondent anderzijds. Dit type van beschrijvend onderzoek, waarbij een correlatie wordt vastgesteld tussen mogelijke oorzaken en mogelijke gevolgen, wordt ook aangeduid als *correlationeel onderzoek*.

Het essentiële verschil tussen beschrijvend en experimenteel onderzoek is gelegen in de vraag naar oorzaak en gevolg. Op basis van beschrijvend onderzoek kan een causaal verband tussen oorzaak en gevolg *niet* goed vastgesteld worden. Uit beschrijvend onderzoek zou kunnen blijken dat er een samenhang is tussen een bepaald soort voeding en een langere levensduur. Is het voedingspatroon dan ook de oorzaak van de langere levensduur? Dat hoeft bepaald niet het geval te zijn: het is ook mogelijk dat dat soort voeding vooral genuttigd wordt door mensen die relatief hoog opgeleid en welvarend zijn, en door deze *andere* factoren ook relatief langer in leven zijn¹. Om vast te kunnen stellen of er een causaal verband is, moeten we experimenteel onderzoek opzetten en uitvoeren.

1.5 Experimenteel onderzoek

Experimenteel onderzoek wordt gekenmerkt doordat de onderzoeker een bepaald aspect van de onderzoeksomstandigheden systematisch varieert (Shadish et al., 2002). Het effect van deze manipulatie staat dan centraal in het onderzoek. Een onderzoeker vermoedt bijvoorbeeld dat een bepaalde nieuwe lesmethode zal resulteren in betere prestatie van de leerlingen dan de huidige lesmethode. De onderzoeker wil deze hypothese toetsen door middel van een experimenteel onderzoek. Hij manipuleert het type onderwijs: sommige klassen of groepen krijgen les volgens de nieuwe experimentele lesmethode en andere klassen of

¹Het is zelfs mogelijk dat het onderzochte voedingspatroon de oorzaak is van een relatief *kortere* levensduur, maar dat dit negatieve effect gemaskeerd wordt door de sterkere, positieve effecten van opleidingsniveau en welvaartsniveau op de levensduur.

groepen krijgen les op de traditionele wijze. Het effect van de nieuwe lesmethode wordt geëvalueerd door de prestaties van de twee soorten schoolklassen te vergelijken, na de ‘behandeling’ met de oude vs. nieuwe lesmethode.

Experimenteel onderzoek heeft als voordeel dat we de onderzoeksresultaten doorgaans mogen interpreteren als het gevolg van de experimentele manipulatie. Omdat de onderzoeker het onderzoek systematisch controleert en slechts één aspect (i.c. de lesmethode) varieert, kunnen eventuele verschillen tussen de prestaties van de twee categorieën alleen toegeschreven worden aan het veranderde kenmerk, i.c. aan de lesmethode. Dit veranderde kenmerk moet dan logischerwijs wel de oorzaak zijn van de geobserveerde verschillen. Experimenteel onderzoek is dus gericht op de evaluatie van causale verbanden.

Deze redenering vereist wel dat proefpersonen (of schoolklassen, in bovenstaand voorbeeld) volgens het toeval, aselekt (Eng. ‘at random’), worden toegewezen aan de experimentele condities (i.c. de oude of nieuwe lesmethode). Deze aselechte toewijzing (Eng. ‘random assignment’) is de beste methode om eventuele niet-relevante verschillen tussen de behandelcondities uit te sluiten. Een dergelijk experiment met aselechte toewijzing van proefpersonen aan condities wordt een *gerandomiseerd experiment* genoemd (Eng. ‘randomized experiment’, ‘true experiment’,). Om bij ons voorbeeld te blijven: als de onderzoeker de oude lesmethode zou inzetten bij jongens, en de nieuwe lesmethode bij meisjes, dan is een eventueel verschil in prestaties niet meer uitsluitend toe te schrijven aan het gemanipuleerde kenmerk (de lesmethode), maar ook aan een niet-gemanipuleerd maar wel relevant kenmerk, hier het geslacht van de leerlingen. Zo’n mogelijk verstorend kenmerk wordt een *storende variabele* (Eng. ‘confound’) genoemd. In Hoofdstuk 6 bespreken we hoe we deze storende variabelen kunnen neutraliseren, door random toewijzing van proefpersonen (of schoolklassen) aan de experimentele condities, in combinatie met andere maatregelen.

Er is ook experimenteel onderzoek waarbij een bepaald aspect (zoals lesmethode) wel systematisch varieert, maar waarbij de proefpersonen of schoolklassen *niet aselekt* zijn toegewezen aan de experimentele condities; dit wordt *quasi-experimenteel* onderzoek genoemd (Shadish et al., 2002). In het bovenstaande voorbeeld is daarvan sprake als de gebruikte lesmethode onderzocht wordt, met gegevens van schoolklassen waarvan niet de onderzoeker maar de docent bepaald heeft of de oude of nieuwe lesmethode gebruikt wordt. Als de nieuwe lesmethode betere prestaties zou opleveren, dan weten we *niet* met zekerheid dat het verschil in prestaties toe te schrijven is aan de lesmethode. Ook het enthousiasme of de werkstijl van de docent kan een storende variabele zijn geweest in dit quasi-experiment. In dit tekstboek zullen we verschillende voorbeelden van quasi-experimenteel onderzoek tegenkomen.

Binnen het type van experimenteel onderzoek kunnen we een verdere verdeling aanbrengen, tussen laboratoriumonderzoek en veldonderzoek. In beide typen experimenteel onderzoek wordt een aspect van de werkelijkheid gemanipuleerd. Het verschil tussen beide typen onderzoek is gelegen in de mate waarin de

onderzoeker in staat is om allerlei storende aspecten van de werkelijkheid onder controle te houden. In laboratoriumonderzoek kan de onderzoeker zeer exact bepalen onder welke omgevingscondities de observaties worden gedaan, en kan de onderzoeker dus ook vele mogelijke storende variabelen onder controle houden (denk aan verlichting, temperatuur, omgevingslawaaï, etc.). In veldonderzoek is dit niet het geval. De onderzoeker is ‘in het vrije veld’ niet in staat om alle (mogelijk relevante) aspecten van de werkelijkheid volledig onder controle te houden.

Voorbeeld 1.2: Margot van den Berg onderzocht samen met collega’s van de Universiteit van Ghana en de Universiteit van Lomé hoe meertalige sprekers hun talen gebruiken als zij eigenschappen zoals kleur, grootte en waarde moeten benoemen door middel van een zogenaamde *Director-Matcher task* (Van den Berg et al., 2017). In deze taak gaf de ene onderzoeksdeelnemer (de directeur) aanwijzingen aan een ander (de uitvoerder) om een reeks voorwerpen in een bepaalde volgorde neer te zetten. Zo konden in een kort tijdsbestek veel voorkomens van eigenschapswoorden worden verzameld (‘Zet de gele auto naast de rode auto maar boven de kleine slipper’). De gesprekken werden opgenomen, uitgeschreven en vervolgens onderzocht op taalkeuze, moment van taalwisseling en type grammaticale constructie. Bij dergelijk veldwerk kunnen echter allerlei niet-gecontroleerde aspecten in de omgeving van invloed zijn op de geluidsopnames, en daarmee op de gegevens: “kakelende kippen, een buurman die z’n motor aan het repareren is en ’m om de haverklap moet starten terwijl je een gesprek aan het opnemen bent, keiharde regen op het aluminium dak van het gebouw waar de interviews plaats vinden.” (Margot van den Berg, pers.comm.)

Voorbeeld 1.3: Bij het luisteren naar gesproken zinnen kunnen we uit de oogbewegingen van een proefpersoon afleiden, hoe die gesproken zinnen worden verwerkt. In een zgn. ‘visual world’-taak krijgen luisteraars een zin te horen (bijv. “Bert zegt dat het konijn is gegroeid”), terwijl ze kijken naar meerdere afbeeldingen op het scherm (meestal 4, bijv. een schelp, pauw, zaag, en wortel). Luisteraars blijken vooral te kijken naar de afbeelding die geassocieerd is aan het woord dat ze op dat moment mentaal verwerken: als ze het woord *konijn* verwerken, dan kijken ze naar de wortel (exacter gezegd: ze kijken vaker en langer naar de wortel dan naar de andere afbeeldingen). Met een zgn. ‘eye tracker’ kan worden vastgesteld naar welke positie van het scherm de proefpersoon kijkt (door observatie van de pupillen).

De onderzoeker kan zo dus observeren welk woord op welk moment mentaal verwerkt wordt (Koring et al., 2012). Dergelijk onderzoek kan het beste uitgevoerd worden in een laboratorium, met controle over achtergrondgeluiden, verlichting, en positie van de ogen t.o.v. computerscherm.

Laboratoriumonderzoek en veldonderzoek hebben beide voordelen en nadelen. Het grote voordeel van laboratoriumonderzoek is natuurlijk de mate waarin de onderzoeker allerlei externe zaken onder controle kan houden. In een laboratorium zal het experiment niet vaak verstoord worden door een startende motor of door een regenbui. Dit voordeel van laboratoriumonderzoek is echter ook een belangrijk nadeel, nl. dat het onderzoek plaatsvindt in een min of meer kunstmatige omgeving. Het is dan nog maar de vraag in hoeverre resultaten die onder kunstmatige omstandigheden verkregen zijn, ook zullen gelden in het leven van alledag buiten het laboratorium. Dit laatste is dan ook een punt in het voordeel van veldonderzoek: het onderzoek wordt verricht onder natuurlijke omstandigheden. Het nadeel van veldonderzoek is dan weer dat er in het veld kan van alles gebeuren wat de onderzoeksresultaten beïnvloedt, maar waar de onderzoeker geen controle over kan houden (zie het bovenstaande voorbeeld). De keuze die een onderzoeker maakt tussen beide typen experimenteel onderzoek wordt uiteraard sterk bepaald door de vraagstelling van het onderzoek. Sommige vraagstellingen laten zich beter in laboratoriumsituaties onderzoeken, terwijl andere beter in veldsituaties onderzocht kunnen worden (zoals bovenstaande voorbeelden illustreren).

1.6 Vooruitblik

Dit tekstboek bestaat uit drie delen. Deel I (hoofdstukken 1 tot en met 7) van dit tekstboek behandelt methoden van onderzoek, en geeft een toelichting bij allerlei termen en begrippen die van belang zijn bij het ontwerpen en opzetten van goed wetenschappelijk onderzoek.

In deel II (hoofdstukken 8 tot en met 12) van het tekstboek behandelen we de beschrijvende statistiek (Eng. ‘descriptive statistics’) en in deel III (hoofdstukken 13 tot en met 17) behandelen we de elementaire technieken uit de toetsende statistiek (Eng. ‘inferential statistics’). Met deze laatste twee delen streven we drie doelen na.

Allereerst willen we dat je in staat bent om artikelen en andere verslagen waarin statistische verwerkings- en toetsingstechnieken zijn gebruikt, kritisch te beoordelen. Ten tweede willen we dat je de noodzakelijke kennis en inzicht hebt in de belangrijkste statistische procedures. Ten derde willen we met deze

statistische delen bereiken dat je in staat bent om zelfstandig statistische bewerkingen uit te voeren voor je eigen onderzoek, bijvoorbeeld voor je stage of eindwerkstuk.

Deze drie doelen zijn geordend in volgorde van belangrijkheid. Wij menen dat een adequate en kritische interpretatie van statistische resultaten en de conclusies die daaraan verbonden kunnen worden van groot belang is voor alle studenten. Om die reden besteden we in dit tekstboek dan ook relatief veel aandacht (in deel I) aan de ‘filosofie’ of methodologie achter de besproken statistische technieken en analyses. Ook geven we aan hoe je de besproken statistische analyses zelf kunt uitvoeren in SPSS (een populair pakket voor statistische analyses) en in R (een wat moeilijker, maar ook krachtiger en veelzijdiger pakket, met stijgende populariteit). Beide statistische pakketten zijn geïnstalleerd in de computerleerzalen van de Faculteit Geesteswetenschappen. SPSS is beschikbaar via SurfSpot.nl voor een sterk gereduceerde prijs. R is vrijelijk beschikbaar via www.R-project.org. Meer achtergrond over het gebruik van R is te vinden via <https://hugoquene.github.io/emlar2020/>.

Chapter 2

Hypothese-toetsend onderzoek

2.1 Inleiding

Veel empirisch onderzoek heeft tot doel om verbanden vast te stellen tussen (vermeende) oorzaken en hun (vermeende) gevolgen. De onderzoeker wil weten of de ene variabele van invloed is op de andere. Het onderzoek toetst de hypothese dat er een verband is tussen de vermeende oorzaak en het vermeende gevolg (zie Tabel 2.1). De beste methode om zo'n causaal verband vast te stellen, en dus om de hypothese te toetsen, is het experiment. Een goed opgezet en goed uitgevoerd experiment is de 'gouden standaard' in veel wetenschappelijke disciplines, omdat het goede waarborgen biedt voor de validiteit van de conclusies (zie Hoofdstuk 5. Anders gezegd: de uitkomsten van een goed experiment vormen de sterkst mogelijke evidentie voor een verband tussen de onderzochte variabelen. Zoals besproken in Hoofdstuk 1 zijn er ook vele andere vormen van onderzoek, en kunnen hypothesen ook op andere wijze en volgens andere paradigmata onderzocht worden, maar we beperken ons hier tot experimenteel onderzoek.

Table 2.1: Mogelijke oorzaken en mogelijke gevolgen.

| onderwerp | vermeende oorzaak | vermeend gevolg |
|-----------|-----------------------------|-----------------------------|
| handel | buitentemperatuur | aantal verkochte ijsjes |
| zorg | type behandeling | mate van herstel |
| onderwijs | lesmethode | prestatie in toets |
| taal | beginleeftijd van onderwijs | mate van taalbeheersing |
| onderwijs | klassegrootte | schoolprestatie algemeen |
| zorg | temperatuur | hoogte van malaria-gebieden |
| taal | leeftijd | spreeksnelheid |

| onderwerp | vermeende oorzaak | vermeend gevolg |
|-----------|--------------------------|--------------------------------|
| zorg | ligtijd voedsel op grond | mate van bacteriële besmetting |

In experimenteel onderzoek wordt het effect onderzocht van een door de onderzoeker gemanipuleerde variabele op een andere variabele. In de inleiding is al een voorbeeld gegeven van een experimenteel onderzoek. Een nieuwe lesmethode werd beproefd door leerlingen te verdelen over twee groepen. De ene groep kreeg les volgens een nieuwe methode, terwijl de andere groep het gebruikelijke onderwijs genoot. De onderzoeker hoopte en verwachtte dat zijn nieuwe lesmethode een gunstig effect zou hebben, d.w.z. dat het zou leiden tot betere prestaties.

In hypothese-toetsend onderzoek wordt nagegaan of de onderzochte variabelen inderdaad met elkaar samenhangen op de verwachte wijze. In deze definitie staan twee termen centraal: ‘variabelen’ en ‘op de verwachte wijze’. Voor dat we nader ingaan op experimenteel onderzoek zullen we deze termen nader beschouwen.

2.2 Variabelen

Wat is een variabele? Grofweg is een variabele een eigenschap van objecten of personen die kan variëren, en die dus verschillende waarden kan aannemen. Laten we twee eigenschappen van personen bekijken: het aantal broers en zussen, en het geslacht van de moeder van die persoon. De eerste eigenschap kan variëren tussen personen, en is dus een variabele (tussen personen). De tweede eigenschap kan niet variëren: als er een moeder is, dan is die altijd en per definitie van het vrouwelijke geslacht. De tweede eigenschap is dus niet een variabele, maar een constante eigenschap.

In onze wereld bestaat bijna alles in een variabele hoeveelheid of hoedanigheid of mate. Ook een eigenschap die lastig te definiëren is, zoals de populariteit van een persoon in een groep, kan een variabele vormen. We kunnen immers personen in een groep rangschikken van meer tot minder populair. Voorbeelden van variabelen zijn er te over:

- van *personen*: hun lengte, hun gewicht, schoenmaat, spreeknelheid, aantal broers en zussen, aantal kinderen, politieke voorkeur, inkomen, geslacht, populariteit in een groep, enz.
- van *teksten*: het totaal aantal woorden (‘tokens’), aantal verschillende woorden (‘types’), aantal spelfouten, aantal zinnen, aantal leestekens, enz.
- van *woorden*: de gebruiksfrequentie, aantal lettergrepen, aantal klanken, grammaticale woordsoort, enz.

- van *objecten* zoals auto's, telefoons, enz.: het gewicht, aantal componenten, energieverbruik, kostprijs, enz.
- van *organisaties*: het aantal werknemers, postcode, omzet, aantal burgers of klanten of patiënten of leerlingen, aantal operaties of diploma's of transacties, rechtsvorm, enz.

2.3 Onafhankelijke en afhankelijke variabelen

In hypothese-toetsend onderzoek kennen we twee soorten variabelen: de afhankelijke en de onafhankelijke variabele. De *onafhankelijke variabele* is dat wat het veronderstelde effect teweeg moet brengen. De onafhankelijke variabele is het aspect dat in een onderzoek door de onderzoeker gemanipuleerd wordt. In het voorbeeld waar een experiment uitgevoerd wordt om het effect van een nieuwe lesmethode te evalueren, vormt die lesmethode de onafhankelijke variabele. Wanneer de prestaties van de leerlingen die de nieuwe lesmethode gevolgd hebben vergeleken worden met de prestaties van leerlingen die alleen traditioneel schrijfonderwijs gevolgd hebben, dan neemt de onafhankelijke variabele twee waarden aan. Deze twee waarden (ook wel *niveau's* genoemd) van de onafhankelijke variabele kunnen we in dit voorbeeld benoemen als “experimenteel” en “controle”, of als “nieuw” en “oud”. We zouden de waarden van de onafhankelijke variabele ook kunnen uitdrukken als een getal, 1 resp. 0. Deze getallen hebben geen numerieke betekenis (we zouden de waarden ook 17 resp. 23 kunnen noemen), maar worden hier enkel gebruikt als willekeurige etiketten om verschillende groepen te onderscheiden. De gemanipuleerde variabele wordt ‘onafhankelijk’ genoemd omdat de gekozen (gemanipuleerde) waarden van deze variabele in een onderzoek niet afhankelijk zijn van iets anders: de onderzoeker is onafhankelijk in zijn of haar keuze van de gekozen waarden. Een onafhankelijke variabele wordt ook wel *factor* of soms *predictor* genoemd.

Het tweede type variabele is de *afhankelijke variabele*. De afhankelijke variabele is de variabele waarvoor we het veronderstelde effect verwachten. De onafhankelijke variabele veroorzaakt dus mogelijkwerwijs een effect op de afhankelijke variabele, of: men veronderstelt dat de waarde van de afhankelijke variabele afhankelijk is van de waarde van de onafhankelijke variabele — vandaar hun benamingen. De afhankelijke variabele is dus datgene wat we meten of observeren. Een geobserveerde waarde van de afhankelijke variabele wordt ook wel *responsie* of *score* genoemd; ook de afhankelijke variabele zelf wordt vaak zo aangeduid. In het voorbeeld waar een experiment uitgevoerd wordt om het effect van een nieuwe lesmethode op de prestaties van leerlingen te evalueren, vormen die prestaties van de leerlingen de afhankelijke variabele. Andere voorbeelden zijn de spreeknelheid, of de score op een vragenlijst, of het aantal malen dat een product verkocht wordt (zie Tabel 2.1). Kortom, in principe kan elke variabele als afhankelijke variabele gebruikt worden. Het is voornamelijk

de vraagstelling die bepaalt welke afhankelijke variabele gekozen wordt, en hoe deze gemeten wordt.

De onafhankelijke en afhankelijke variabelen dienen we overigens nadrukkelijk *niet* te interpreteren als ‘oorzaak’ resp. ‘gevolg’. Het doel van het onderzoek is immers om overtuigend aan te tonen dat er een (causaal) verband bestaat tussen de onafhankelijke en de afhankelijke variabele. In Hoofdstuk 5 zullen we echter zien hoe complex dat is.

De onderzoeker varieert de onafhankelijke variabele en observeert of dit resulteert in verschillen in de afhankelijke variabele. Als de waarden van de afhankelijke variabele verschillen voor en na de manipulatie van de onafhankelijke variabele, dan nemen we aan dat dit een gevolg is van de manipulatie van de onafhankelijke variabele. Er is sprake van een relatie tussen beide variabelen. Als de waarde van de afhankelijke variabele niet verschilt onder invloed van de waarden van de onafhankelijke variabele, dan is er geen verband tussen beide variabelen.

Voorbeeld 2.1: (Quené et al., 2012) onderzochten of een glimlach of frons invloed heeft op hoe luisteraars gesproken woorden verwerken. De woorden werden door de computer uitgesproken (gesynthetiseerd) in verschillende fonetische varianten, en wel op zo’n manier dat die woorden klonken alsof ze neutraal, of met een glimlach, of met een frons waren uitgesproken. Luisteraars moesten de woorden zo snel mogelijk classificeren als ‘positief’ danwel ‘negatief’ (qua betekenis). In dit onderzoek vormt de fonetische variant (neutraal, glimlach, frons) de onafhankelijke variabele, en de snelheid waarmee de luisteraars oordelen vormt de afhankelijke variabele.

2.4 Falsificatie en nul-hypothese

Het doel van wetenschappelijk onderzoek is om te komen tot een coherente verzameling van “justified true beliefs” (Morton, 2003). Een wetenschappelijke overtuiging moet dus deugdelijk onderbouwd en gerechtvaardigd zijn (en coherent met andere overtuigingen). Hoe komen we tot zo’n goede onderbouwing en rechtvaardiging? Daarvoor moeten we eerst terug naar het zgn. inductieprobleem van (Hume, 1739). Hume constateerde dat het logisch onmogelijk is om een bewering te generaliseren van een aantal specifieke gevallen (de waarnemingen in een onderzoek) naar een algemene regel (alle mogelijke waarnemingen in het universum).

Het probleem met deze generalisatie of inductie zullen we illustreren met de overtuiging ‘alle zwanen zijn wit’. Als ik 10 zwanen heb gezien die allemaal wit zijn, dan zou ik dat kunnen beschouwen als een onderbouwing voor deze overtuiging. Deze generalisatie zou echter ook onterecht kunnen zijn: misschien bestaan er ook niet-witte zwanen, al heb ik die niet gezien. Meer algemeen: de inductie van specifieke waarnemingen naar een generalisatie houdt altijd een risico in, en kan niet gedaan worden “met behoud van waarheid”. Er zit dus altijd een logische ‘sprong’ in, waardoor de generalisatie niet zonder risico is. Een regel die wel opgaat voor alle waargenomen specifieke gevallen (‘alle zwanen zijn wit’) hoeft daarmee nog niet een algemene regel te zijn. Hetzelfde inductieprobleem blijft bestaan als ik 100 of 1000 witte zwanen heb gezien. Maar wat als ik één zwarte zwaan heb gezien? Dan weet ik meteen, met zekerheid, dat de overtuiging dat alle zwanen wit zijn, niet waar is. Dit principe gebruiken we ook in wetenschappelijk onderzoek.

Laten we terugkeren naar ons eerdere voorbeeld waarin we hebben verondersteld dat een nieuwe lesmethode beter is dan een oude lesmethode; deze overtuiging noemen we H1. Laten we deze redenering nu eens omdraaien, en ons baseren op de complementaire overtuiging¹ dat de nieuwe methode *niet* beter is dan de oude; deze overtuiging noemen we de nul-hypothese of H0. Deze overtuiging H0 ‘alle methoden hebben gelijk effect’ is analoog aan de overtuiging ‘alle zwanen zijn wit’ uit het voorbeeld in de vorige alinea. Hoe moeten we nu toetsen of de overtuiging of hypothese H0 waar is? Laten we daarvoor een representatieve steekproef van leerlingen trekken (zie Hoofdstuk 7), en laten we de leerlingen volgens het toeval toewijzen aan de nieuwe of oude lesmethode (waarden van onafhankelijke variabele); we observeren vervolgens alle prestaties (afhankelijke variabele) van alle deelnemende leerlingen, volgens hetzelfde protocol voor alle gevallen. Vooralsnog veronderstellen we dat H0 waar is. We verwachten dus ook geen verschil tussen de prestaties van de verschillende groepen leerlingen. Als de leerlingen van de nieuwe methode desalniettemin veel beter blijken te presteren dan de leerlingen van de oude methode, dan vormt dat waargenomen verschil de figuurlijke zwarte zwaan: het gevonden verschil (dat in tegenspraak is met H0) maakt het onwaarschijnlijk dat H0 waar is (*mits* het onderzoek valide was; meer daarover in het volgende hoofdstuk). Omdat H0 en H1 elkaar uitsluiten, is het dan dus ook erg waarschijnlijk dat H1 wèl waar is. En omdat we onze onderbouwing baseerden op H0 en niet op H1, kunnen sceptici ons niet van partijdigheid beschuldigen: we probeerden immers juist aan te tonen dat er géén verschil was tussen de prestaties van de leerlingen uit de twee groepen.

Deze methode wordt *falsificatie* genoemd, omdat we kennis verwerven door hypothesen te verwerpen (falsifiëren) en niet door hypothesen te aanvaarden (verifiëren). Deze methodologie is ontwikkeld door de wetenschapsfilosoof Karl Popper (Popper, 1935, 1959, 1963). De falsificatie-methode heeft interessante overeenkomsten met de evolutietheorie. Door variatie tussen de individuen kun-

¹Twee beweringen zijn complementair als ze elkaar wederzijds uitsluiten, zoals H1 en H0 in dit voorbeeld.

nen sommigen zich succesvol voortplanten, terwijl veel anderen voortijdig sterven en/of zich niet voortplanten. Op analoge wijze kunnen sommige tentatieve beweringen niet weerlegd worden, en kunnen deze dus ‘overleven’ en ‘zich voortplanten’, terwijl veel andere beweringen weerlegd worden en dus ‘sterven’. In de woorden van (Popper, 1963, p.51):

” ... to explain (the world) ... as far as possible, with the help of laws and explanatory theories ...there is no more rational procedure than the method of trial and error — of conjecture and refutation: of boldly proposing theories; of trying our best to show that these are erroneous; and of accepting them tentatively if our critical efforts are unsuccessful.”

Een goede wetenschappelijke bewering of theorie dient dus falsifieerbaar of weerlegbaar of toetsbaar te zijn (Popper, 1963), d.w.z. het moet mogelijk zijn om de onjuistheid van die bewering of theorie aan te tonen. De wetenschappelijke onderbouwing en daarmee de plausibiliteit van een toetsbare bewering neemt toe, naarmate die bewering vaker en onder meer wisselende omstandigheden bestand is gebleken tegen falsificatie. ‘Het klimaat wordt warmer’ is een goed voorbeeld van een bewering die steeds beter bestand blijkt te zijn tegen falsificatie, en die daarmee steeds sterker wordt.

Voorbeeld 2.2: ‘Alle zwanen zijn wit’ en ‘de gemiddelde temperatuur van de aarde stijgt sinds 1900’ zijn falsifieerbare, en daarom wetenschappelijk bruikbare beweringen. Maar hoe zit dat met de volgende beweringen?

- a. Goud lost op in water.
 - b. Zout lost op in water.
 - c. Vrouwen praten meer dan mannen.
 - d. De muziek van Coldplay is beter dan die van U2.
 - e. De muziek van Coldplay verkoopt beter dan die van U2.
 - f. Als een patiënt een duiding van de psychoanalyticus afwijst, dan is dat het gevolg van weerstand omdat de duiding van de psychoanalyticus juist is.
 - g. De stijging van de gemiddelde temperatuur van de aarde is het gevolg van menselijke activiteiten.
-

2.5 De empirische cyclus

In het voorafgaande hebben we op een vrij globale manier kennis gemaakt met experimenteel onderzoek. In deze paragraaf beschrijven we het verloop

van experimenteel onderzoek meer systematisch. Er zijn in de loop der tijd verschillende schema's opgesteld waarin onderzoek in fasen beschreven wordt. De bekendste van deze schema's is waarschijnlijk wel de empirische cyclus van (De Groot, 1961).

In de empirische cyclus worden vijf onderzoeksfasen onderscheiden: de observatiefase, de inductiefase, de deductiefase, de toetsingsfase en de evaluatiefase. In de laatste fase worden tekortkomingen en alternatieve interpretaties geformuleerd. Dit leidt weer tot nieuw onderzoek, waarin opnieuw de serie fasen kan worden doorlopen (vandaar 'cyclus'). Deze vijf onderzoeksfasen zullen wij één voor één behandelen.

2.5.1 observatie

In deze fase construeert de onderzoeker een probleem. Dat wil zeggen dat de onderzoeker een idee vormt over de mogelijke relaties tussen verschillende (theoretische) concepten of constructen. Deze veronderstellingen worden later uitgewerkt tot meer algemene hypothesen. Veronderstellingen kunnen op duizenden manieren tot stand komen — maar vereisen altijd nieuwsgierigheid van de onderzoeker. De onderzoeker kan een vreemd fenomeen opmerken dat verklaard moet worden, bv het fenomeen dat het vermogen om absolute toonhoogte te horen ("absoluut gehoor") veel vaker voorkomt bij Chinezen dan bij Amerikanen (Deutsch, 2006). Ook het systematisch doorzoeken van wetenschappelijke publicaties kan leiden tot veronderstellingen. Soms blijkt dan dat de resultaten van verschillende onderzoeken elkaar tegenspreken, of dat er een duidelijke lacune zit in onze kennis.

Veronderstellingen kunnen ook gebaseerd zijn op case-studies: onderzoeken waarbij één of enkele gevallen intensief bestudeerd en extensief beschreven worden. Zo ontwikkelde Piaget zijn theorie over de verstandelijke ontwikkeling van kinderen op basis van observaties van zijn eigen kinderen in de tijd dat hij werkloos was. Deze observaties vormden later, toen Piaget zijn eigen laboratorium had, aanleiding voor vele experimenten op basis waarvan hij zijn theoretische inzichten kon verdiepen en verifiëren.

Het is belangrijk om te beseffen dat puur onbevangen, objectieve waarneming niet mogelijk is. Waarnemingen zijn altijd min of meer theorie-geladen of kennis-geladen. Als we niet weten waarop we moeten letten, kunnen we ook niet goed waarnemen. Zo kunnen wolken-experts veel meer typen van bewolking onderscheiden en interpreteren dan leken. Voordat er observaties gedaan worden en feiten worden geanalyseerd, is het dus verstandig om eerst een expliciet theoretisch kader aan te brengen, ook al is dit nog rudimentair.

Een onderzoeker komt tot veronderstellingen naar aanleiding van opmerkelijke verschijnselen, case-studies, literatuurstudie, e.d. Er zijn echter geen methodologische richtlijnen over hoe dit proces zou moeten verlopen: het is een creatief proces.

2.5.2 inductie

In de inductiefase wordt de in de observatiefase geopperde veronderstelling gegeneraliseerd. Op grond van specifieke observaties wordt nu een hypothese geopperd waarvan de onderzoeker vermoedt dat die algemeen geldig is. (**Inductie** is de logische stap waarbij een algemene bewering of hypothese wordt afgeleid uit specifieke gevallen: mijn kinderen (hebben) leren praten \rightarrow alle kinderen (kunnen) leren praten.)

Zo kan een onderzoeker uit de observatie dat de vrouwen in zijn/haar omgeving meer praten dan de mannen (meer minuten per etmaal, en meer woorden per etmaal), een algemene hypothese afleiden: H1: vrouwen praten meer dan mannen (zie Voorbeeld 2.2); deze hypothese kan nader ingeperkt worden in tijd en plaats.

De hypothese moet tevens een duidelijk omschreven empirische inhoud hebben, d.w.z. het type of de klasse van observaties moet goed omschreven zijn. Gaat het over alle vrouwen en mannen? Of alleen sprekers van het Nederlands? En hoe zit het met meertalige sprekers? En met kinderen die hun taal nog aan het leren zijn? Die duidelijk omschreven inhoud is nodig om de hypothese te kunnen toetsen (zie subsectie Toetsing hieronder, en zie Hoofdstuk ??).

Tenslotte moet een hypothese ook logisch coherent zijn, d.w.z. de hypothese moet aansluiten bij andere theorieën of hypothesen. Als een hypothese niet logisch coherent is, dan kan zij per definitie niet eenduidig aan de empirie gerelateerd worden, en is zij dus niet goed toetsbaar. Hieruit volgt dat een hypothese niet multi-interpretabel mag zijn: een hypothese moet op zichzelf één en niet meer dan één uitkomst van een experiment voorspellen.

In het algemeen worden drie typen hypothesen onderscheiden (De Groot, 1961):

- Universeel-deterministische hypothesen.
Deze hebben als algemene vorm: *alle A's zijn B's*. Bijvoorbeeld: alle zwanen zijn wit, alle (volwassen) mensen kunnen spreken. Als een onderzoeker voor één A kan aantonen dat deze niet B is, dan is de hypothese in beginsel gefalsificeerd. Een universeel deterministische hypothese kan nooit geverifieerd worden; een onderzoeker kan alleen een uitspraak doen over de gevallen die hij geobserveerd, dan wel gemeten heeft. Bij een oneindige verzameling, zoals: alle vogels, of alle mensen, of alle kachels, kan dit tot problemen leiden. De onderzoeker weet niet of er misschien één enkel geval bestaat waarin geldt: A is niet B; er is één vogel die niet kan vliegen, et cetera. Over deze andere gevallen kan dus geen uitspraak gedaan worden, waardoor de universele geldigheid van de hypothese nooit volledig 'bewezen' kan worden.
- Deterministische existenthypothesen.
Deze hebben als algemene vorm: *er is tenminste één A die B is*. Bijvoorbeeld: er is tenminste één zwaan die wit is, er is tenminste één mens

die kan praten, er is tenminste één kachel die warmte geeft. Als een onderzoeker kan aantonen dat er één A is die B is, dan is de hypothese geverifieerd. Deterministische existentiehypothesen kunnen echter nooit gefalsificeerd worden. Daarvoor zou het nodig zijn om van een oneindige verzameling alle eenheden of individuen te onderzoeken op het al dan niet B zijn, en dat is door de oneindigheid van de verzameling nu juist uitgesloten. Hieruit blijkt tegelijk dat dit type hypothesen geen algemene uitspraken doen, en dat het wetenschappelijk belang ervan niet zo duidelijk is. Je kunt het ook zo zeggen: voor elk specifiek geval A doet een dergelijke hypothese helemaal geen duidelijke voorspelling; een gegeven A zou de gezochte B kunnen zijn, maar dat hoeft helemaal niet. In deze zin voldoet een deterministische existentiehypothese dan ook niet aan ons criterium van falsificatie.

- Probabilistische hypothesen.

Deze hebben als algemene vorm: *er zijn relatief meer A's die B zijn, dan niet-A's die B zijn*. In de gedragswetenschappen (inclusief taal en communicatie) is dit verreweg het meest voorkomende type hypothese.

Bijvoorbeeld: er zijn relatief meer vrouwen die veelpratend zijn dan mannen die veelpratend zijn. Of: er zijn relatief meer hoog-presterende leerlingen bij de nieuwe methode dan bij de oude methode. Of: versprekingen treden relatief vaker op bij het begin dan bij het einde van een woord. Daarmee wordt nog niet aangegeven dat alle vrouwen meer praten dan alle mannen, en evenmin wordt aangegeven dat alle leerlingen met de nieuwe methode beter presteren dan alle leerlingen van de oude methode.

2.5.3 deductie

In deze fase van de empirische cyclus worden specifieke voorspellingen afgeleid uit de algemeen geformuleerde hypothese die is opgezet in de inductiefase. (**Deductie** is de logische stap waarbij een specifieke bewering of voorspelling wordt afgeleid uit een meer algemene bewering: alle kinderen leren praten \rightarrow mijn kinderen (zullen) leren praten.)

Laten we veronderstellen (H1) dat “vrouwen meer praten dan mannen”. Uit deze hypothese doen we in deze fase specifieke voorspellingen voor specifieke steekproeven. Wanneer we bijvoorbeeld 40 vrouwelijke en 40 mannelijke docenten Nederlands zouden interviewen, zonder tijdsbeperking, dan luidt de voorspelling op grond van deze H1 dat de vrouwelijke docenten in deze steekproef meer zullen zeggen dan de mannelijke docenten in de steekproef (en dus ook, dat ze een groter aantal lettergrepen zullen spreken in het interview).

Zoals hierboven uitgelegd (§2.4), wordt in het meeste wetenschappelijk onderzoek echter niet de H1 getoetst, maar de logische tegenhanger daarvan, die met H0 wordt aangeduid. Voor de toetsing (in de volgende fase van de empirische cyclus) is het dus gebruikelijk om voorspellingen te toetsen die zijn afgeleid uit

de H_0 (!), bijvoorbeeld “vrouwen en mannen produceren *even veel* lettergrepen in een vergelijkbaar interview”.

In de praktijk worden de termen ‘hypothese’ en ‘voorspelling’ vaak door elkaar gebruikt, en spreken we vaak over het toetsen van hypothesen. Volgens bovenstaande terminologie toetsen we echter niet de hypothesen, maar leiden we uit de hypothesen voorspellingen af (via deductie), en toetsen we daarna die voorspellingen aan de data.

2.5.4 toetsing

In deze fase verzamelen we empirische observaties en vergelijken we die met de uitgewerkte voorspellingen “onder H_0 ”, d.w.z. de voorspellingen als H_0 waar zou zijn. In Hoofdstuk ?? zullen we nader ingaan op deze toetsing. Hier introduceren we alleen het algemene principe om nulhypothese te toetsen. (Naast het hier beschreven conventionele “frequentistische” principe kunnen we ook hypothesen toetsen of vergelijken op een nieuwere “Bayesiaanse” wijze; we bespreken die in §??).

Als de observaties buitengewoon onwaarschijnlijk zijn onder H_0 , dan zijn er twee logische mogelijkheden. (i) De observaties deugen niet, we hebben fout geobserveerd. Maar als de onderzoeker zijn werk goed gecontroleerd heeft en zichzelf serieus neemt, dan is dat niet waarschijnlijk. (ii) De voorspelling was onjuist, H_0 is wellicht niet juist, en moet dus verworpen worden, ten gunste van H_1 .

In ons voorbeeld hierboven (in de voorgaande subsectie over deductie) hebben we uit H_0 (!) de voorspelling afgeleid dat in een steekproef van 40 mannelijke en 40 vrouwelijke docenten, de leden van de twee groepen even veel lettergrepen gebruiken in een gestandaardiseerd interview. We vinden echter dat de mannen meer lettergrepen gebruiken (gemiddeld 4210 lettergrepen) dan de vrouwen (gemiddeld 3926 lettergrepen) (Quené, 2008, p.1112). Hoe waarschijnlijk is dit verschil als de observaties kloppen, en als H_0 waar zou zijn? Die kans is zodanig klein dat de onderzoeker H_0 verworpt (zie optie (ii) hierboven), en concludeert dat vrouwen en mannen *niet even veel* praten, althans in dit onderzoek.

In het bovenstaande voorbeeld worden in de toetsingsfase twee groepen vergeleken, hier mannen en vrouwen. Eén van die twee groepen is vaak een neutrale groep of controle-groep, zoals we al zagen in het eerdere voorbeeld van de nieuwe en oude lesmethode. Waarom maken onderzoekers vaak gebruik van zo’n controle-groep? Stel je eens voor dat we alleen de nieuwe-methode-groep zouden onderzoeken. In de toetsingsfase meten we de prestaties van de leerlingen, en die is ruim voldoende: gemiddeld een 7. Is de nieuwe methode dan een succes? Misschien niet: als de leerlingen volgens de oude methode een 8 zouden behalen, dan zou de nieuwe methode eigenlijk slechter zijn, en zouden we de nieuwe methode beter niet kunnen invoeren. Om daar een zinnige conclusie over te kunnen trekken, is het essentieel om de nieuwe en

oude methoden onderling te vergelijken. Vandaar dat in veel onderzoek een neutrale conditie, nul-conditie, controle-groep, placebo-behandeling, o.i.d, is opgenomen.

Hoe kunnen we nu de kans bepalen op de gevonden observaties, als H_0 waar zou zijn? Dat is vaak wat complex, maar we illustreren het hier met een eenvoudig voorbeeld. We gooien kop of munt met een munt. We veronderstellen (H_0): de munt is eerlijk, de kans op kop is $1/2$ per worp. We gooien $10\times$ met dezelfde munt, en wonderbaarlijk genoeg observeren we alle $10\times$ een kop als uitkomst. De kans dat dit gebeurt, als H_0 waar is, is $P = (1/2)^{10} = 1/1024$. Als H_0 waar zou zijn is deze uitkomst uiterst onwaarschijnlijk (al is de uitkomst niet onmogelijk, want $P > 0$), en daarom verwerpen we H_0 . We concluderen dus dat de munt waarschijnlijk niet eerlijk is.

Dit roept een belangrijk punt op: wanneer is een uitkomst zò onwaarschijnlijk dat we H_0 verwerpen? Welk criterium hanteren we voor de kans op de gevonden observaties als H_0 waar zou zijn? Dit is de vraag naar het significantieniveau, d.w.z. het kansniveau waarbij we besluiten de H_0 te verwerpen. Dit wordt aangeduid met symbool α . Als in een onderzoek een significantieniveau gehanteerd wordt van $\alpha = 0.05$, dan wordt de H_0 verworpen als de kans om deze resultaten te vinden als H_0 waar is², kleiner is dan 5%. De uitkomst is dan zo onwaarschijnlijk, dat we ervoor kiezen om H_0 te verwerpen (optie (ii) hierboven), d.w.z. we concluderen dat H_0 waarschijnlijk *niet* waar is.

Als we H_0 aldus verwerpen, dan lopen we wel een kleine kans dat we eigenlijk met optie (i) te maken hebben: H_0 is waar, maar de observaties wijken *toevallig* sterk af van de voorspelling op basis van H_0 , en H_0 wordt dan ten onrechte verworpen. Dit wordt een Type-I-fout genoemd. Deze fout is vergelijkbaar met de onterechte veroordeling van een onschuldig persoon, of met de onjuiste classificatie van een onschuldig email-bericht als ‘spam’. Meestal wordt $\alpha = .05$ gebruikt, maar ook andere significantie-niveau’s zijn mogelijk en soms verstandiger.

Merk op dat de significantie betrekking heeft op de kans om de gevonden extreme gegevens (of meer extreme gegevens) te vinden, indien H_0 waar is:

$$\text{significantie} = P(\text{data}|\mathbf{H_0})$$

De significantie is dus *niet* de kans dat H_0 waar is als je deze gegevens gevonden hebt, $P(H_0|\text{data})$, hoewel we deze denkfout vaak tegenkomen.

Bij iedere vorm van toetsing is er ook een kans op de omgekeerde fout, nl. dat we H_0 ten onrechte niet verwerpen. Dat wordt een Type-II-fout genoemd: H_0 is eigenlijk niet waar (dus H_1 is waar) maar H_0 wordt desalniettemin niet verworpen. Deze fout is vergelijkbaar met de onterechte vrijspraak van een schuldig persoon, of met het onterecht goedkeuren van een *spam* email-bericht (zie Tabel 2.2).

²Vollediger: Als de kans om deze resultaten te vinden, of resultaten die nog meer verschillen van de door H_0 voorspelde resultaten, kleiner is dan 5%, dan wordt H_0 verworpen.

Table 2.2: Mogelijke uitkomsten van beslissingsprocedure.

| werkelijkheid | | |
|------------------------------|------------------------------|--------------------------------|
| | H0 verworpen | H0 niet verworpen |
| H0 is waar (H1 onwaar) | Type-I-fout (α) | correct |
| H0 is onwaar (H1 waar) | correct | Type-II-fout (β) |
| | verdachte veroordeeld | verdachte vrijgesproken |
| verdachte is onschuldig (H0) | Type-I-fout | correct |
| verdachte is schuldig | correct | Type-II-fout |
| | bericht weggegooid | bericht doorgestuurd |
| bericht is OK (H0) | Type-I-fout | correct |
| bericht is spam | correct | Type-II-fout |

Als we het significantieniveau hoger instellen, bv. $\alpha = .20$, dan is de kans om de H_0 te verwerpen dus ook veel groter. In de toetsingsfase verwerpen we immers H_0 al indien de kans op deze gegevens (of meer extreme gegevens) kleiner is dan 20%. Een uitkomst van $8 \times$ kop in 10 worpen is dan al voldoende om H_0 te verwerpen (d.i. om de munt als onzuiver te beoordelen). Er zijn dus meer uitkomsten mogelijk waarbij we H_0 zullen verwerpen. Dat hogere significantieniveau houdt dus een groter risico in op een Type-I-fout, en tegelijk een kleiner risico op een Type-II-fout. De afweging tussen de twee typen fouten hangt af van de precieze omstandigheden van het onderzoek, en van de consequenties van de twee typen van fouten. Welke fout is ernstiger: een goed bericht weggooien, of een *spam*-bericht doorsturen? De kans op een Type-I-fout (significantieniveau) heeft een onderzoeker in eigen hand. De kans op een Type-II-fout is afhankelijk van drie factoren, en is lastig te bepalen. We zullen dat nader bespreken in Hoofdstuk ??.

2.5.5 evaluatie

Aan het einde van het onderzoek moet de onderzoeker de onderzoeksresultaten evalueren: wat is het nu allemaal waard? Het draait hier niet slechts om de vraag of de onderzoeksresultaten al dan niet ten gunste van de getoetste theorie uitgevallen zijn. Het gaat om een kritische beschouwing van de wijze waarop de data zijn verzameld, de denkstappen, de operationalisatie, de mogelijke alternatieve verklaringen, alsmede de consequenties van de resultaten. De resultaten moeten in een bredere context geplaatst en besproken worden. Wellicht leiden de conclusies ook tot aanbevelingen, bijvoorbeeld voor klinische toepassingen of voor de onderwijspraktijk. Dit is ook het moment om suggesties voor ander of vervolgonderzoek te doen.

In deze fase gaat het primair om de interpretatie van de resultaten, waarbij de onderzoeker als interpretator een belangrijke en persoonlijke rol speelt. Verschillende onderzoekers kunnen dezelfde uitkomsten geheel anders interpreteren. En

soms zijn de resultaten in tegenspraak met wat was voorspeld of gewenst.

2.6 Keuzemomenten

Onderzoek bestaat uit een reeks van keuze-momenten: van de inspirerende observaties in de eerste fase, via de operationele beslissingen in de uitvoering van het onderzoek, tot de interpretatie van de resultaten in de laatste fase. Zelden zal een onderzoeker in staat zijn om altijd de beste keuze te maken, maar hij of zij moet er voor waken dat ergens een slechte keuze gemaakt zou worden. Het hele onderzoek is net zo sterk als de zwakste schakel: de waarde van het hele onderzoek hangt af van de slechtste keuze in de reeks van keuzes. Ter illustratie geven we een beeld van de keuzes die een onderzoeker moet maken tijdens de gehele empirische cyclus.

De eerste keuze die gemaakt moet worden betreft de probleemstelling. Relevante vragen die de onderzoeker op dit moment moet beantwoorden zijn: hoe herken ik een bepaalde onderzoeksvraag, is onderzoek hier het aangewezen middel, is dit idee onderzoekbaar? De beantwoording van dergelijke vragen is van allerlei factoren afhankelijk, zoals mens- en maatschappijvisie, wensen van de opdrachtgever, financiële en praktische mogelijkheden, enz.

De onderzoeksvraag moet wel te beantwoorden zijn met de beschikbare methoden en middelen. Maar binnen die beperking kan de onderzoeksvraag elk aspect van de werkelijkheid betreffen, ongeacht of dit aspect nu irrelevant of belangrijk wordt geacht. Er zijn vele voorbeelden van onderzoek dat aanvankelijk werd afgedaan als irrelevant, maar dat desondanks wel degelijk van wetenschappelijke waarde bleek te zijn, bijvoorbeeld een studie over de vraag “is ‘Huh?’ a universal word?” (Dingemanse et al., 2013) (Voorbeeld 1.1). Ook bleken ideeën die eerst als onjuist werden afgedaan later toch te kloppen met de werkelijkheid. Zo beweerde Galilei, zogenaamd ‘ten onrechte’, dat de aarde om de zon draaide. Kortom, onderzoeksvragen moeten niet te snel verworpen worden omdat zij ‘nuteloos’, een ‘open deur’, ‘irrelevant’ of ‘triviaal’ zouden zijn.

Als de onderzoeker besluit om verder te gaan met het onderzoek, dan is de volgende stap doorgaans literatuurstudie. In de meeste handboeken wordt aanbevolen veel te lezen, maar hoe wordt de literatuur verzameld? Uiteraard moet de relevante onderzoeksliteratuur over het probleemgebied doorgenomen worden. Gelukkig bestaan er tegenwoordig allerlei hulpmiddelen om relevante wetenschappelijke publicaties te vinden. Het is raadzaam om daarvoor de aanwijzingen en zgn. “libguides” te bestuderen die de Universiteitsbibliotheek aanbiedt (zie <http://www.uu.nl/bibliotheek>, en <http://libguides.library.uu.nl>). Ook de gids van (Sanders, 2011) bevelen we ten eerste aan: de gids bevat vele uiterst nuttige aanwijzingen over het opsporen van relevante onderzoeksliteratuur.

In de fase daarna doemen de eerste methodologische problemen op. De onderzoeker moet namelijk de probleemstelling exacter formuleren. Een belangrijke

afweging die hier gemaakt dient te worden is of de probleemstelling wel onderzoekbaar is (§2.4). Een vraag als “wat is het effect van beginleeftijd van leren op de taalvaardigheid in een vreemde taal?” is bijvoorbeeld niet zonder meer onderzoekbaar. Deze vraag moet nader gespecificeerd worden. Cruciale concepten moeten ge(her)definieerd worden: wat is de beginleeftijd van het leren van een vreemde taal? Wat is taalvaardigheid? Wat is een effect? En wat is eigenlijk een vreemde taal? Hoe definieer ik de populatie? De onderzoeker wordt geconfronteerd met allerlei vragen over definities en operationalisatie: Worden begrippen theoretisch of empirisch of pragmatisch gedefinieerd? Welke instrumenten worden gebruikt om de verschillende constructen te meten? Maar ook: hoe ingewikkeld moet het onderzoek worden? Kan het hele onderzoek dan wel tot een goed einde worden gebracht? Op welke wijze moeten de gegevens verzameld worden? Kunnen de gewenste gegevens wel verzameld worden, of zullen respondenten dergelijke vragen nooit (kunnen) beantwoorden? Is de voorgestelde manipulatie ethisch verantwoord? Wat is de afstand tussen het theoretische construct en de wijze waarop dat zal worden gemeten? Wanneer in deze fase iets fout gaat, dan heeft dat direct weerslag op de rest van het onderzoek.

Als er met succes een probleemstelling is geformuleerd en geoperationaliseerd, dan volgt een nadere literatuurverkenning. Dit tweede literatuuronderzoek is veel meer toegespitst op de inmiddels uitgewerkte onderzoeksvraag dan de eerder genoemde, brede literatuurverkenning. Op grond van eerdere publicaties kan de onderzoeker zijn of haar oorspronkelijke probleemstelling heroverwegen. Niet alleen moet de literatuur nu doorgenomen worden met het oog op inhoudelijk theoretische overwegingen, maar ook moet aandacht worden besteed aan voorbeelden van operationalisering van de kernbegrippen. Zijn deze begrippen wel goed geoperationaliseerd, en als er verschillende manieren van operationalisering zijn, wat is dan de ratio achter deze verschillen? En, kunnen de kernbegrippen zo geoperationaliseerd worden dat de afstand tussen het begrip-zoals-bedoeld en het begrip-zoals-bepaald (nog) kleiner is (§1.3)? De aanwijzingen hierboven voor het zoeken in wetenschappelijke literatuur zijn hier wederom van nut. De onderzoeker dient zich vervolgens (nogmaals) te beraden op het nut van het onderzoek. Afhankelijk van de probleemstelling moeten vragen gesteld worden als: draagt het onderzoek bij aan de kennis op een bepaald gebied, worden door het onderzoek oplossingen gecreëerd voor ervaren knelpunten of problemen, of draagt het onderzoek bij aan te creëren oplossingen? Voldoet de vraagstelling nog aan het oorspronkelijke probleem (of de oorspronkelijke vraagstelling) van de opdrachtgevers? Zijn er voldoende (technische, financiële, praktische) mogelijkheden om het onderzoek uit te voeren?

In de volgende stap moet worden gespecificeerd hoe de gegevens worden verzameld. Dit is een essentiële stap die van invloed is op de rest van het onderzoek; we wijden er daarom een apart hoofdstuk aan (Hoofdstuk 7). Waaruit bestaat de populatie: uit taalgebruikers? leerlingen? tweetalige babies? versprekingen van medeklinkers? zinnen? En hoe moet je een representatieve steekproef of steekproeven trekken uit deze populatie(s)? Hoe groot moet die steekproef dan zijn? Ook moet er in deze fase gekozen worden voor een analysemethode. Het

is zelfs aan te bevelen om in deze fase al een analyseplan te ontwerpen. Welke analyses zullen worden uitgevoerd, welke exploraties van de gegevens worden voorzien?

Met al deze keuzes zijn de voorbereidingen nog niet afgerond. Ook de instrumenten moeten worden gekozen: welke apparatuur, opname-gereedschap, vragenlijsten, enz., worden gebruikt om waarnemingen mee te doen? Bestaan er al geschikte instrumenten? Zo ja, zijn deze dan makkelijk toegankelijk en mogen zij gebruikt worden? Zo nee, dan moeten instrumenten ontwikkeld worden (§1.3). Maar in dat geval neemt de onderzoeker ook de taak op zich om deze instrumenten eerst te beproeven, om na te gaan of de gegevens die met deze instrumenten verkregen worden, voldoen aan de kwaliteitseisen die de onderzoeker zich gesteld heeft, of die in het algemeen aan de instrumenten in wetenschappelijk onderzoek gesteld mogen worden (in termen van betrouwbaarheid en validiteit, zie Hoofdstukken 5 en 12).

Pas nadat ook de instrumenten in gereedheid gebracht zijn begint het eigenlijke empirische onderzoek: de gekozen gegevens van de gekozen steekproef worden verzameld op de gekozen wijze met behulp van de gekozen instrumenten. Ook hierbij zijn er allerlei, vaak praktische problemen waar de onderzoeker tegenaan loopt. Een waar gebeurd voorbeeld: drie dagen nadat een onderzoeker zijn vragenlijst verstuurd had begon een poststaking die twee weken duurde. Helaas had de onderzoeker de respondenten ook twee weken de tijd gegeven om te reageren. Dus toen de poststaking voorbij was, was de inzendingstermijn verlopen. Wat moest hij toen? Bij gebrek aan alternatieven besloot de onderzoeker alle 1020 respondenten telefonisch te benaderen met het verzoek de vragenlijst alsnog in te vullen en te retourneren.

Voor de onderzoeker die zich de moeite getroost heeft van te voren een analyseplan op te stellen breekt nu de tijd aan om te oogsten. Eindelijk kunnen de geplande analyses ook uitgevoerd worden. Helaas blijkt de werkelijkheid meestal veel weerbarstiger dan de onderzoeker van te voren had bedacht. Proefpersonen geven onverwachte responsies, of houden zich niet aan de instructies, veronderstelde verbanden blijken niet aanwezig, en onverwachte (en ongewenste) verbanden blijken in sterke mate aanwezig. In latere hoofdstukken zullen we dieper ingaan op analysemethoden en problemen daarbij.

Tenslotte moet de onderzoeker ook rapporteren over het onderzoek. Zonder (adequaat) onderzoeksverslag zijn de gegevens niet toegankelijk en had het onderzoek net zo goed *niet* uitgevoerd kunnen worden. Dit is een essentiële stap, waarbij onder meer de vraag gesteld dient te worden of het onderzoek op basis van de verslaglegging controleerbaar en repliceerbaar is. Meestal wordt van onderzoeksactiviteiten verslag gedaan in de vorm van een werkstuk, een onderzoeksrapport of een artikel in een wetenschappelijk tijdschrift. Soms wordt van een onderzoek ook verslag gedaan in een meer populair tijdschrift, dat voor een bredere doelgroep bedoeld is dan alleen collega-onderzoekers.

Tot zover een beknopt overzicht van de keuzen die onderzoekers moeten maken

tijdens hun onderzoek. Ieder empirisch onderzoek bestaat uit een aaneenschakeling van problemen, keuzes en beslissingen. De belangrijkste keuzes zijn al gemaakt voordat de onderzoeker begint met gegevens verzamelen.

Chapter 3

Integriteit

3.1 Inleiding

Wetenschappelijk onderzoek heeft de mensheid onmetelijk grote baten opgeleverd, zoals betrouwbare computer-technologie, goede medische zorg, en begrip van andere talen en culturen. Al deze verworvenheden zijn gebaseerd op wetenschappelijk onderbouwde kennis. Onderzoekers produceren kennis, en de vooruitgang en groei van kennis ontstaat omdat onderzoekers voortbouwen op de ervaringen en inzichten van hun voorgangers.

Voorbeeld 3.1: Sir Isaac Newton schreef over zijn wetenschappelijke werk: “If I have seen further it is by standing on (the) shoulders of Giants” (in een brief aan Robert Hooke d.d. 5 Feb 1676¹). Dit beeld is te herleiden tot de middeleeuwse geleerde Bernard de Chartres: “...nos esse quasi nanos gigantum umeris insidentes” (dat wij zijn als dwergen gezeten op de schouders van reuzen) in vergelijking tot geleerden uit de Oudheid. Newton’s uitspraak is ook het motto van Google Scholar (scholar.google.com), een zoekmachine voor wetenschappelijke publicaties.

In dit hoofdstuk bespreken we de ethische en morele aspecten van wetenschappelijk onderzoek. Wetenschap is mensenwerk, en het vereist

¹Een kopie van de brief is te lezen via http://digitallibrary.hsp.org/index.php/Detail/Object/Show/object_id/9285; voor achtergrond-informatie zie <http://www.bbc.co.uk/worldservice/learningenglish/movingwords/shortlist/newton.shtml>.

een goed ontwikkeld beoordelingsvermogen van de onderzoekers. De *Nederlandse Gedragscode Wetenschappelijke Integriteit* (VSNU, 2018) (http://www.vsnul.nl/wetenschappelijke_integriteit) beschrijft hoe wetenschappelijke onderzoekers (en studenten) zich dienen te gedragen. Volgens deze gedragscode dient wetenschappelijk onderzoek en onderwijs gebaseerd te zijn op de volgende principes:

- eerlijkheid,
- zorgvuldigheid,
- transparantie,
- onafhankelijkheid, en
- verantwoordelijkheid

In de volgende paragrafen zullen we nagaan hoe we volgens deze principes dienen te handelen bij de verschillende fasen van wetenschappelijk onderzoek. Hoe moeten we op eerlijke, zorgvuldige, transparante, onafhankelijke en verantwoordelijke wijze een onderzoek opzetten, de gegevens verzamelen en verwerken, en verslag doen van het onderzoek? We moeten daarover nadenken nog voor het onderzoek begint, en daarom bespreken we deze onderwerpen aan het begin van deze syllabus, hoewel we ook vooruit zullen wijzen naar termen en begrippen die worden uitgewerkt in volgende hoofdstukken.

3.2 Ontwerp

Weliswaar levert wetenschappelijk onderzoek ons onmetelijk grote baten op, maar daar staan ook aanzienlijke kosten tegenover. De directe kosten zijn o.a. de inrichting en onderhoud van laboratoria, apparatuur en technische ondersteuning, maar ook de loonkosten van de onderzoekers, vergoedingen voor informanten en proefpersonen, reiskosten voor toegang tot bibliotheken, archieven, informanten en proefpersonen, e.d. Deze directe kosten worden doorgaans gefinancierd uit publieke middelen van universiteiten en andere wetenschappelijke instellingen. Daarnaast zijn er indirecte kosten, die voor een deel ten laste komen van de informanten en proefpersonen: tijd en moeite die niet aan iets anders besteed kan worden, verlies van privacy, en mogelijke andere risico's die we nog niet kennen. Een vaak vergeten kostenpost is het verlies van onbevangenheid: een proefpersoon die heeft meegedaan aan een experiment leert daarvan, en reageert daarna misschien anders in een volgend experiment (zie §5.4, onder Geschiedenis). De resultaten uit zo'n volgend experiment zijn daardoor minder goed generaliseerbaar naar andere personen die een andere geschiedenis hebben, en *niet* eerder aan een onderzoek hebben meegedaan.

Gezien de grote kosten moet onderzoek zodanig zijn doordacht en ontworpen, dat de verwachte baten redelijkerwijs opwegen tegen de verwachte kosten (Rosenthal and Rosnow, 2008, Ch.3). Als de kans op valide conclusies uit een onderzoek erg klein is, dan is het beter om dat onderzoek *niet* uit te voeren, en zo de directe en indirecte kosten te besparen.

Voorbeeld 3.2: Stel dat we willen onderzoeken of tweetalige kinderen van 4 jaar oud een cognitief voordeel hebben boven eentalige leeftijdsgenoten. Op grond van eerder onderzoek verwachten we een verschil van tenminste 2 punten (op een 10-punts-schaal) tussen beide groepen (met “pooled standard deviation” $s_p = 4$, dus $d = 0.5$, zie § ?? en § ??).

We vergelijken twee groepen van elk $n = 4$ kinderen. Zelfs als er inderdaad een verschil is van 2 punten tussen de twee groepen (dus als de onderzoekshypothese waar is), dan nog is er in dit onderzoek slechts 51% kans om een significant verschil te vinden: de power is slechts .51 (Hoofdstuk ??), omdat de twee groepen zo weinig proefpersonen bevatten. De vierjarige kinderen en hun ouders kunnen beter andere dingen doen (school, thuis, werk) dan meedoen aan dit onderzoek.

Als er echter $n = 30$ kinderen in elk van de twee groepen zouden meedoen, en als er inderdaad een verschil is van 2 punten tussen de twee groepen (dus als de onderzoekshypothese waar is) dan zou de power .90 zijn. Met grotere groepen hebben we dus een veel betere kans om onze onderzoekshypothese te bevestigen. Dit uitgebreide ontwerp van het onderzoek zal meer kosten (voor de onderzoekers en de kinderen en hun ouders), maar levert vermoedelijk ook veel meer op: een valide conclusie met grote maatschappelijke impact.

Het ontwerp van een onderzoek (zie Hoofdstuk 6) moet zo efficiënt mogelijk zijn, en de onderzoeker moet daarover al in een vroeg stadium nadenken. De efficiëntie hangt ten eerste af van keuzes over hoe de onafhankelijke variabelen worden gevarieerd. Is er een aparte groep proefpersonen voor iedere conditie van de onafhankelijke variabele (condities zijn “between subjects”, zoals in voorbeeld 3.2 hierboven? Bij een between-subjects ontwerp met twee groepen zijn er ca $n = (5.6/d)^2$ nodig in elke groep (Gelman and Hill, 2007) (zie §??). Of doen alle proefpersonen mee aan alle condities (condities zijn “within subjects”)? Bij een within-subjects ontwerp met twee condities zijn er dan slechts $n = (2.8/d)^2$

proefpersonen nodig in elke conditie, en het onderzoek heeft dan dus minder directe en indirecte kosten voor veel minder proefpersonen. In het algemeen is het daarom beter om indien mogelijk, onafhankelijke variabelen te variëren binnen proefpersonen, en niet tussen proefpersonen. Toch is dat niet altijd mogelijk, ten eerste omdat individuele kenmerken nu eenmaal alleen verschillen tussen proefpersonen (denk aan: mannelijk/vrouwelijk geslacht, wel/niet meertalige jeugd, wel/niet afasie, enz.). Ten tweede moeten we terdege rekening houden met effecten van ‘transfer’ tussen condities, die de validiteit bedreigen (denk aan: ervaring, leren, vermoeidheid, rijping). We keren hierop terug in §5.3.

Meertaligheid en geslacht zijn kenmerken die alleen tussen personen kunnen variëren. Maar andere condities kunnen ook variëren binnen personen, bijvoorbeeld de dag waarop een cognitieve meting wordt afgenomen. Stel dat we een verschil verwachten van $D = 2$ punten tussen cognitieve metingen afgenomen op maandag of op vrijdag (met $s = 4$ en $d = 0.5$, zie voorbeeld 3.2). Als we de dag van de meting variëren tussen proefpersonen, en dus aparte groepen maken voor de maandag-kinderen en de vrijdag-kinderen, dan zijn er $n = (5.6/0.5)^2 = 126$ kinderen nodig in iedere groep, dus $N = 252$ kinderen in totaal. Als we de dag van de meting echter variëren binnen proefpersonen, en iedere proefpersoon dus observeren zowel op maandag als op vrijdag, dan zijn er in totaal slechts $N = (2.8/0.5)^2 = 32$ kinderen nodig. Met het within-subjects ontwerp hoeven we dus veel minder kinderen lastig te vallen met onze cognitieve meting. Wel moeten we terdege rekening houden met leereffecten tussen de eerste en de tweede meting, en daarvoor gepaste maatregelen treffen. We kunnen bijvoorbeeld niet meer dezelfde vragenlijsten afnemen in beide condities.

De efficiëntie van een onderzoek hangt ook af van de afhankelijke variabele, en met name van het meetniveau (Hoofdstuk ??), de nauwkeurigheid, en de betrouwbaarheid van de observaties (Hoofdstuk 12). Hoe lager het meetniveau, des te lager ook de efficiëntie van het onderzoek. En hoe lager de nauwkeurigheid, des te lager ook de efficiëntie van het onderzoek, en des te meer proefpersonen en observaties zijn er nodig om valide conclusies te kunnen trekken.

Stel dat we een verschil willen onderzoeken tussen twee condities binnen proefpersonen, en stel dat het verschil in werkelijkheid 2 punten bedraagt (met $s_D = 4$ en $d = 0.5$, zie voorbeeld 3.2). We kijken nu echter niet naar de richting en de grootte van het verschil, maar alleen naar de *richting* van het verschil tussen de twee observaties per proefpersoon: heeft die proefpersoon een positief of een negatief verschil tussen de eerste en de tweede conditie? Deze binomiale afhankelijke variabele bevat minder informatie dan de oorspronkelijke puntenscore (nl. alleen de richting, en niet de grootte van het verschil), en het onderzoek is daardoor dus minder efficiënt. We hebben daarom in dit specifieke voorbeeld niet 34 maar tenminste 59 proefpersonen nodig.

Onderzoekers zijn dus verantwoordelijk om de kosten en baten van hun onderzoek zorgvuldig en eerlijk af te wegen en te beoordelen, en zij dienen te beschikken over voldoende methodologische bagage om een goed onderzoeksontwerp (design) te kiezen gezien het tijdsbestek, de mogelijk beschikbare proef-

personen, de meetinstrumenten, enz.

3.3 Proefpersonen en informanten

Wetenschappelijk onderzoek is mensenwerk: onderzoekers zijn ook mensen. Op het gebied van de geesteswetenschappen bestuderen die onderzoekers weer het gedrag en de geestelijke producten van (andere) mensen. Daarvoor gelden wetten, regels, richtlijnen en gedragscodes waaraan onderzoekers (en studenten!) zich dienen te houden, vanuit de eerder genoemde principes van zorgvuldigheid en verantwoordelijkheid. Het onderzoek zelf, en de verzamelde gegevens, mogen geen schade of groot verlies van privacy opleveren voor de deelnemers.

Voor geesteswetenschappelijk onderzoek zijn twee wetten relevant:

- Algemene Verordening Gegevensbescherming (AVG),
zie <https://autoriteitpersoonsgegevens.nl/nl/onderwerpen/avg-europese-privacywetgeving>
- Wet Medisch-wetenschappelijk Onderzoek met mensen (WMO),
zie <http://www.wetten.nl>

Het is verplicht om proefpersonen (of hun wettelijke vertegenwoordigers) te vragen om expliciete “informed consent”. Dat houdt in dat de proefpersonen eerlijk geïnformeerd worden over het onderzoek, over de baten en kosten daarvan, en over hun beloning, en dat zij daarna (d.i. “informed”) expliciet toestemmen in hun deelname (“consent”). Voorbeelden van informed consent (informatiebrieven en toestemmingsverklaringen) zijn te vinden op de website van de Facultaire Ethische Toetsingscommissie (FETC, hieronder nader besproken), via <https://fetc-gw.wp.hum.uu.nl/>.

Alle gegevens waaruit een individuele persoon te herleiden is, worden beschouwd als “persoonsgegevens”, en deze persoonsgegevens mogen alleen worden verzameld en verwerkt conform de AVG. Het is raadzaam om de onderzoeksgegevens zo snel mogelijk los te koppelen van de persoonsgegevens, d.w.z. dat je de gegevens anonimiseert. De koppeling tussen persoonsgegevens en onderzoeksgegevens (bijv. een lijst met namen van proefpersonen en hun bijbehorende anonieme persoonlijke code) is zelf weer vertrouwelijke informatie die je zorgvuldig moet bewaren en opslaan. Bewaar de persoonsgegevens niet langer dan nodig. De onderzoeksgegevens mag je alleen gebruiken voor het (wetenschappelijke) doel waarmee ze zijn verzameld. Zorg ook dat de proefpersonen niet herkenbaar zijn (gebruik anonieme codes) in verslagen en publicaties over het onderzoek.

Foto's en opnames van personen (audio, video, fysiologische gegevens, EEG) vallen onder het zgn. portretrecht. Foto's en andere identificerende

opnames worden dus als portretten beschouwd. Bij publicatie kan de afgebeelde/weergegeven persoon zich beroepen op het portretrecht, en een schadevergoeding eisen voor het letsel dat hem of haar door die publicatie wordt aangedaan. Als je een herkenbare opname zou willen publiceren, dan moet je dus vooraf expliciete toestemming daarvoor vragen van de opgenomen persoon of zijn wettelijke vertegenwoordiger (zie het bovengenoemde voorbeeld van “informed consent”). Dat geldt ook als je een fragment van zo’n opname laat zien of horen tijdens een conferentie of op een website.

In de wet WMO is vastgelegd dat onderzoek met mensen eerst moet worden goedgekeurd door een speciale commissie; voor de Faculteit Geesteswetenschappen van de Universiteit Utrecht is dat de Medisch-Ethische Toetsingscommissie die valt onder het Universitair Medisch Centrum Utrecht (METC). Die commissie weegt af of de mogelijke baten van het onderzoek redelijkerwijs opwegen tegen de kosten en mogelijke schade voor de proefpersonen.

Het meeste onderzoek op het gebied van talen en communicatie bij de Universiteit Utrecht is vrijgesteld van de tijdrovende toetsing door de METC, maar moet wel verplicht worden voorgelegd aan de **Facultaire Ethische Toetsingscommissie** (FETC), en wel aan de kamer Linguïstiek daarvan. Dat geldt echter niet voor onderzoek door studenten! Op de website van de FETC is meer informatie te vinden: <https://fetc-gw.wp.hum.uu.nl/>. Overleg bij twijfel altijd met je begeleider of docent. Ethische toetsing is ook verplicht voor studenten en onderzoekers uit andere domeinen (literatuur, geschiedenis, media & cultuur) die van plan zijn onderzoek te verrichten met mensen.

3.4 Gegevens

De verzamelde data of gegevens vormen de onderbouwing voor de conclusies uit wetenschappelijk onderzoek. Die gegevens zijn daarmee van essentieel belang: zonder gegevens geen valide conclusies. Zoals we hierboven zagen (§3.2) zijn die gegevens bovendien zeer kostbaar (in tijd, geld, privacy, enz). We moeten er dus uiterst zorgvuldig mee omgaan. We moeten anderen kunnen overtuigen van de validiteit van onze conclusies op basis van die gegevens, en we moeten de onderliggende gegevens desgevraagd kunnen delen met andere onderzoekers.

Die zorgvuldigheid vereist dus in ieder geval dat we zo snel mogelijk voldoende reservekopieën maken, en die bewaren op verschillende veilige plaatsen. Bedenk eens wat er zou gebeuren als een brand of overstroming je werkplek of woning zou vernietigen, of als tijdens je scriptie-project je laptop wordt gestolen (waar gebeurd!). Heb je dan goede en recente kopieën van de gegevens elders opgeslagen? Voor kopieën en ‘backups’ kun je goed gebruik maken van een afdoende beveiligde “cloud service”².

²Medewerkers van de UU kunnen SurfDrive (<https://www.surfdrive.nl>) gebruiken om gegevens veilig en makkelijk te bewaren op een beveiligde netwerk-schijf.

De zorgvuldigheid vereist ook dat we goed bijhouden wat de gegevens voorstellen, en hoe ze zijn verzameld. Gegevens zonder bijbehorende beschrijving zijn nagenoeg waardeloos voor wetenschappelijk onderzoek. Charles Darwin noteerde nauwkeurig welke vogel op welk van de Galapagos-eilanden welke vorm van snavel had, en deze observaties vormden later (deel van) de onderbouwing van zijn evolutie-theorie. Houd dus een logboek bij (op papier of digitaal) waarin je alle stappen van je onderzoek beschrijft, en eventueel motiveert. Noteer ook merk en type en instellingen van de gebruikte apparatuur, en noteer versie-nummer en instellingen van de gebruikte software. Houd bij welke bewerkingen je op de gegevens hebt toegepast, en waarom, en in welk bestand welke gegevens zijn opgeslagen.

Als je werkt met geditigaliseerde data (bv in Excel of SPSS of R), houd dan ook zorgvuldig bij welke variabelen in welke kolom is opgeslagen, in welke eenheden, en met welke codes.

Voorbeeld 3.3: Het bestand <http://tinyurl.com/nj4pjaq> bevat gegevens van 80 sprekers van het Nederlands, ten dele ontleend aan het Corpus Gesproken Nederlands (CGN). De eerste regel bevat de namen van de variabelen. Iedere volgende regel correspondeert met één spreker. De gegevens op iedere regel zijn gescheiden door spaties. De eerste kolom bevat de anonieme identificatie-code van de spreker volgens het CGN. In de vijfde kolom staat de regio van herkomst van de spreker gecodeerd, als één letterteken, met de codes W Randstad, M Midden-Nederland, N Noord-Nederland, S Zuid-Nederland) (Quené, 2008). Door de zorgvuldige annotatie zijn deze gegevens nog goed bruikbaar, ook al zijn ze ruim 20 jaar geleden verzameld door collega-onderzoekers.

Gegevens blijven het intellectuele eigendom van degene die ze heeft verzameld. Gebruik van andermans data zonder bronvermelding kan beschouwd worden als diefstal, of als plagiaat.

Fraude met gegevens (gegevens fabriceren of verzinnen, in plaats van observeren) is uiteraard strijdig met meerdere principes uit de bovengenoemde gedragscode (VSNU, 2018). Fraude schaadt het wederzijds vertrouwen waarop wetenschap is gebaseerd. Het misleidt andere onderzoekers die voortbouwen op de fictieve resultaten, en onderzoeksgeld voor die frauduleuze onderzoekslijn wordt weggezogen uit ander, niet frauduleus onderzoek — kortom, een wetenschappelijke doodzonde. Als je wilt overleggen over vragen of dilemma's hierover, neem dan contact op met prof.dr. Josine Blok, vertrouwenspersoon wetenschappelijke integriteit van de Faculteit Geesteswetenschappen (j.h.blok@uu.nl).

3.5 Teksten

Wetenschappelijk onderzoek wordt pas echt nuttig, als de resultaten ervan verspreid worden. Onderzoek dat niet wordt gerapporteerd, zou net zo goed *niet* kunnen zijn uitgevoerd, en de kosten van dat onderzoek zijn dan feitelijk tevergeefs geweest. Een belangrijk deel van het wetenschappelijk werk bestaat daarom uit verslaglegging ervan. Publicaties (en octrooien) vormen een zeer belangrijk deel van de “output” van wetenschappelijk onderzoek. Onderzoekers worden gemeten naar het aantal publicaties, en naar de “impact” daarvan (het aantal malen dat die publicaties weer geciteerd worden door anderen die erop voortbouwen). Mede gezien de grote belangen dienen we dus zorgvuldig om te gaan met teksten van anderen en van onszelf.

De onderzoekers die betrokken zijn bij een onderzoek, moeten met elkaar overleggen wie de auteurs van het verslag of van de publicatie zullen zijn, en in welke volgorde. Mede-auteurs van een wetenschappelijk verslag moeten voldoen aan drie voorwaarden (Office of Research Integrity, 2012, Ch.10). Ten eerste moeten zij een substantiële wetenschappelijke bijdrage hebben geleverd aan één of meer fasen in het onderzoek: het oorspronkelijke idee bedenken, het onderzoek opzetten en ontwerpen, de gegevens verzamelen, en de gegevens analyseren en interpreteren. Ten tweede moeten ze hebben meegewerkt aan het verslag, als schrijver en/of als commentator. Ten derde moeten ze instemmen met de definitieve tekst van het verslag (meestal impliciet, soms expliciet), en tevens instemmen met hun mede-auteurschap daarvan. De auteurs doen er goed aan om af te spreken in welke volgorde hun namen vermeld worden. Meestal correspondeert die volgorde met het afnemend belang en de afnemende omvang van de respectievelijke bijdragen van de auteurs. Als de eindverantwoordelijke hoofd-onderzoeker tevens mede-auteur is, dan wordt deze vaak als laatste genoemd.

Voorbeeld 3.4: Student-assistent A heeft geholpen bij het verzamelen van de gegevens, maar deze assistent heeft geen andere bijdragen geleverd, en weet niet goed waar het onderzoek eigenlijk over gaat. A hoeft geen mede-auteur te worden van het verslag, maar de auteurs dienen de bijdrage van A wel te beschrijven en te erkennen in hun verslag.

Student B heeft één van de delen van een onderzoeksproject uitgevoerd onder begeleiding van onderzoeker C. Deze begeleider C heeft het hele project bedacht, maar B heeft literatuur verzameld, een deelonderzoek opgezet en uitgevoerd, data verzameld, geanalyseerd en geïnterpreteerd, en daarvan verslag gedaan in een werkstuk. Student B en begeleider C zijn daarom beiden mede-auteurs van een

publicatie over B's deel van het onderzoeksproject. Zij spreken af in welke volgorde de auteurs genoemd worden. Omdat student B het belangrijkste was voor dit werk, en C de eindverantwoordelijke was, spreken zij af dat B de eerste auteur wordt en C de tweede en laatste.

Onderzoekers bouwen voort op het werk van hun voorgangers (zie voorbeeld 3.1). Dat kan ook gelden voor hun redeneringen, en zelfs hun teksten, maar daarbij moeten we dan altijd correct verwijzen naar de juiste bron, d.w.z. naar het werk van die voorgangers. Anders is immers niet meer te onderscheiden wie verantwoordelijk is voor welke gedachte of tekstfragment. Plagiaat is "het overnemen van stukken, gedachten, redeneringen van anderen en deze laten doorgaan voor eigen werk" (*Van Dale*, 12e druk). Ook deze vorm van fraude is een wetenschappelijke doodzonde, waar krachtige sancties op kunnen volgen. De Faculteit Geesteswetenschappen van de UU zegt daarover het volgende:

"Van plagiaat is sprake bij het in een scriptie of ander werkstuk gegevens of tekstgedeelten van anderen overnemen zonder bronvermelding. Onder plagiaat valt onder meer:

- het knippen en plakken van tekst van digitale bronnen zoals encyclopedieën en digitale tijdschriften zonder aanhalingstekens en verwijzing;
- het knippen en plakken van teksten van het internet zonder aanhalingstekens en verwijzing;
- het overnemen van gedrukt materiaal zoals boeken, tijdschriften en encyclopedieën zonder aanhalingstekens en verwijzing;
- het opnemen van een vertaling van bovengenoemde teksten zonder aanhalingstekens en verwijzing;
- het parafraseren van bovengenoemde teksten zonder (deugdelijke) verwijzing: parafrasen moeten als zodanig gemarkeerd zijn (door de tekst uitdrukkelijk te verbinden met de oorspronkelijke auteur in tekst of noot), zodat niet de indruk wordt gewekt dat het gaat om eigen gedachtegoed van de student;
- het overnemen van beeld-, geluids- of testmateriaal van anderen zonder verwijzing en zodoende laten doorgaan voor eigen werk;
- het zonder bronvermelding opnieuw inleveren van eerder door de student gemaakt eigen werk en dit laten doorgaan voor in het kader van de cursus vervaardigd oorspronkelijk werk, tenzij dit in de cursus of door de docent uitdrukkelijk is toegestaan;

- het overnemen van werk van andere studenten en dit laten doorgaan voor eigen werk. Indien dit gebeurt met toestemming van de andere student is de laatste medeplichtig aan plagiaat;
- ook wanneer in een gezamenlijk werkstuk door een van de auteurs plagiaat wordt gepleegd, zijn de andere auteurs medeplichtig aan plagiaat, indien zij hadden kunnen of moeten weten dat de ander plagiaat pleegde;
- het indienen van werkstukken die verworven zijn van een commerciële instelling (zoals een internetsite met uittreksels of papers) of die tegen betaling door iemand anders zijn geschreven.”

<http://students.uu.nl/praktische-zaken/regelingen-en-procedures/fraude-en-plagiaat>

Bij plagiaat van eigen werk worden de teksten of gedachten niet overgenomen van anderen maar van één van de auteurs. Over dit zelf-plagiaat wordt verschillend gedacht; het is echter raadzaam om in voorkomende gevallen wel de bron te vermelden, vanuit de principes van zorgvuldigheid, betrouwbaarheid, controleerbaarheid, en verantwoordelijkheid.

Een verwijzing of citatie of referentie is een verkorte bronvermelding in de tekst; in dit boek ben je er al vele tegengekomen. Aan het einde van de tekst volgt dan de volledige lijst van bronnen, meestal aangeduid als bronvermeldingen, geraadpleegde bronnen, referenties, literatuur, of bibliografie (“boekbeschrijving”). Een foutieve bronvermelding kan worden beschouwd als plagiaat (Universiteitsbibliotheek, Vrije Universiteit Amsterdam, 2015) omdat de lezer niet verwezen wordt naar de juiste bron. Onderzoekers dienen hun bronnen daarom op correcte wijze te vermelden. Daarvoor bestaan verschillende conventies, afhankelijk van het vakgebied. Meestal zal een docent aangeven volgens welke stijl of conventie je je bronnen moet vermelden. In dit boek volgen we zoveel mogelijk de stijl van de (American Psychological Association, 2010), die gebruikelijk is in de sociale wetenschappen en een deel van de geesteswetenschappen.

De regels voor bronvermelding zijn soms ingewikkeld. Bovendien moeten de auteurs zorgen dat de citaties in de tekst overeenkomen met de lijst van referenties. Deze taken kunnen beter worden bijgehouden door een zgn. “reference manager”, een programma dat referenties of bronvermeldingen verzamelt en op de juiste wijze invoegt in de tekst. Een overzicht van zulke programma’s is te vinden via https://en.wikipedia.org/wiki/Comparison_of_reference_management_software. Voor dit tekstboek is gebruik gemaakt van Zotero, gecombineerd met BibTeX.

Chapter 4

Meetniveau

4.1 Inleiding

In Hoofdstuk 2 maakten we al kennis met variabelen: eigenschappen die verschillende waarden kunnen aannemen. De waarde van een variabele is dus een aanduiding van een eigenschap, of kwaliteit, of hoedanigheid, van een object of persoon. Als het gaat om een afhankelijke variabele, dan wordt die waarde ook aangeduid als *score* of *responsie*, vaak aangeduid met symbool Y . De wijze waarop een kenmerk wordt uitgedrukt in een (gemeten) waarde, noemen we het *meetniveau* van de variabele; het meetniveau is dus een eigenschap of kenmerk van de variabele zelf! We onderscheiden vier meetniveau's, in toenemende niveau's van informativiteit: nominaal, ordinaal, interval, ratio. Bij de eerste twee meetniveau's worden alleen discrete categorieën onderscheiden, zonder of met ordening. Bij de laatste twee meetniveau's worden getalswaarden gebruikt, zonder of met nulpunt. We zullen de meetniveau's hieronder nader bespreken. Inzicht in het meetniveau van een variabele is van belang voor de interpretatie van de scores op een variabele en — zoals we later zullen zien — voor de keuze van de juiste statistische toets om een onderzoeksvraag te beantwoorden.

4.2 Nominaal

We spreken van een nominale variabele (of nominaal meetniveau) als een kenmerk gecategoriseerd wordt in afzonderlijke (discrete) categorieën, waarbij er *niet* een ordening is tussen de categorieën. Bekende voorbeelden zijn o.a. de nationaliteit van een proefpersoon, het merk van een auto, de kleur van iemands ogen, de smaak van een bak schepijs, je woonsituatie (bij gezin van herkomst, op kamers, zelfstandig, samenwonend, anders), enz. De scores kunnen alleen gebruikt worden om de categorieën te onderscheiden (de uitspraak “vanille is

anders dan aardbei” is wel zinnig). We kunnen wel tellen hoe vaak iedere categorie voorkomt, maar er is geen interpreteerbare rangorde (de uitspraak “vanille is groter dan aardbei” is onzinnig), en we kunnen ook niet rekenen met de gemeten waarden van een nominale variabele. We kunnen dus wel de meest voorkomende nationaliteit vaststellen, maar we kunnen niet de gemiddelde nationaliteit uitrekenen.

4.3 Ordinaal

Er is sprake van een ordinale variabele (of van een ordinaal meetniveau) als een kenmerk gecategoriseerd wordt in afzonderlijke categorieën, waarbij er *wel* een rangorde is tussen de categorieën. Bij een ordinale variabele weten we echter niets over de afstand tussen de verschillende categorieën. Bekende voorbeelden zijn o.a. schooltype (VMBO, HAVO, VWO, ...), antwoord op een schaalvraag (*mee eens*, *neutraal*, *niet mee eens*), positie op een ranglijst, volgorde van afvallen bij een talentenjacht, kledingmaat (XS, S, M, L, XL, ...), of militaire rang (soldaat, majoor, generaal, ...). Ook hier kunnen we wel tellen hoe vaak iedere categorie voorkomt, en we kunnen ook de rangorde zinnig interpreteren (wie als laatste afvalt presteert beter dan wie als eerste afvalt, maat L is groter dan M, een generaal is de baas van een majoor). We kunnen echter niet rekenen met de gemeten waarden van een ordinale variabele. We kunnen wel de meest verkochte kledingmaat vaststellen, maar we kunnen niet de gemiddelde verkochte kledingmaat uitrekenen¹.

4.4 Interval

Er is sprake van een interval-variabele (of van een interval-meetniveau) als een kenmerk uitgedrukt wordt in een getal op een continue schaal, waarbij deze schaal *niet* een nulpunt heeft. Door de schaal weten we bij een interval-variabele ook wat de afstanden of intervallen zijn tussen de verschillende waarden. Bekende voorbeelden zijn o.a. temperatuur in graden Celcius (het nulpunt is arbitrair), of jaartal (idem). We kunnen tellen hoe vaak iedere categorie voorkomt, we kunnen de rangorde zinnig interpreteren (het jaar 1999 in onze gregoriaanse kalender ging vooraf aan het jaar 2000), en we kunnen ook de intervallen zinnig interpreteren (van 1918 tot 1939 is net zo lang als van 1989 tot 2010). We kunnen wel rekenen met de waarden van een interval-variabele, maar de enige zinnige bewerkingen zijn optellen en aftrekken. Daarmee kunnen we wel een gemiddelde berekenen, bijv. het gemiddelde jaar waarin de personen in een steekproef hun eerste mobiele telefoon begonnen te gebruiken.

¹Als de helft van de respondenten *mee eens* antwoordt, en de andere helft *niet mee eens*, dan kunnen we niet zinnig concluderen dat de responsies gemiddeld *neutraal* zouden zijn.

4.5 Ratio

Het vierde en hoogste meetniveau is het ratio-niveau. Er is sprake van een ratio-variabele (of van een ratio-meetniveau) als een kenmerk uitgedrukt wordt in een getal op een continue schaal, waarbij deze schaal *wel* een nulpunt heeft. Door de schaal weten we bij een ratio-variabele wat de afstanden of intervallen zijn tussen de verschillende waarden. Bovendien weten we door het nulpunt wat de verhoudingen of ratio's zijn tussen de verschillende waarden. Bekende voorbeelden zijn o.a. temperatuur in graden Kelvin (vanaf het absolute nulpunt), de responsietijd² in duizendsten van een seconde (ms), je lengte in cm, je leeftijd in jaren, het aantal gemaakte fouten in een toets, enz. Bij een ratio-variabele kunnen we tellen hoe vaak iedere categorie voorkomt, we kunnen de rangorde zinnig interpreteren (iemand van 180 cm is langer dan iemand van 179 cm), we kunnen intervallen zinnig interpreteren (de toename in leeftijd van 12 naar 18 is tweemaal zo groot als de toename van 9 naar 12), en we kunnen ook verhoudingen tussen de waarden zelf zinnig interpreteren (een leeftijd van 24 is *tweemaal* zo oud als een leeftijd van 12). We kunnen rekenen met de waarden van een interval-variabele, en daarbij kunnen we niet alleen optellen en aftrekken maar ook delen en vermenigvuldigen. Ook hier is het mogelijk om een gemiddelde te berekenen, bijv. de gemiddelde leeftijd waarop de personen in een steekproef hun eerste mobiele telefoon begonnen te gebruiken.

4.6 Ordening van meetniveaus

De meetniveaus zijn hierboven besproken in toenemende informativiteit of sterkte. Een nominale variabele bevat het minste informatie en geldt als het laagste meetniveau, en een ratio-variabele bevat het meeste informatie en geldt als het hoogste meetniveau.

Het is altijd mogelijk om gegevens gemeten op een hoger meetniveau te interpreteren alsof ze op een lager niveau zijn gemeten. Als we bijvoorbeeld het maandinkomen van de personen in een steekproef hebben gemeten op ratio-niveau (in €), dan kunnen we daar probleemloos een ordinale variabele van maken (*minder dan modaal, van modaal tot tweemaal modaal, meer dan tweemaal modaal*). We gooien daarbij informatie weg: de oorspronkelijke meting in € bevat meer informatie dan de daaruit afgeleide classificatie in drie geordende categorieën.

Natuurlijk is het omgekeerde niet mogelijk: een variabele van een laag meetniveau kunnen we niet interpreteren op een hoger niveau. We zouden dan informatie achteraf moeten toevoegen die we niet hebben verzameld bij de oorspronkelijke meting van die variabele. Het is dus zaak om de relevante variabelen te meten of te observeren op het juiste meetniveau. Stel je voor dat we de

²Het nulpunt is het moment van de gebeurtenis waarop de proefpersoon moet reageren.

lichaamslengte van volwassen mannen en vrouwen willen vergelijken. Als we de lichaamslengte meten op ordinaal meetniveau (met drie categorieën *kort*, *mid-delmatig* en *lang* gelijkelijk gedefinieerd voor alle personen), dan kunnen we dus niet de gemiddelde lichaamslengte uitrekenen, en we kunnen ook niet een statistische toets gebruiken die refereert aan het gemiddelde van de lichaamslengte. Dat hoeft geen probleem te zijn, maar het is wel goed om vooraf te doordenken wat de consequenties zijn van de keuze voor een bepaald meetniveau.

Chapter 5

Validiteit

5.1 Inleiding

Experimenteel onderzoek heeft tot doel om hypotheses te toetsen. Ook in ander, niet-experimenteel onderzoek kunnen hypotheses worden getoetst, maar we beperken ons hier voor de helderheid tot experimenteel onderzoek, d.w.z. onderzoek waarin het experiment als methode wordt gebruikt. In experimenteel onderzoek wordt getracht causale verbanden aannemelijk te maken. Als de resultaten van een experimenteel onderzoek de onderzoekshypothese bevestigen (d.w.z. de nulhypothese wordt verworpen), dan is het aannemelijk dat een verandering in de onafhankelijke variabele de oorzaak (Latijn: *causa*) is voor een verandering of *effect* in de afhankelijke variabele. Zo kunnen we na experimenteel onderzoek met enige zekerheid concluderen, bijvoorbeeld, dat een verschil in behandeling na een herseninfarct de oorzaak is, of een belangrijke oorzaak is, van een verschil in taalvaardigheid van een patiënt zoals geobserveerd 6 maanden na een herseninfarct. Het experiment heeft aannemelijk gemaakt dat er een causaal of oorzakelijk verband is tussen de behandelingsmethode (onafhankelijke variabele) en de resulterende taalvaardigheid (afhankelijke variabele).

5.2 Causaliteit

Een causaal of oorzakelijk verband tussen twee variabelen is iets anders dan een ‘gewoon’ verband of samenhang tussen twee variabelen. Als twee verschijnselen met elkaar samenhangen, hoeft het ene niet de oorzaak van het andere te zijn. Een eerste voorbeeld zien we bij de samenhang tussen de lengte van personen en hun gewicht: lange mensen zijn over het algemeen zwaarder dan korte mensen (en omgekeerd: korte mensen zijn over het algemeen lichter

dan lange mensen). Is er nu sprake van een causale relatie tussen lengte en gewicht? Wordt het ene kenmerk (deels) veroorzaakt door het andere? Nee, in dit voorbeeld is er wel samenhang maar geen causaal verband tussen de kenmerken: zowel lengte als gewicht worden “veroorzaakt” door andere variabelen, o.a. genetische eigenschappen en voedingspatronen. Een tweede voorbeeld is de samenhang tussen motivatie en taalvaardigheid van iemand die een vreemde taal leert: hoog gemotiveerde studenten leren een nieuwe vreemde taal beter en vlotter dan laag gemotiveerde studenten, maar ook hier is niet duidelijk wat de oorzaak en wat het gevolg is.

Een causaal verband is een speciale vorm van samenhang. Een causaal verband is een verband tussen twee verschijnselen of kenmerken, waarbij bovendien voldaan moet zijn aan een aantal extra voorwaarden (Shadish et al., 2002). Ten eerste moet de oorzaak aan het gevolg vooraf gaan (na behandeling treedt verbetering op). Ten tweede moet het gevolg niet optreden als de oorzaak niet aanwezig was (zonder behandeling geen verbetering). Bovendien moet het gevolg — althans in theorie — altijd optreden als de oorzaak aanwezig is (behandeling resulteert altijd in verbetering). Ten derde kunnen we geen andere plausibele verklaring vinden voor het optreden van het gevolg, behalve de mogelijke oorzaak. Als we het causale mechanisme kennen (we snappen waarom behandeling de oorzaak is van verbetering), dan zijn we beter in staat om mogelijke andere plausibele verklaringen uit te sluiten. Helaas is dat bij de gedragswetenschappen, inclusief de taalwetenschap, echter zelden het geval. We constateren wel dat een behandeling resulteert in verbetering, maar de theorie die oorzaak (behandeling) en gevolg (verbetering) verbindt is zelden compleet en vertoont belangrijke lacunes. Dat betekent dat we goede voorzorgen moeten treffen in onze onderzoeksmethoden, teneinde mogelijke alternatieve plausibele verklaringen voor de gevonden effecten uit te sluiten.

5.3 Validiteit

Een bewering of conclusie is *valide* als de bewering *waar* (true) en *gerechtvaardigd* (justified) is. Een ware uitspraak correspondeert met de werkelijkheid: de bewering *ieder kind leert ten minste een taal* is waar, omdat de bewering de werkelijkheid goed weergeeft. Een gerechtvaardigde bewering ontleent geldigheid aan de empirische evidentie waarop die bewering is gebaseerd: ieder kind dat wij hebben geobserveerd, of dat anderen hebben geobserveerd, leert een taal of heeft een taal geleerd (behalve bijzondere gevallen voor wie een aparte verklaring nodig is). De rechtvaardiging van een bewering is sterker naarmate de methode van (directe of indirecte) observatie sterker is en meer zekerheid biedt. Dit houdt ook in dat de validiteit van een bewering niet een categoriale eigenschap is (wel/niet valide) maar een gradueel kenmerk: een bewering kan meer of minder valide zijn.

Aan de validiteit van een bewering kunnen drie verschillende aspecten worden

onderscheiden.

1. In hoeverre zijn de conclusies over de relaties tussen de afhankelijke en de onafhankelijke variabele geldig? Deze vraag heeft betrekking op de *interne validiteit*.
2. In hoeverre zijn de uitwerkingen, operationalisering, van de afhankelijke en onafhankelijke variabele adequaat? Deze vraag heeft betrekking op de *constructvaliditeit*.
3. In hoeverre kunnen de conclusies gegeneraliseerd worden naar andere proefpersonen, stimuli, condities, situaties, observaties? Deze vraag heeft betrekking op de *externe validiteit*.

Deze drie vormen van validiteit zullen wij in de navolgende paragrafen toelichten.

5.4 Interne validiteit

Het is vanzelfsprekend de bedoeling om in een experimenteel onderzoek zoveel mogelijk alternatieve verklaringen voor de onderzoeksresultaten uit te sluiten. Er moet immers aangetoond worden dat er een causaal verband is tussen twee variabelen X en Y, en daarbij moeten storende factoren zoveel mogelijk onder controle gehouden worden. Laten we eens kijken naar voorbeeld 5.1 hieronder.

Voorbeeld 5.1: (Verhoeven et al., 2004) onderzochten o.a. de hypothese dat ouderen (boven de 45 jaar) langzamer spreken dan jongeren (onder de 40 jaar). Om dat te onderzoeken werd spraak opgenomen van 160 sprekers, gelijk verdeeld over de twee leeftijdsgroepen, in een interview van ongeveer 15 minuten. Na fonetische analyse van de articulatiesnelheid blijkt dat de “jongeren” relatief snel spreken met 4.78 lettergrepen per seconde, en de “ouderen” aanzienlijk langzamer, met 4.52 lettergrepen per seconde (Verhoeven et al., 2004, p.302). We concluderen dat de hogere leeftijd de *oorzaak* is van het lagere spreektempo bij de oudere sprekers — maar is die conclusie terecht?

Deze vraag naar de rechtvaardiging van de conclusie is een vraag naar de interne validiteit van het onderzoek. De interne validiteit heeft betrekking op de relaties tussen gemeten of gemanipuleerde variabelen, en is onafhankelijk van

de (theoretische) constructen die de verschillende variabelen representeren (vandaar de term ‘interne validiteit’). Of, anders gezegd: de vraag naar de interne validiteit is een vraag naar mogelijke alternatieve verklaringen voor de gevonden onderzoeksresultaten. Veel van de mogelijke alternatieve verklaringen kunnen worden ondervangen door de manier waarop de gegevens worden verzameld. We bespreken hieronder de meest in het oog lopende bedreigingen van de interne validiteit (Shadish et al., 2002).

1. **Geschiedenis** is een bedreiging van de interne validiteit. Het begrip ‘geschiedenis’ omvat o.a. gebeurtenissen die hebben plaatsgevonden tussen of tijdens een voormeting en een nameting; het gaat dan om gebeurtenissen die geen deel uitmaken van de experimentele manipulatie (de onafhankelijke variabele), maar die wel van invloed zouden kunnen zijn op de afhankelijke variabele. Een hittegolf, bijvoorbeeld, kan van invloed zijn op het gedrag van de proefpersonen tijdens een onderzoek.

In een laboratorium wordt de ‘geschiedenis’ onder controle gehouden door de proefpersonen af te sluiten van invloeden van buitenaf (zoals een hittegolf), of door afhankelijke variabelen te kiezen die nauwelijks beïnvloed kunnen worden door externe factoren. In onderzoek buiten het laboratorium, waaronder veldonderzoek, is het veel lastiger en vaak zelfs onmogelijk om invloeden van buitenaf onder controle te houden. In het volgende voorbeeld wordt dit duidelijk.

Voorbeeld 5.2: In een onderzoek worden twee methoden vergeleken om leerlingen een vreemde taal te leren spreken, i.c. Nieuw-Grieks. De eerste groep moet Griekse woordjes en grammatica leren in een klaslokaal, gedurende enkele weken. De tweede groep gaat in diezelfde periode op een studiereis naar Griekenland, waar leerlingen moeten converseren in de doeltaal. De totale tijd besteed aan het taalvaardigheidsonderwijs is voor beide groepen gelijk. Na afloop blijkt de taalvaardigheid van de tweede groep groter dan die van de eerste groep. Wordt dat verschil in de afhankelijke variabele inderdaad veroorzaakt door de lesmethode (onafhankelijke variabele)?

2. **Rijping** is de natuurlijke veroudering of rijping van proefpersonen tijdens een onderzoek. Als de proefpersonen gedurende een onderzoek ouder worden, zich ontwikkelen, meer ervaren of sterker worden, en als deze rijping niet is opgenomen in de onderzoeksvraag, dan vormt rijping een bedreiging van de interne validiteit. In experimenten waarin reactietijden worden gemeten, bijvoorbeeld, zien we meestal dat de reactietijden

van een proefpersoon sneller worden gedurende het experiment, als gevolg van training en oefening. We kunnen de interne validiteit dan beschermen tegen dit leer-effect, door de stimuli voor iedere proefpersoon in een andere willekeurige volgorde aan te bieden.

Meestal is er sprake van rijping doordat de proefpersonen vele malen achtereenvolgende dezelfde taak uitvoeren of dezelfde vragen beantwoorden. Rijping kan echter ook optreden wanneer proefpersonen hun antwoorden kenbaar moeten maken op een juist niet gebruikelijke manier, bv. door een ongewone vraagstelling, of in een ongebruikelijke vorm van meerkeuze-vragen. Bij de eerste paar keer dat een proefpersoon dan vragen beantwoordt, kan de wijze van beantwoorden interfereren met het antwoord zelf. Achteraf kunnen we een vergelijking maken tussen bv. het eerste kwart en het laatste kwart van de antwoorden, om zo te bekijken of er een mogelijk effect was van ervaring, d.w.z. van rijping.

3. Ook de **instrumentatie** of instrumenten die voor een onderzoek gebruikt worden, kunnen een bedreiging vormen voor de interne validiteit. Verschillende instrumenten die worden geacht hetzelfde construct te meten, moeten ook gelijke metingen produceren. En hetzelfde instrument moet ook gelijke metingen produceren onder verschillende omstandigheden. Voor computer-gestuurde experimenten is dat meestal geen probleem. Maar bij vragenlijsten, of bij de beoordeling van schrijfp opdrachten, kan de interne validiteit wel worden bedreigd.

Bij veel onderzoek worden observaties gedaan zowel voorafgaand aan een behandeling, als na afloop daarvan. Daarbij kan dezelfde toets gebruikt worden, maar dan kan er een leer-effect optreden (zie hierboven). Onderzoekers gebruiken daarom vaak verschillende toetsen bij de voormeting en de nameting, maar daarbij kan er wel een instrumentatie-effect optreden. De onderzoeker moet de mogelijke voor- en nadelen tegen elkaar afwegen.

Voorbeeld 5.3: (Rijlaarsdam, 1986) onderzocht het effect van ‘peer evaluation’ op de kwaliteit van schrijfproducten. De opzet van zijn onderzoek was (enigszins vereenvoudigd) als volgt: eerst schrijven de leerlingen een opstel over onderwerp A, dan volgt het schrijfonderwijs inclusief ‘peer evaluation’, waarna nogmaals een opstel geschreven wordt over onderwerp B. De schrijfproducten van voormeting en nameting worden beoordeeld, waarna getoetst wordt of de gemiddelde prestaties verschillen tussen voormeting en nameting.

In dit onderzoek vormt niet alleen de interventie (schrijfonderwijs) een duidelijk verschil tussen de voormeting en de nameting, maar

ook het onderwerp van de schrijfpdracht (A of B) vormt een verschil. Het is twijfelachtig of met beide schrijfpdrachten wel precies hetzelfde wordt gemeten. Dit verschil in instrumentatie bedreigt de interne validiteit, omdat er op verschillende momenten misschien een (deels) verschillend aspect van de schrijfvaardigheid is gemeten. De instrumentatie (hier: het verschil in onderwerpen van de schrijfpdrachten) geeft een plausibele alternatieve verklaring voor een verschil in schrijfvaardigheid, naast of in plaats van de onafhankelijke variabele (hier: het tussentijdse schrijfonderwijs).

-
4. Een volgende bedreiging van de interne validiteit staat bekend als het effect van **regressie naar het gemiddelde**. Regressie naar het gemiddelde kan een rol spelen zodra het onderzoek gericht is op speciale groepen, bijvoorbeeld slechte lezers, slechte schrijvers, maar evenzo: goede lezers, goede schrijvers, etc. We geven eerst een voorbeeld, omdat het verschijnsel niet direct intuïtief duidelijk is.

Voorbeeld 5.4: Er is enige controverse over het gebruik van illustraties in kinderboeken. Sommigen menen dat in boeken waarmee kinderen leren lezen geen (of zo min mogelijk) illustraties mogen voorkomen: illustraties leiden de aandacht af van te leren kenmerken van woorden. Anderen menen dat in illustraties wezenlijke informatie weergegeven kan worden: illustraties dienen als extra informatiebron.

(Donald, 1983) onderzocht de invloed van illustraties bij een tekst op het begrip van die tekst. De onderzoeker selecteerde 120 leerlingen (uit 1868 leerlingen) uit de derde en zesde groep van het basisonderwijs; 60 uit elk van beide groepen. Volgens de prestaties op een eerder afgenomen leestoets bleken van de 60 leerlingen per klas er 30 als slechte en 30 als goede lezers geclassificeerd te kunnen worden. Elke leerling kreeg dezelfde tekst te zien, aangeboden met of zonder illustraties (onafhankelijke variabele), zie Tabel 5.1.

De resultaten bleken goeddeels de tweede hypothese te ondersteunen: illustraties bevorderen het begrip van de tekst, ook bij onervaren lezers. De slechtere lezers begrepen de tekst met illustraties beter, en ook jongere lezers ondervonden voordeel van de illustraties.

Table 5.1: Aanbiedingscondities in het onderzoek van Donald (1983).

| groep | leesvaardigheid | conditie | <i>n</i> |
|-------|-----------------|----------|----------|
| 3 | slecht | zonder | 15 |
| 3 | slecht | met | 15 |
| 3 | goed | zonder | 15 |
| 3 | goed | met | 15 |
| 6 | slecht | zonder | 15 |
| 6 | slecht | met | 15 |
| 6 | goed | zonder | 15 |
| 6 | goed | met | 15 |

Wat is er nu mis met dit onderzoek? Het antwoord is gelegen in de manier waarop leerlingen zijn geselecteerd. Lezers werden ingedeeld als ‘slecht’ of ‘goed’ op basis van een leesvaardigheidstoets, maar hun prestaties op die toets worden altijd beïnvloed door toevallige factoren, die niets met leesvaardigheid te maken hebben: Tom voelde zich niet lekker, daarom heeft hij deze toets slecht gemaakt, Sarah was met haar gedachten elders, Niels had last van zijn knie, Julie was enorm gemotiveerd en heeft zichzelf overtroffen. Met andere woorden: de leesvaardigheid is niet geheel betrouwbaar gemeten. Dit betekent (1) dat de slechte lezers die toevallig boven hun niveau gepresteerd hebben, ten onrechte niet bij de slechte lezers ingedeeld werden, maar deel uitmaakten van de groep goede lezers; en omgekeerd (2) dat goede lezers die bij deze toets toevallig onder hun niveau gepresteerd hebben, ten onrechte als slechte lezers bestempeld werden. Onder de slechte lezers zitten dus altijd ook een paar lezers die helemaal zo slecht nog niet zijn, en onder de goede lezers zitten ook een paar lezers die eigenlijk niet zo goed zijn.

Wanneer de eigenlijk-goede lezers, die ten onrechte geëvalueerd zijn als niet-goede lezers, een tweede leestoets maken (nadat zij een tekst met of zonder illustraties bestudeerd hebben), dan zullen zij meestal weer op hun gewone hoge niveau presteren. Een hogere score op de tweede toets (de nameting) kan dus een artefact zijn van de selectiemethode. Hetzelfde geldt, *mutatis mutandis*, voor de eigenlijk-slechte lezers die ten onrechte geselecteerd zijn als niet-slechte lezers. Wanneer deze leerlingen een tweede leestoets maken, dan zullen ook zij meestal weer op hun gewone (lage) niveau presteren. De score op de nameting ligt voor hen dus lager dan de score op de voormeting.

Voor het aangehaalde onderzoek van betekent dit dat het geconstateerde verschil tussen slechte en goede lezers deels toevallig is. Ook als de onafhankelijke variabele geen effect heeft, zal de groep ‘goede’ lezers bij de tweede leestoets gemiddeld slechter presteren, en zal de groep ‘slechte’ lezers bij de tweede leestoets gemiddeld beter presteren. Met andere woorden: het verschil tussen de twee groepen is bij de nameting minder groot dan bij de voormeting, als gevolg van

toevallige variatie: regressie naar het gemiddelde. Het zal duidelijk zijn dat onderzoeksresultaten getroebleerd kunnen worden door dit verschijnsel. Zoals we hierboven zagen kan een experimenteel effect afgezwakt worden of verdwijnen als gevolg van regressie naar het gemiddelde; omgekeerd kan regressie naar het gemiddelde ten onrechte aangezien worden als een experimenteel effect (Retraction Watch, 2018).

In het algemeen kan regressie naar het gemiddelde optreden als er een classificatie gemaakt wordt op basis van een voormeting, waarvan de scores samenhang vertonen met de scores van de nameting (zie Hoofdstuk 11). Als er geen enkele correlatie is tussen voormeting en nameting, dan speelt regressie naar het gemiddelde zelfs de hoofdrol: een verschil tussen voormeting en nameting is dan alleen het gevolg van regressie naar het gemiddelde. Als er perfecte correlatie is, dan speelt regressie naar het gemiddelde geen enkele rol, maar dan is ook de voormeting niet informatief, want immers geheel (achteraf) te voorspellen uit de nameting.

Regressie naar het gemiddelde kan een alternatieve verklaring bieden voor de vermeende grote toename van scores tussen voormeting en nameting voor een lage prestatiegroep (bv. slechte lezers), ten opzichte van een kleinere toename voor een hoge prestatiegroep (bv. goede lezers). Omgekeerd kan het ook een alternatieve verklaring bieden voor de vermeende afname van scores tussen voormeting en nameting voor een hoge prestatiegroep (bv. goede lezers), ten opzichte van een lage prestatiegroep (bv. slechte lezers).

Het is beter om de groepen *niet* samen te stellen op basis van een van de uitkomsten van een van de metingen (voormeting of nameting), maar op basis van een ander, onafhankelijk criterium. De proefpersonen van beide groepen zullen dan zullen bij de voormeting ongeveer gemiddeld scoren, en het effect van regressie naar het gemiddelde is dan klein. In alle groepen zullen dan ongeveer evenveel proefpersonen zitten met een door het toeval iets te hoge als met een iets te lage uitgevallen score, zowel bij de voormeting als bij de nameting.

5. Een vijfde bedreiging van de interne validiteit is **selectie**. Hiermee doelen we (voornamelijk) op een zodanige verdeling van proefpersonen over verschillende condities dat deze bij aanvang van het onderzoek niet gelijkwaardig zijn. Wanneer bijvoorbeeld in de experimentele conditie alle slimme proefpersonen zitten, terwijl in de controleconditie alleen de domme leerlingen terecht gekomen zijn, dan kan een effect niet zonder meer aan de manipulatie van de onafhankelijke variabele toegeschreven worden. Het verschil in aanvangsniveau (hier: in intelligentie) levert dan een plausibele alternatieve verklaring die de interne validiteit bedreigt.

Voorbeeld 5.5: Voor een eerlijke vergelijking tussen scholen van hetzelfde schooltype (VMBO, HAVO, VWO, etc) moeten we rekening

houden met verschillen tussen scholen in hun ingangsniveau van de leerlingen. Stel dat school A leerlingen heeft met ingangsnivo 50, en eindexamennivo 100 (op een willekeurige schaal). School B heeft leerlingen met ingangsnivo 30, en eindexamennivo 90 (op dezelfde schaal). Is school B slechter dan A (want lager eindnivo), of is school B beter dan A (want kleiner verschil in eindnivo)?

In veel onderwijskundig onderzoek is het onmogelijk om leerlingen van verschillende klassen op basis van het toeval aan condities toe te wijzen — dit wordt wel *aselecte toewijzing* genoemd. Dit kan namelijk onoverkomelijke organisatorische problemen met zich meebrengen. Deze organisatorische problemen omvatten meer dan alleen het (aselect) splitsen van de klas, hoewel dit vaak al lastig te realiseren is. Ook moet de onderzoeker rekenschap afleggen van mogelijke overdrachtseffecten tussen de condities: de leerlingen praten met elkaar, leren elkaar misschien zelfs wel de essentialia van de experimentele conditie(s). Het uitblijven van een effect zou dan op tenminste één alternatieve manier verklaard kunnen worden. Vanwege de geschetste problematiek worden vaak complete schoolklassen toegewezen aan een van de condities. Maar klassen bestaan uit een aantal leerlingen van dezelfde school. Bij de keuze van leerlingen, en hun ouders, voor een school treedt zelf-selectie op (in het Nederlandse onderwijssysteem), waardoor er verschillen zijn in uitgangspositie tussen condities (d.w.z. tussen klassen binnen condities). Eventuele gevonden verschillen tussen condities zouden dus ook door zelfselectie van leerlingen naar scholen veroorzaakt kunnen zijn.

Hierboven is al de meest eenvoudige manier aangegeven om verschillende condities een gelijk aanvangsniveau te geven: wijs de leerlingen *aselect*, volgens toeval, ‘at random’, toe aan de condities. Deze methode staat bekend als *randomisatie* (Shadish et al., 2002, p.294 ff). We kunnen bijvoorbeeld randomiseren door leerlingen een willekeurig (random) nummer te geven (zie Appendix A) en daarna de ‘even leerlingen’ aan de ene conditie en de ‘oneven leerlingen’ aan de andere conditie toe te wijzen. Bij *aselecte toewijzing* van proefpersonen aan condities berusten alle verschillen tussen de proefpersonen in de verschillende condities op toeval, en worden die verschillen dus uitgemiddeld. Naar alle waarschijnlijkheid zijn er dan geen systematische verschillen tussen de onderscheiden groepen of condities. Dit geldt echter alleen indien de groepen groot genoeg zijn.

Randomisatie, de *aselecte toewijzing* van proefpersonen aan condities, moet onderscheiden worden van de *aselecte steekproeftrekking* uit een populatie (zie §7.3). Bij *aselecte steekproeftrekking* gaat het om de willekeurige selectie van proefpersonen uit de populatie van mogelijke proefpersonen naar de steekproef; we streven er dan naar dat de steekproef of steekproeven lijken op de populatie waaruit die getrokken is/zijn. Bij randomisatie gaat het om de willekeurige toewijzing van de proefpersonen uit de steekproef aan de verschillende condities van het onderzoek; we streven er dan naar dat de steekproeven lijken op elkaar.

Een tweede methode om twee gelijke groepen te creëren is *matching*. Bij *matching* worden proefpersonen eerst gemeten op een aantal relevante variabelen. Daarna worden koppels gevormd die een gelijke score op deze variabelen hebben. Van deze koppels wordt er één aan de ene conditie en één aan de andere conditie toegewezen. Matching heeft echter verschillende bezwaren. Ten eerste kan regressie naar het gemiddelde een rol gaan spelen. Ten tweede is matching, wanneer de proefpersonen op meerdere variabelen gematcht moeten worden, zeer bewerkelijk, en is een grote groep potentiële proefpersonen vereist. Ten derde wordt bij matching alleen rekening gehouden met variabelen die de onderzoeker relevant acht, en niet met andere onbekende variabelen. Bij randomisatie wordt niet alleen gerandomiseerd naar die relevante variabelen, maar ook naar andere eigenschappen die mogelijk een rol zouden kunnen spelen zonder dat de onderzoeker zich dat realiseert. Kortom, de relatief eenvoudige randomisatie is verre te prefereren boven matching.

6. **Uitval** van respondenten is de laatste bedreiging van interne validiteit. In sommige gevallen begint een onderzoeker met veel proefpersonen. Gedurende het onderzoek vallen echter proefpersonen uit. Zolang het percentage uitvallers beperkt blijft, is er geen probleem. Maar er ontstaat wel een probleem, als de uitval selectief is voor één van de onderscheiden condities. Is dat laatste wel het geval, dan kan er over die conditie niet veel meer gezegd worden. Het probleem van uitval speelt vooral een rol bij longitudinaal onderzoek. Dit is onderzoek waarbij een beperkte groep respondenten gedurende een langere periode gevolgd wordt. Men heeft daarbij echter te maken met mensen die verhuizen, of overlijden gedurende het experiment, of participanten die niet meer willen meewerken, enz. Dit kan een enorme reductie van het aantal respondenten teweeg brengen.

Hierboven hebben we een aantal veel voorkomende problemen besproken die de interne validiteit van een onderzoek kunnen bedreigen. De lijst is echter niet uitputtend! Elk type onderzoek heeft zo z'n eigen problemen, en het is de taak van de onderzoeker om alert te zijn op mogelijke bedreigingen van de interne validiteit. Probeer daartoe plausibele verklaringen te bedenken die een eventueel effect ook, of zelfs beter zouden kunnen verklaren dan de te onderzoeken oorzaak. De onderzoeker moet dus denken als zijn eigen scepticus, die geenszins overtuigd is dat de onderzochte factor werkelijk de oorzaak is van het gevonden effect. Welke mogelijke alternatieve verklaringen zijn er volgens die scepticus, en hoe zou de onderzoeker die bedreigingen voor de validiteit kunnen wegnemen door de opzet van het onderzoek? Dat vereist goed inzicht in de logische relaties tussen de onderzoeksvragen, de onderzochte variabelen, de resultaten, en de conclusie.

5.5 Constructvaliditeit

In een experimenteel onderzoek wordt een onafhankelijke variabele gemanipuleerd. Dit kan, afhankelijk van de vraagstelling, op vele manieren. Evenzo kan de wijze waarop de afhankelijke variabele(n) gemeten wordt op verschillende manieren vorm gegeven worden. De manier waarop de onafhankelijke en de afhankelijke variabelen vorm gegeven worden noemen we de *operationalisatie* van deze variabelen. De leesvaardigheid van leerlingen kan bijvoorbeeld geoperationaliseerd worden als (a) hun score op een tekstbegriptoets met open vragen; (b) hun score op een tekstbegriptoets met meerkeuzevragen; (c) hun score op een zgn. cloze-toets (ontbrekend woord invullen); of (d) als de mate waarin geschreven instructies uitgevoerd kunnen worden. Meestal zijn er heel veel manieren om een variabele te operationaliseren, en zelden volgt uit een theorie één dwingende beschrijving voor de wijze van operationalisatie van de onafhankelijke of de afhankelijke variabelen. *Constructvaliditeit*, of *begripsvaliditeit*, heeft betrekking op de mate waarin de operationalisatie van zowel de afhankelijke variabele(n) als de onafhankelijke variabele(n) een adequate afspiegeling is (zijn) van de theoretische constructen waar het onderzoek zich op richt. Met andere woorden: zijn de onafhankelijke en de afhankelijke variabelen goed gerelateerd aan de theoretische concepten waar het onderzoek op gericht is?

Voorbeeld 5.6: De *taalontwikkeling* van babies en peuters is lastig te observeren, en al helemaal als het gaat om de auditieve en perceptieve ontwikkeling van deze proefpersonen die nog niet of nauwelijks zelf spreken. Een veel gebruikte methode is het Head Turn Preference Paradigm (Johnson and Zamuner, 2010). Bij deze methode kijkt de baby eerst naar een groen knipperend licht recht voor zich. Als de aandacht van het kind zo is gevangen, dooft vervolgens het groene licht en begint een rood licht te knipperen, aan de linker of rechter zijde van de proefpersoon. Het kind draait dan zijn of haar hoofd om het knipperende licht te zien. Vervolgens wordt er een spraakgeluidsbestand afgespeeld, via een luidspreker vlak bij het knipperende licht aan de zijkant. De afhankelijke variabele is de periode waarin het kind zijwaarts blijft kijken (met minder dan 2 s onderbreking). Daarna begint een nieuwe aanbiedingscyclus. De kijktijd wordt opgevat als een indicatie voor de mate van voorkeur van het kind voor de gesproken stimulus.

De interpretatie van de verkregen kijktijden is echter lastig, omdat kinderen nu eens voorkeur hebben voor nieuwe geluidsstimuli (bv zinnen in een onbekende taal), en dan weer juist aan bekende stimuli (bv grammaticale vs ongrammaticale zinnen). Zelfs als de stimuli

nauwkeurig zijn afgestemd op het ontwikkelingsniveau van de proefpersoon, is het lastig om de afhankelijke variabele (kijktijd) goed te relateren aan het bedoelde theoretische construct (voorkeur van kind).

Voorbeeld 5.7: Zoals hierboven aangegeven kan het begrip *leesvaardigheid* op allerlei manieren worden geoperationaliseerd. Volgens sommigen kan leesvaardigheid niet goed gemeten worden met behulp van meerkeuzevragen (Houtman 1986, Shohamy 1984). Bij meerkeuzevragen worden de antwoorden zeer sterk beïnvloed door andere zaken zoals algemene ontwikkeling, gokvaardigheid, ervaring met eerdere toetsen, en door de vraagstelling zelf, zoals geïllustreerd in deze vraag:

Wie van de volgende personen heeft de afgelopen jaren een autobiografie gepubliceerd?

- a. Jeanne d'Arc* (algemene ontwikkeling)
- b. mijn buurvrouw* (vraagstelling, ervaring)
- c. Malala Yousafzai*
- d. Alexander Graham Bell* (algemene ontwikkeling)**

Deze vraag is duidelijk niet construct-valide voor het meten van kennis over autobiografieën.

Uiteraard gelden bovengenoemde problemen met de constructvaliditeit niet alleen voor schriftelijke vragen of meerkeuzevragen, maar ook voor mondelinge vragen aan proefpersonen.

Voorbeeld 5.8: Als we ouders mondeling de vraag stellen *Hoe vaak leest U uw kind eigenlijk voor?* dan wekken we met die vraag al de suggestie dat voorlezen wenselijk is. De ouders zouden hun voorleesgedrag wel eens kunnen overschatten. We meten dus niet alleen het construct ‘voorleesgedrag’, maar ook het construct ‘neiging tot sociaal wenselijke antwoorden’ (zie hierna).

Een notoir lastig construct om te operationaliseren is *schrijfvaardigheid*. Wat is een goed en wat is een slecht schrijfproduct? En wat is dan eigenlijk schrijfvaardigheid? Kan schrijfvaardigheid gemeten worden door een telling van relevante inhoudselementen in een tekst, moeten er zinnen of woorden geteld worden, of misschien vooral connectieven (*dus, want, omdat, hoewel*, enz), moeten er oordelen van *lezers* verzameld worden over de geschreven tekst (t.a.v. doelgerichtheid, publiekgerichtheid, stijl), of moet er één oordeel van lezers verzameld worden over de globale kwaliteit, moeten er spelfouten geteld worden, etc? De problemen bij de operationalisatie komen voort uit een gebrek aan theorie over schrijfvaardigheid, waaruit een definitie voor de kwaliteit van schrijfproducten afgeleid zou kunnen worden (Van den Bergh and Meuffels, 1993). Kritiek op onderzoek naar schrijfvaardigheid is daarom makkelijk, maar alternatieve operationalisaties van het construct zijn moeilijk.

Een ander lastig construct is de *verstaanbaarheid* van gesproken zinnen. Verstaanbaarheid ('intelligibility') kan op diverse manieren worden geoperationaliseerd. De eerste mogelijkheid is dat de onderzoeker de woorden of zinnen uitspreekt en dat de proefpersoon die naspreekt, waarbij fouten in de reproductie geteld worden; een nadeel hierbij is dat er nauwelijks controle is over de model-uitspraak van de onderzoeker. Een tweede mogelijkheid is dat de woorden of zinnen vooraf worden opgenomen en verder dezelfde procedure wordt gevolgd; een nadeel blijft dat de responsies worden beïnvloed door kennis van de wereld, grammaticale verwachtingen, bekendheid met de spreker of zijn taalgebruik, enz. De meest betrouwbare methode is die van de zgn. 'speech reception threshold' (Plomp and Mimpfen, 1979) beschreven in het volgende voorbeeld. Deze methode heeft echter als nadeel dat ze tijdrovend is, niet goed automatisch afgenomen kan worden, en dat er veel stimulusmateriaal (spraakopnamen) nodig is (zijn) voor een enkele meting.

Voorbeeld 5.19: We laten een lijst van 13 gesproken zinnen horen, gemaskeerd met ruisgeluid. De verhouding tussen spraak en ruis (speech-to-noise ratio, SNR) wordt uitgedrukt in dB. Bij 0 dB SNR zijn spraak en ruis even luid, bij +3 dB SNR is de spraak 3 dB luider dan de ruis, bij -2 dB SNR is de spraak 2 dB *zachter* dan de ruis, etc. Na iedere zin moet de luisteraar de aangeboden zin naspreken. Als dat foutloos gebeurt, dan wordt voor de volgende zin de SNR met 2 dB verlaagd (minder spraak of meer ruis); als de responsie fout was, dan wordt voor de volgende zin de SNR met 2 dB verhoogd (meer spraak of minder ruis). Na een paar zinnen is er weinig variatie meer in SNR, en schommelt de SNR rond een optimum. De gemiddelde SNR over de laatste 10 aangeboden zinnen vormt de 'speech reception threshold' (SRT). Deze SRT is ook op te vatten als de SNR waarbij de helft van de zinnen goed wordt verstaan.

Tot nog toe hebben we het gehad over problemen met betrekking tot de constructvaliditeit van de afhankelijke variabelen. Maar ook de operationalisatie van de *onafhankelijke* variabele staat vaak ter discussie. De onderzoeker heeft immers vele keuzes moeten maken tijdens de operationalisering van zijn onafhankelijke variabele (zie §2.6), en de gemaakte keuzes zijn vaak wel aanvechtbaar.

Een onderzoek is niet constructvalide, of niet begripsvalide, als de operationalisaties van de afhankelijke variabelen de toets der kritiek niet kunnen doorstaan. Een onderzoek is ook niet constructvalide, als de onafhankelijke variabele niet een valide operationalisatie is van het-theoretische-begrip-zoals-bedoeld. Als die operationalisatie niet valide is, dan wordt er dus eigenlijk iets anders gemanipuleerd dan de bedoeling was. In dat geval is de relatie tussen de afhankelijke variabele en de gemanipuleerde onafhankelijke variabele zoals bedoeld niet eenduidig meer. Eventuele geobserveerde verschillen in de afhankelijke variabele hoeven niet alleen veroorzaakt te worden door de onafhankelijke variabele zoals bedoeld, maar kunnen ook beïnvloed zijn door andere factoren. Een bekend effect in dit opzicht is het zogenaamde Hawthorne-effect.

Voorbeeld 5.10: De directie van de Hawthorne Works Factory (Western Electric Company) in Cicero (Illinois), USA, was gealarmeerd door slechte bedrijfsresultaten. Een team onderzoekers nam de gang van zaken onder de loep, waarbij ongeveer alles werd onderzocht: werktijden, beloning, pauzes, verlichting, verwarming, werkoverleg, management, enz. De resultaten van dat onderzoek (uit 1927) wezen uit dat de productiviteit enorm was gestegen – maar dat er geen verband was met een van de onafhankelijke variabelen. De toename van productiviteit werd uiteindelijk toegeschreven aan de grotere aandacht voor de werknemers.

Het Hawthorne-effect houdt dus in dat een verandering in gedrag niet samenhangt met de manipulatie van enige onafhankelijke variabele, maar dat die verandering van gedrag het gevolg is van een psychologisch verschijnsel: proefpersonen die weten dat ze worden geobserveerd, doen meer hun best om gewenst gedrag te vertonen.

Voorbeeld 5.11: (Richardson et al., 1978) vergeleken de effectiviteit van twee methoden ter verbetering van de leesvaardigheid van slechte lezers. De leerlingen werden geselecteerd op basis van hun scores op drie toetsen. De 72 geselecteerde leerlingen werden aselekt toegewezen aan één van de twee methode-condities (gestructureerd leesonderwijs versus geprogrammeerde instructie). In de eerste conditie werd het gestructureerde leesonderwijs verzorgd door vier docenten, die aan een klein groepje (van vier leerlingen) les gaven. In feite is de leerling-docent-ratio dus 1 : 1. In de tweede conditie (geprogrammeerde instructie) bemoeiden de docenten zich zo min mogelijk met de leerlingen. Het experiment nam 75 sessies van 45 minuten in beslag. Na de tweede observatie bleek dat de leerlingen die volgens de eerste (gestructureerde) methode les gekregen hadden, beter vooruit waren gegaan dan de leerlingen die met behulp van de tweede methode (geprogrammeerde instructie) les gekregen hadden.

Tot zover is er geen probleem met dit onderzoek. Er ontstaat pas een probleem als we zouden concluderen dat de gestructureerde methode beter is dan de geprogrammeerde instructie. Een alternatieve verklaring, die in dit onderzoek niet uitgesloten kan worden, is dat het gevonden effect niet (alleen) het gevolg is van de methode, maar (ook) een gevolg is van de grotere individuele aandacht in de eerste conditie (gestructureerd leesonderwijs).

Net zoals bij de interne validiteit kan ook bij de construct- of begripsvaliditeit een aantal validiteitbedreigende factoren genoemd worden.

1. Een eerste bedreiging van de begripsvaliditeit is *mono-operationalisatie*. In veel onderzoeken wordt de afhankelijke variabele slechts op één manier geoperationaliseerd. De proefpersonen hoeven slechts één taak uit te voeren, bv. één auditieve taak met reactietijdmetingen (over meerdere aanbiedingen), of één vragenlijst (met meerdere vragen). Het onderzoek staat of valt dan met deze specifieke operationalisatie van de afhankelijke variabele. Over de validiteit van deze specifieke operationalisatie zijn dan geen verdere gegevens voorhanden. De onderzoeker laat in zo'n geval ruimte voor twijfel. Strikt genomen moeten we de onderzoeker immers op zijn woord geloven omtrent de validiteit van zijn operationalisering. Dergelijk onderzoek kan veel beter worden uitgevoerd. De onderzoeker moet dan het te meten construct op verschillende manieren operationaliseren, bv. door meerdere auditieve taken te laten uitvoeren, met niet alleen reactietijdmetingen maar ook met tellingen van foutieve responsies. Of de onderzoeker laat niet alleen een vragenlijst invullen, maar observeert

het bedoelde construct ook d.m.v. andere taken en observatiemethoden. Wanneer de prestaties op de verschillende typen responsies in hoge mate samenhangen, kan daarmee aangetoond worden dat al deze toetsen hetzelfde construct vertegenwoordigen. We noemen dit *convergente validiteit*. Er is sprake van convergente validiteit als de prestaties op instrumenten die hetzelfde theoretische construct vertegenwoordigen, in hoge mate samenhangen (convergeren).

Het is echter niet voldoende om te laten zien dat toetsen die hetzelfde concept of construct beogen te meten, inderdaad convergent valide zijn. Daarmee is immers nog niet aangetoond wat dit construct is, en evenmin of het gemeten construct wel het bedoelde construct is. Hebben we wel echt ‘vloeiendheid’ van de spreker gemeten, met meerdere methoden, of hebben we eigenlijk steeds het construct ‘aandacht’ of ‘spreeksnelheid’ gemeten? En hebben we wel echt ‘mate van tekstbegrip’ gemeten, met verschillende convergente methoden, of hebben we eigenlijk steeds het construct ‘faalangst’ gemeten? Om de construct-validiteit te waarborgen moet eigenlijk ook worden aangetoond dat de operationalisaties *divergent valide* zijn ten opzichte van operationalisaties die een ánder aspect of een ándere (verwante) vaardigheid beogen te meten. Kortom de onderzoeker moet kunnen aantonen dat de prestaties op instrumenten (operationalisaties) die één vaardigheid (construct) vertegenwoordigen in hoge mate samenhangen (convergeren), terwijl de prestaties op instrumenten die verschillende vaardigheden vertegenwoordigen juist lage samenhang vertonen (divergeren). Pas dan heeft de onderzoeker aannemelijk gemaakt dat de specifieke operationalisaties inderdaad constructvalide zijn.

2. Ook de verwachtingen van de onderzoeker — die zich uiten in bewust en onbewust gedrag — kunnen de constructvaliditeit van een onderzoek bedreigen. De onderzoeker is ook een mens, en is dus niet immuun voor de invloed van zijn of haar eigen verwachtingen op de uitkomsten van het onderzoek. Na afloop van het experiment is de invloed van de onderzoeker helaas moeilijk te achterhalen.

Voorbeeld 5.12: Kluger Hans was een paard dat kon rekenen. Als aan Kluger Hans gevraagd werd *hoeveel is* $4 + 4$?, dan stampte het paard 8 maal met zijn rechter voorhoef, als gevraagd werd *hoeveel is* $3 - 1$?, dan stampte Hans twee maal met zijn voorhoef. Kluger Hans baarde veel opzien en werd onderwerp van verschillende studies. Een commissie stelde in 1904 vast dat Kluger Hans inderdaad kon rekenen (en communiceren met mensen). Later constateerde een lid van de onderzoekscommissie, Carl Stumpf, samen met zijn assistent Oskar Pfungst, echter: “...het paard laat verstek gaan, als de oplossing van de gestelde opgave aan geen van de aanwezigen bekend is” (Pfungst,

1907, p.185, vert. HQ), of als het de persoon die de oplossing weet niet kan zien. “Es bedarf also optischer Hilfen” (idem). Na nauwkeurige observaties bleek dat de baas van Kluger Hans (en andere aanwezigen) zich een heel klein beetje ontspande zodra Hans het juiste aantal malen met zijn rechter voorpoot gestampt had. Dit onopzettelijke teken was voor Kluger Hans voldoende aanleiding om het stampen te staken (d.i. om zijn rechter voorhoef op de grond te houden), teneinde daarna zijn beloning van wortels en brood in ontvangst te nemen (Pfungst, 1907) (Watzlawick, 1977, p.38–47).

Een misschien vergelijkbaar, recenter geval is dat van Alex, een papegaai met bijzondere cognitieve gaven, zie o.a. (Boswall, zj) en (Ale, 2015).

Het beroemde voorbeeld van Kluger Hans illustreert hoe subtiel de invloed van een onderzoeker of proefleider op het te onderzoeken object kan zijn. Deze invloed bedreigt natuurlijk de constructvaliditeit. Het is daarom beter als de onderzoeker niet ook zelf fungeert als experimentator¹ of proefleider. Studies waarin de onderzoeker zelf optreedt als behandelaar of docent of beoordeelaar, kunnen worden bekritiseerd omdat de (verwachtingen van de) onderzoeker de uitkomsten kunnen beïnvloeden, waardoor de constructvaliditeit van de onafhankelijke variabele wordt bedreigd. Onderzoekers kunnen zich wel verweren tegen deze ‘experimenter bias’. In het Head Turn Preference Paradigm (voorbeeld 5.6), bijvoorbeeld, is het gebruikelijk dat de experimentator niet weet uit welke groep een proefpersoon afkomstig is, en dat de experimentator niet hoort welk geluidsbestand wordt aangeboden (Johnson and Zamuner, 2010, p.74).

3. Een derde bedreiging van de constructvaliditeit kan samengevat worden onder de term *motivatie*. Aan de bedreiging van de validiteit door motivatie zitten tenminste twee kanten. Als (ten minste) één van de condities in een onderzoek erg belastend of vervelend is, dan kunnen de proefpersonen gedemotiveerd raken en zich minder inspannen bij hun taken. Ze presteren dan minder, maar dit is een effect van (gebrek aan) motivatie, en niet een direct effect van de onafhankelijke variabele (hier: conditie). Het effect hoeft dan niet veroorzaakt te worden door de manipulatie van het bedoelde construct, maar door de onbedoelde manipulatie van de *motivatie* van de proefpersonen. Ook het omgekeerde kan natuurlijk een bedreiging van de constructvaliditeit vormen. Indien van één van de condities een extra motiverende werking op de proefpersonen heeft, dan kan een eventueel effect toegeschreven worden aan motivationele aspecten. Ook dan kan er sprake zijn van een effect van een onbedoeld gemanipuleerde variabele.

¹De experimentator is degene die een experiment afneemt bij een proefpersoon. De experimentator kan een andere persoon zijn dan de onderzoekers die de onderzoekshypothesen hebben opgesteld en/of proefpersonen hebben gerecruteerd.

4. Een vierde bedreiging van de validiteit heeft te maken met de keuze uit de vele mogelijke waarden van een onafhankelijke variabele, d.w.z. de ‘*dosering*’ ervan. Als de onafhankelijke variabele is ‘het aantal keren dat een gedicht ter voorbereiding mag worden doorgelezen’, moet de onderzoeker bepalen hoeveel keer de proefpersonen het gedicht mogen doorlezen: één, twee, drie of meer keren? Als de onafhankelijke variabele is ‘de tijd die de proefpersonen mogen studeren’, dan moet de onderzoeker kiezen hoe lang de proefpersonen mogen leren: vijf minuten, een kwartier, twee uur? De onderzoeker maakt een keuze uit de dosering van de onafhankelijke variabele ‘leertijd’. Op grond van deze dosering kan de onderzoeker concluderen dat de afhankelijke variabele niet beïnvloed wordt door de onafhankelijke variabele. In feite moet de onderzoeker echter concluderen dat er geen verband lijkt tussen de *gekozen dosering* van de onafhankelijke variabele, en de afhankelijke variabele. Een mogelijk effect wordt verhuld door de keuze van de dosering (waarden) van de onafhankelijke variabele.

Voorbeeld 5.13: Als een personenauto en een voetganger botsen, loopt de voetganger een risico te overlijden. Dat overlijdensrisico is relatief gering (kleiner dan 20%) bij botsingssnelheden tot ca 50 km/u. Als we ons onderzoek naar het verband tussen botsingssnelheid en overlijdensrisico zouden beperken tot deze lage ‘doseringen’ van botsingssnelheden, dan zouden we wellicht concluderen dat de botsingssnelheid géén invloed heeft op het overlijdensrisico voor de voetganger. Dat zou een foutieve conclusie zijn (van welk type?), want bij hogere botsingssnelheden neemt het overlijdensrisico voor de voetganger toe tot bijna 100% (Rosén et al., 2011; SWOV, 2012).

5. Een vijfde bedreiging van de constructvaliditeit wordt veroorzaakt door de *sturende werking van de voormeting*. In veel studies wordt de afhankelijke variabele herhaaldelijk gemeten, zowel voor als na manipulatie van de afhankelijke variabele: de zgn. voormeting en nameting. De aard en inhoud van de voormeting kunnen echter sporen nalaten bij de proefpersoon. Zo kan de proefpersoon zijn onbevangenheid verliezen, waardoor het effect van de onafhankelijke variabele (bv. behandeling) wordt verkleind. Een eventueel verschil in scores tussen de experimentele condities kan dus op meerdere manieren worden verklaard. De verklaring kan immers liggen in een effect van alleen de onafhankelijke variabele, maar kan ook liggen in een effect van *de combinatie van voormeting en onafhankelijke variabele*. Bovendien kan de afwezigheid van een effect soms worden verklaard door het feit dat een voormeting is verricht (zie het Solomon vier-groepen-ontwerp, in Hoofdstuk 6, voor een onderzoeksontwerp dat hiermee rekening houdt).

Voorbeeld 5.14: We kunnen de effecten van twee behandelingen vergelijken in een experiment waarin de deelnemers volgens het toeval in twee groepen worden ingedeeld. De eerste groep (E) krijgt eerst een voormeting, dan een behandeling, en dan een nameting. De tweede groep (C) krijgt geen voormeting, en ook geen behandeling, maar alleen een nameting, die voor deze groep de enige meting is.

Als we bij de nameting een verschil vinden tussen de twee groepen, dan is dat niet zonder meer toe te schrijven aan het verschil in behandeling. Het verschil zou ook, of mede, veroorzaakt kunnen zijn door de sturende werking van de voormeting, bv als gevolg van de sturende woordkeuze of zinsbouw van de vragen of opdrachten in de voormeting. Misschien hebben de deelnemers in groep E iets geleerd in de voormeting, d.w.z. *niet* in de behandeling, waardoor ze beter of anders presteren in de nameting dan de deelnemers in groep C.

-
6. Een ander probleem dat van invloed kan zijn op de constructvaliditeit is *sociaal wenselijk antwoorden*. Dat is niets anders dan dat mensen geneigd zijn een antwoord geven, dat in de gegeven sociale situatie wenselijk is, en dat hen dus niet in de problemen brengt of tot gezichtsverlies leidt. Een voorbeeld kan dit verduidelijken.

Voorbeeld 5.15: Bij peilingen voor verkiezingen zijn respondenten geneigd om sociaal wenselijk te antwoorden, en dat geldt ook voor de vraag of de respondent überhaupt zal gaan stemmen (Karp and Brockington, 2005). De neiging tot het sociaal wenselijke antwoord (“ja, ik ga stemmen”) is sterker naarmate respondenten hoger zijn opgeleid, en dus is de overschatting van het opkomst-percentages groter voor hoger-opgeleiden dan voor lager-opgeleiden. Dat heeft weer gevolgen voor de uitslagen van de peilingen van de verschillende partijen, omdat de populariteit van de politieke partijen verschillend is voor kiezers van verschillend opleidingsniveau.

Dit effect heeft mede gezorgd voor de overschatting van het aantal Clinton-stemmers, en onderschatting van het aantal Trump-stemmers, bij de peilingen voorafgaand aan de Amerikaanse presidentsverkiezing in 2016.

7. Een laatste probleem met betrekking tot de constructvaliditeit kan aangeduid worden als: een *beperkte generaliseerbaarheid* over constructen. Bij de presentatie van onderzoeksresultaten worden regelmatig opmerkingen gemaakt als: ‘Ja, ik ben het eens met uw conclusie dat X van invloed is op Y, maar hoe zit het met...’. Op de puntjes kan dan van alles ingevuld worden: de toepasbaarheid bij andere doelgroepen, of in andere genres, of in andere talen, etc. Deze aspecten zijn weliswaar van belang, maar spelen in het onderzoek zelf niet direct een rol: we hebben het onderzoek immers uitgevoerd met een bepaalde selectie van doelgroep, genre, talen, etc.

Toch bevelen we wel aan om zulke vragen over generaliseerbaarheid onder ogen te zien. Zijn de conclusies eveneens van toepassing op een andere doelgroep of taal? Waarom wel of niet? Welke andere factoren zouden de generalisatie kunnen beïnvloeden? Zou een gunstig effect voor de ene groep of taal ook kunnen uitpakken als een ongunstig effect voor een andere groep of taal die buiten het onderzoek is gevallen?

5.6 Externe validiteit

Op basis van de gegevens die zijn verzameld kan een onderzoeker — als het goed is — de conclusie trekken: *in dit onderzoek geldt dat....* Het is echter zelden de bedoeling van een onderzoeker om conclusies te trekken die alleen gelden voor één onderzoek. Een onderzoeker wil niet aantonen dat tweetaligheid een gunstige invloed heeft op de taalontwikkeling *van de steekproef van onderzochte kinderen*. Een onderzoeker wil conclusies trekken als: tweetaligheid heeft een gunstige invloed op de taalontwikkeling *van kinderen*. De onderzoeker wil generaliseren. In het dagelijks leven doen we hetzelfde: we proeven één hapje soep uit een hele pan, en op grond daarvan doen we een uitspraak over die hele pan soep. We gaan er van uit dat onze bevindingen op basis van dat ene hapje gegeneraliseerd mogen worden naar de hele pan, en dat het niet nodig is om de hele pan leeg te eten voordat we er een uitspraak over kunnen doen.

De vraag of een onderzoeker de resultaten kan en mag generaliseren is de vraag naar de *externe validiteit* van een onderzoek (Shadish et al., 2002). Generalisatie heeft betrekking op o.a.

- eenheden: zijn de resultaten ook geldig voor andere elementen (bv. scholen, personen, teksten) uit de populatie, die niet aan het onderzoek deelnamen?
- behandelingen: zijn de resultaten ook geldig voor andere behandelingen die lijken op de specifieke condities in dit onderzoek?
- situaties: zijn de resultaten ook geldig buiten de specifieke context van dit onderzoek?

- tijden: zijn de resultaten van dit onderzoek ook geldig op andere tijdstippen?

Bij externe validiteit maken we een onderscheid tussen (1) de generalisatie *naar* een beoogde specifieke doelgroep, situatie en tijd, en (2) de generalisatie *over* andere doelgroepen, situaties en tijden. Het generaliseren *naar* en *over* zijn twee aspecten van de externe validiteit die goed uit elkaar gehouden moeten worden. Het generaliseren *naar* een doelgroep of populatie, van personen en vaak ook van taalmateriaal, heeft te maken met de representativiteit van de gebruikte steekproef; in hoeverre is de steekproef een goede afspiegeling van de populatie (van personen, van woorden, van relevante mogelijke zinnen)? Het generaliseren *naar* is dus direct verbonden met het onderzoeksdoel; pas als er gegeneraliseerd kan worden naar gedefinieerde populaties kan een onderzoeksdoel bereikt zijn. Het generaliseren *over* doelgroepen heeft te maken met de mate waarin de geformuleerde conclusies geldig zijn voor te onderscheiden deelpopulaties. We illustreren dit met een voorbeeld.

Voorbeeld 5.16: (Lev-Ari and Keysar, 2010) onderzochten of luisteraars minder geloof hechten aan sprekers met een vreemd buitenlands accent in de uitspraak van het Engels. Voor de stimuli lieten ze zinnen uitspreken (bv. *A giraffe can hold more water than a camel*) door verschillende sprekers zonder enig accent, met licht accent, of met sterk accent. Luisteraars (moedertaal-sprekers van het Engels) gaven aan in welke mate ze dachten dat de gesproken zin waar was. De resultaten lieten zien dat de luisteraars de zinnen beoordeelden als minder waar, als de zin was gesproken door een spreker met een vreemd buitenlands accent.

We mogen aannemen dat deze uitkomst gegeneraliseerd kan worden *naar* de beoogde doelgroep, nl. alle moedertaal-luisteraars van het Amerikaans Engels. Deze generalisatie kan worden gemaakt ondanks de mogelijkheid dat verschillende luisteraars misschien in verschillende mate beïnvloed werden door het buitenlandse accent van de spreker.

Wellicht zou een latere analyse kunnen laten zien dat er verschil is tussen vrouwelijke en mannelijke luisteraars. Het is denkbaar dat vrouwen en mannen verschillen in hun gevoeligheid voor het accent van de spreker. Zo'n (denkbeeldige) uitkomst zou laten zien dat er niet gegeneraliseerd mag worden *over* deelpopulaties binnen de doelgroep, hoewel er wel gegeneraliseerd kon worden *naar* de doelgroep.

In het (toegepast) taalwetenschappelijk onderzoek proberen onderzoekers door- gaans om *tegelijkertijd* te generaliseren naar *twee* populaties van eenheden, nl. van personen (c.q. scholen of families) *en stimuli* (woorden, zinnen, teksten, enz). We willen aannemelijk maken dat de resultaten niet alleen geldig zijn voor de onderzochte taalgebruikers, maar ook voor andere taalgebruikers. Tegelijk- ertijd willen we ook aannemelijk maken dat de resultaten niet alleen geldig zijn voor de onderzochte stimuli, maar ook voor andere vergelijkbaar taalmateriaal waaruit de steekproef van stimuli is getrokken. Die gelijktijdige generalisatie vereist een complex onderzoeksontwerp, doordat er herhaalde observaties zijn binnen proefpersonen (meerdere oordelen van eenzelfde proefpersoon) en binnen stimuli (meerdere oordelen over dezelfde stimulus). Stimuli, proefpersonen en condities worden vervolgens slim gecombineerd om de interne validiteit zo goed mogelijk te beschermen. Uiteraard vereist de generalisatie naar ander taalma- teriaal wel, dat de stimuli willekeurig zijn geselecteerd uit de (soms oneindig grote) populatie van al het mogelijke taalmateriaal (zie Hoofdstuk 7).

Chapter 6

Ontwerp

6.1 Inleiding

Veel van de problemen met validiteit, die we bespraken in Hoofdstuk 5, kunnen voorkomen worden door goede gegevens op een goede manier te verzamelen. Het *ontwerp* (Eng. “design”) van een onderzoek geeft aan volgens welk schema of plan de gegevens verzameld zullen worden. Als we een goed en sterk ontwerp gebruiken, dan kunnen we daarmee al veel mogelijke bedreigingen voor de validiteit neutraliseren. Dat maakt ons onderzoek sterker. Het is dus raadzaam om een onderzoeksontwerp vooraf heel goed te doordenken! Uiteraard moet het ontwerp nauw aansluiten bij de vraagstelling: de gegevens uit het onderzoek moeten de onderzoeker immers in staat stellen om een valide antwoord te geven op de onderzoeksvraag.

De onderzoeksontwerpen die we in dit hoofdstuk bespreken vormen slechts een beperkte selectie uit de mogelijke ontwerpen. Sommige ontwerpen bespreken we vooral om aan te geven wat er mis kan gaan bij een “zwak” ontwerp; andere ontwerpen zijn juist populair omdat ze relatief “sterk” onderzoek mogelijk maken.

Een onderzoeksontwerp is opgebouwd uit verschillende elementen:

- *tijd*, meestal afgebeeld als verstrijkend in de leesrichting. De tijdsvolgorde is van belang om een causaal verband vast te stellen: eerst de oorzaak, daarna het gevolg (§5.2). De tijdsvolgorde is echter een noodzakelijke voorwaarde, maar niet een voldoende voorwaarde om een causaal verband vast te stellen. Anders gezegd, ook als het gevolg (bv. herstel) inderdaad optreedt na de oorzaak (bv. behandeling), dan houdt dat *niet* in dat de behandeling ook inderdaad het herstel heeft veroorzaakt. Misschien is het herstel wel spontaan opgetreden, of is het herstel het gevolg van een andere oorzaak waar het onderzoek niet op gericht was.

Voorbeeld 6.1: Stel je Gus voor: als iemand last heeft van brandneteluitslag, of een insectenbeet, of eczeem, of een blauwe plek, dan spuit Gus er wat Glassex op — en na een paar dagen is de aandoening verdwenen. Gus is ervan overtuigd dat zijn Glassex-behandeling de oorzaak is van de genezing. Maar dit is een misvatting die bekend staat als “post hoc ergo propter hoc” (na iets dus als gevolg van iets). De aandoening zou hoogstwaarschijnlijk ook goed zijn genezen zonder de Glassex-behandeling. De genezing bewijst dus niet dat de Glassex-behandeling noodzakelijk is. (Dit voorbeeld is ontleend aan de speelfilm *My Big Fat Greek Wedding*, 2004).

- *groepen* van eenheden (bv. proefpersonen), doorgaans correspondeert een groep met een regel in het ontwerp.
- *behandeling*, meestal afgebeeld als X . Een behandeling kan ook bestaan uit het ontbreken van een behandeling (“control”), of uit het aanbieden van de niet-experimentele, gebruikelijke behandeling (“usual care”).
- *observatie*, meestal afgebeeld als 0 .
- de *toewijzing van proefpersonen* aan groepen of behandelcondities kan op verschillende manieren gebeuren. Meestal doen we dat aselekt (willekeurig, at random, hieronder aangegeven met R), omdat daarmee de validiteit meestal het beste beschermd wordt.

6.2 Tussen of binnen ?

Voor het onderzoeksontwerp is het van groot belang of een onafhankelijke variabele gevarieerd wordt *tussen proefpersonen* of *binnen proefpersonen*. Voor veel taalkundig onderzoek, waarbij meerdere teksten of zinnen of woorden worden aangeboden als stimuli, geldt hetzelfde voor het onderscheid *tussen stimuli* of *binnen stimuli*.

Individuele variabelen van de proefpersonen, zoals diens geslacht (man, vrouw) of meertaligheid, kunnen normaliter alleen variëren tussen proefpersonen: eenzelfde proefpersoon kan niet meedoen aan beide geslachts-groepen van een onderzoek, en ééntalige proefpersonen kunnen niet meedoen in de groep van meertalige proefpersonen. Maar bij andere variabelen, die betrekking hebben op de wijze waarop stimuli worden verwerkt, is dat wel mogelijk. Dezelfde proefpersoon kan schrijven met zijn linkerhand en met zijn rechterhand, of kan geobserveerd worden voorafgaand aan en volgend op een behandeling. De onderzoeker moet dan in het onderzoeksontwerp kiezen op welke wijze de behandelingen en observaties worden gecombineerd. We komen daarop terug in §6.9.

6.3 Het one-shot single-case-ontwerp

Dit is een zwak ontwerp, waarbij er slechts éénmaal observaties worden gedaan, na een behandeling. Dit onderzoeksontwerp heeft het volgende schema:

X 0

We zouden bijvoorbeeld kunnen tellen, voor alle eindwerkstukken van studenten van een bepaalde opleiding van een bepaald cohort, hoeveel fouten (van een bepaald type) er in die eindwerkstukken voorkomen. Dat is wel een beetje interessant, maar wetenschappelijk zijn deze gegevens echter van weinig waarde. Er kan geen enkele vergelijking gemaakt worden met andere gegevens (van andere studenten, en/of andere werkstukken van dezelfde studenten). Het is niet mogelijk om een valide conclusie te trekken over mogelijke effecten van de “behandeling” (studie, X) op de observaties (aantal fouten, 0).

Soms worden de gegevens uit een one-shot-single-case-onderzoek geforceerd vergeleken met andere gegevens, bijvoorbeeld met norm-resultaten voor een grote controlegroep. Stel je voor dat we willen onderzoeken of een nieuwe methode van taalonderwijs leidt tot betere taalvaardigheid in de doeltaal. Na een cursus met de nieuwe lesmethode meten we de taalvaardigheid, en vergelijken die met de eerder gepubliceerde resultaten van een controlegroep die de traditionele lesmethode heeft gebruikt. Deze aanpak wordt veelvuldig toegepast, maar er zijn desalniettemin diverse factoren die de validiteit bedreigen (zie §5.4): o.a. geschiedenis (de nieuwe proefpersonen hebben een andere geschiedenis en levensloop gehad dan de controlegroep uit het verleden), rijping (de nieuwe proefpersonen zijn misschien verder of minder ver ontwikkeld dan de controlegroep), instrumentatie (de toets is mogelijk niet even geschikt voor personen onderwezen met de nieuwe lesmethode als met de traditionele methode), en uitval (de uitval van proefpersonen voorafgaand aan de observatie is niet bekend, noch voor de traditionele methode noch voor de nieuwe methode).

Voorbeeld 6.2: Een interviewer kan zgn. ‘gesloten’ vragen stellen met slechts enkele mogelijke antwoorden (*welk van de drie groentesoorten vind je het lekkerst, doperwtjes of sperziebonen of broccoli?*), of ‘open’ vragen waarin de mogelijke antwoorden niet worden beperkt door de vraagstelling (*welke groente vind je het lekkerst?*). Er is ook een derde categorie, nl. open vragen met voorbeeld-antwoorden (*welke groente vind je het lekkerst, bijvoorbeeld doperwtjes of sperziebonen of...?*). Het is echter niet duidelijk of deze voorbeeld-antwoorden wel of niet een sturend effect hebben, d.w.z. of ze meer vergelijkbaar zijn met gesloten of met open vragen. (Houtkoop-Steenstra, 1991)

bestudeerde opgenomen gesprekken tussen artsen en hun patiënten. De artsen stelden regelmatig open vragen met voorbeeldantwoorden. Meestal bleken de patiënten zo'n vraag *niet* als sturend op te vatten; zij vatten de vraag vooral op als een verzoek om te vertellen.

Dit onderzoek is te beschouwen als een one-shot-single-case-ontwerp, zonder vergelijking met gegevens uit andere condities. De conclusies zijn weliswaar gebaseerd op empirische observaties, maar we weten niet wat de geïnterviewde geantwoord zou hebben als de vraag anders gesteld zou zijn.

Ondanks al deze bezwaren kan een one-shot-case onderzoek wel van nut zijn in de observatiefase van de empirische cyclus, wanneer het gaat om het opdoen van ideeën en het formuleren van (globale) hypothesen, die later goed getoetst kunnen worden.

6.4 Het één-groep-voormeting-nameting-ontwerp

Bij het één-groep-voormeting-nameting-ontwerp worden gegevens verzameld van één groep. Op het eerste tijdstip (meestal aangeduid als T1, maar soms als T0) wordt een eerste meting uitgevoerd (voormeting, 01), vervolgens wordt de groep aan de experimentele behandeling blootgesteld, en tenslotte wordt op een later tijdstip (T2) een tweede meting uitgevoerd (nameting, 02). In schema ziet een één-groep-voormeting-nameting-ontwerp er als volgt uit:

01 X 02

De behandeling X varieert dus niet: iedereen krijgt dezelfde behandeling, want er is slechts één groep. Het tijdstip van de meting, meestal aangeduid als voormeting T0 (01) en nameting T1 (0), varieert binnen proefpersonen.

Dit ontwerp is over het algemeen beter dan het vorige one-shot-case-ontwerp én beter dan helemaal geen gegevens. Toch beschouwen wij het als een zwak onderzoeksontwerp, omdat diverse bedreigingen van de validiteit niet goed ondervangen worden (zie §5.4). Een eventueel verschil tussen 02 en 01 kan niet uitsluitend toegeschreven worden aan de tussenliggende behandeling X: dit effect kan ook het gevolg zijn van rijping (de verbetering is het gevolg van rijping van de proefpersonen) of van geschiedenis (de verbetering is het gevolg van een of meerdere gebeurtenissen anders dan X die zijn opgetreden tussen de tijdstippen van 01 en 02). Als de behandeling X of de nameting 02 afhankelijk is van de score op de voormeting 01, dan kan ook de regressie naar het gemiddelde de validiteit bedreigen. Kortom, aan dit onderzoeksontwerp kleven diverse bezwaren, omdat de hypothese over het effect van de onafhankelijke variabele niet zonder meer op valide wijze beantwoord kan worden.

6.5 Het voormeting-nameting-controlegroep-ontwerp

De bovengenoemde problemen kunnen voor een deel ondervangen worden door een controlegroep toe te voegen aan het ontwerp; we krijgen dan een voormeting-nameting-controlegroep-ontwerp. Er zijn dan dus twee groepen van elementen (proefpersonen). In schema wordt dat weergegeven door twee regels. Dit ontwerp wordt zeer vaak gebruikt. Waar mogelijk proberen onderzoekers de twee groepen zo vergelijkbaar mogelijk te maken, door de proefpersonen aselekt (at random, willekeurig, volgens toeval) toe te wijzen aan de twee groepen. In schema ziet dit model er als volgt uit (de R staat voor random toewijzing aan de twee groepen):

| | | | |
|---|----|---|----|
| R | 01 | X | 02 |
| R | 03 | | 04 |

Dit onderzoeksontwerp is populair, omdat het veel mogelijke bedreigingen van de interne validiteit kan ondervangen (zie §5.4). Het effect van de manipulatie of behandeling (X) wordt geëvalueerd door een vergelijking van de twee verschillen (02-01) en (04-03). Dit onderzoeksontwerp heeft eigenlijk niet één maar twee onafhankelijke variabelen, die van invloed kunnen zijn op de metingen: (1) de manipulatie of behandeling, X of niet-X, variërend tussen proefpersonen, en (2) het tijdstip van de meting, meestal aangeduid als voormeting T0 en nameting T1, variërend binnen proefpersonen.

In dit ontwerp wordt wel rekening gehouden met de effecten van geschiedenis, althans voor zover die effecten voor beide groepen in gelijke mate zijn opgetreden. Er wordt geen rekening gehouden met gebeurtenissen die slechts één van de groepen (condities) hebben beïnvloed. Als er wel zo'n gebeurtenis is geweest voor de ene groep en niet voor de andere groep, dan kan dat verschil in geschiedenis dus ook verantwoordelijk zijn voor een ongelijk verschil tussen voormeting en nameting in de ene groep ten opzichte van de andere groep.

De bedreiging van de interne validiteit door rijping kan in dit onderzoeksontwerp makkelijk opgevangen worden. Een effect van rijping komt immers naar verwachting in beide groepen in gelijke mate tot uiting, en kan daarom niet van invloed zijn op het verschil tussen (02-01) en (04-03). Natuurlijk gaan we er hierbij vanuit dat de voormetingen voor de twee groepen resp. de nametingen voor de twee groepen op hetzelfde tijdstip zijn afgenomen.

Ook een storend effect van instrumentatie wordt geneutraliseerd, als aan de eisen voor vergelijkbare afnamecondities voldaan wordt, en als gemeten wordt met hetzelfde instrument, zoals hetzelfde apparaat of computerprogramma of gedrukte toets. Wanneer echter observatoren of beoordelaars ingeschakeld moeten worden, zoals bij onderzoek naar de schrijfvaardigheid, dan wordt de instrumentatie een moeilijker factor. Het is dan van groot belang dat deze

beoordelaars *niet* weten door welke proefpersonen of onder welke conditie de te beoordelen producten of responsies tot stand zijn gekomen. Anders zouden hun verwachtingen (onbewust en onbedoeld) een rol kunnen spelen bij het tot stand komen van hun oordeel. In dat geval zou niet een effect van de onafhankelijke variabele aangetoond worden, maar een effect van de vooringenomenheid van beoordelaars.

Ook het probleem van regressie naar het gemiddelde speelt in dit ontwerp een kleinere rol. Indien de proefpersonen aselekt zijn toegewezen aan de twee groepen, én de gegevens van alle proefpersonen gelijktijdig in een analyse betrokken worden, dan speelt regressie naar het gemiddelde geen enkele rol. In beide groepen treedt immers regressie naar het gemiddelde op, en naar verwachting in gelijke mate, waardoor dat niet van invloed is op de analyse van het verschil tussen (02-01) en (04-03).

Selectie van proefpersonen wordt in dit onderzoeksontwerp uitgesloten door de steekproef van proefpersonen aselekt te kiezen uit de populatie, en door daarna de proefpersonen wederom aselekt toe te wijzen aan de twee groepen of condities. Natuurlijk geldt hier de wet van de grote getallen: als een grotere steekproef aselekt wordt gesplitst in twee groepen, dan is ook de kans groter dat de twee groepen gelijkwaardig zijn, ten opzichte van een kleinere steekproef.

Uitval kan wel degelijk een oorzaak zijn voor een verschil tussen (02-01) en (04-03). Deze voor de validiteit bedreigende factor is moeilijk te beheersen. We kunnen proefpersonen immers niet dwingen om aan een onderzoek te blijven meewerken, of om niet te verhuizen, of niet te overlijden. Uitval kan dus een probleem zijn, zeker wanneer er een verschil in uitval is tussen de twee groepen of condities. Het is goed gebruik om de uitval te melden in het onderzoeksverslag, en de mogelijke gevolgen ervan te bespreken.

Met dit voormeting-nameting-controlegroep-ontwerp kunnen de verschillende factoren die de interne validiteit bedreigen dus redelijk goed beheerst worden. Maar hoe zit het met de constructvaliditeit (zie §5.5)? Deze bedreigingen hebben we niet eerder aangeroerd bij het one-shot-case-ontwerp en het één-groep-voormeting-nameting-ontwerp, omdat bij deze onderzoeksontwerpen de interne validiteit al twijfelachtig was.

Niet alle aspecten van de constructvaliditeit hebben echter repercussies op het onderzoeksontwerp. Sommige aspecten met betrekking tot de wijze van operationalisatie, zoals convergente en divergente validiteit, zijn niet relevant voor de keuze van het onderzoeksontwerp. Maar andere aspecten zijn wel relevant: de verwachtingen van de onderzoeker, aandacht, motivatie, en de sturende werking van de voormeting.

Het voormeting-nameting-controlegroep-onderzoeksontwerp biedt voor geen van deze vier bedreigingen van de constructvaliditeit adequate waarborgen. De *verwachtingen van de onderzoeker* kunnen in zowel de experimentele als de controle-conditie een (verschillende) rol spelen, omdat in beide condities op twee tijdstippen gemeten wordt. Bovendien kan een eventueel verschil tussen

(02-01) en (04-03) ook te wijten zijn aan de (extra) *aandacht* die aan de experimentele conditie besteed is: het zgn. Hawthorne-effect (zie Voorbeeld 5.10 in Hoofdstuk 5). Dit effect speelt vooral een rol als de proefpersonen in de ene conditie (groep) meer aandacht krijgen dan in de andere, zoals in het onderstaande voorbeeld.

Een derde bedreiging van de constructvaliditeit van een onderzoek is de *motivatie*. Soms kan één van de condities zo demotiverend werken dat de proefpersonen in deze conditie niet meer serieus aan het onderzoek meewerken. Net als bij aandacht gaat het niet zozeer om de aantrekkelijkheid van één van de condities, maar om de verschillen in aantrekkelijkheid tussen de onderzoekscondities.

In het voormeting-nameting-controlegroep-ontwerp kan de constructvaliditeit tevens bedreigd worden door de *sturende werking van de voormeting*. Door een voormeting (01 en 03) kunnen de proefpersonen zich van bepaalde aspecten van het onderzoek (meer) bewust worden, waardoor zij zich daarna niet meer als naïeve proefpersonen gedragen. De voormeting kan dan als een soort manipulatie beschouwd worden (zie Voorbeeld 6.3 hieronder).

6.6 Het Solomon-vier-groepen-ontwerp

Het Solomon-vier-groepen-ontwerp wordt veel minder vaak gebruikt dan het voormeting-nameting-controlegroep-ontwerp. Toch verdient dit ontwerp duidelijk de voorkeur boven het voormeting-nameting-controlegroep-ontwerp. Met name bedreigingen van de constructvaliditeit worden in dit ontwerp beter onder controle gehouden.

In het Solomon-vier-groepen-ontwerp worden vier condities onderscheiden. De proefpersonen worden aselekt toegewezen aan een van deze vier condities. In de eerste twee condities wordt eerst een voormeting gehouden, waarna één van de groepen aan de experimentele behandeling blootgesteld wordt. Daarna volgt voor beide groepen een nameting. Tot zover is het Solomon-vier-groepen-ontwerp dus exact gelijk aan het voormeting-nameting-controlegroep-ontwerp. In de derde en vierde conditie wordt echter géén voormeting gehouden. In de ene conditie worden de proefpersonen wel aan de experimentele behandeling blootgesteld, maar in de andere conditie niet. Tot slot maken deze beide groepen weer een nameting. Schematisch kan het Solomon-vier-groepen-ontwerp als volgt weergegeven worden:

| | | |
|----|---|----|
| 01 | X | 02 |
| 03 | | 04 |
| | X | 05 |
| | | 06 |

Het Solomon-vier-groepen-ontwerp is dus een uitbreiding van het voormeting-nameting-controlegroep-ontwerp met twee groepen, die niet meedoen met de

voormeting. Door de twee extra condities zonder voormeting kan rekening gehouden worden met de sturende werking van de voormeting: die sturende werking is immers niet aanwezig in de derde en vierde groep. Bovendien wordt het effect van de manipulatie van de onafhankelijke variabele X verschillende malen getoetst, in de vier vergelijkingen van 02 en 01, 02 en 04, 05 en 06, en (02-01) en (04-03). Het effect van de mogelijk sturende voormeting wordt getoetst in de twee vergelijkingen van 02 en 05, en 04 en 06. We kunnen dus in één onderzoek zowel een effect van de behandeling als van de voormeting aantonen. Daarvoor moeten we echter wel twee extra groepen proefpersonen inzetten (ten opzichte van het voormeting-nameting-controlegroep-ontwerp).

Voorbeeld 6.3: In een onderzoek (Ayres et al., 2000) werd het effect onderzocht van een gewenningstraining (X) op de angst om in het openbaar te spreken. Spreekangst werd gemeten door de proefpersoon eerst een toespraak te laten houden, en daarna twee vragenlijsten over spreekangst te laten invullen. Bij elkaar vormt dat één meting. De gewenningstraining voor de ene groep bestond uit het bekijken van een trainingsvideo van ca 20 minuten; de tweede groep kreeg in plaats daarvan een pauze van dezelfde duur. Het onderzoek gebruikte een Solomon-vier-groepen-ontwerp om een mogelijk sturende werking van de voormeting te kunnen onderzoeken. Het is immers mogelijk dat de voormeting (waarvan een spreekbeurt deel uitmaakt) zelf al een training vormt voor de proefpersonen, zodat de gunstige effecten na de “behandeling” X (gewenningstraining) niet toegeschreven kunnen worden aan die behandeling, maar (mede) aan die voormeting. De resultaten lieten echter zien dat de gewenningstraining inderdaad een sterk (gunstig) effect had op de spreekangst, en dat de voormeting alleen (dus zonder behandeling) geen enkel effect had op de mate van spreekangst bij de proefpersonen.

6.7 Het nameting-controlegroep-ontwerp

In heel veel onderzoeken wordt een voormeting uitgevoerd, omdat de onderzoekers willen onderbouwen dat de twee (of meer) onderzoeksgroepen niet van elkaar verschillen bij de aanvang van het onderzoek. Toch is die voormeting niet een essentieel onderdeel van een adequaat onderzoeksontwerp. Als de groepen voldoende groot zijn, en als de proefpersonen (of andere onderzoekseenheden) geheel volgens het toeval zijn toegewezen aan de groepen, dan zijn

de twee groepen op statistische gronden al goed vergelijkbaar. Als we bijvoorbeeld 100 proefpersonen geheel volgens het toeval verdelen over 2 groepen, dan is de kans buitengewoon klein dat de twee groepen zouden verschillen in de voormeting. In veel van dit soort gevallen kan dan ook volstaan worden met een nameting-controlegroep-ontwerp, schematisch weergegeven als volgt:

X 05
 06

Dit ontwerp is echter alleen adequaat indien de groepen voldoende groot zijn, en indien de proefpersonen aselekt zijn toegewezen aan de condities. Als dat niet mogelijk is, dan voldoet dit ontwerp ook niet.

Voorbeeld 6.4: In vervolg op het onderzoek van (Houtkoop-Steenstra, 1991) (Voorbeeld 6.2) onderzochten (Wijffels et al., 1992) in hoeverre vragen met danwel zonder voorbeeldantwoorden in een mondelinge (telefonisch) vraaggesprek als sturend werden opgevat. Hiertoe werden vijf vragen geconstrueerd over criminaliteit. Van elke vraag werden twee versies geconstrueerd: één met en één zonder voorbeeldantwoorden. Aan elke respondent (van een steekproef van 50) werden twee of drie vragen gesteld met voorbeeldantwoorden, en twee of drie vragen zonder voorbeeldantwoorden. De toedeling van vragen met en zonder voorbeeldantwoorden was gerandomiseerd, en daardoor mogen we aannemen dat de groep respondenten die een bepaalde vraag met voorbeeldantwoorden kreeg niet verschilt van de groep respondenten die dezelfde vraag zonder voorbeeldantwoorden kreeg. Als beide groepen dezelfde (soort) antwoorden geven, dan hebben de voorbeeldantwoorden blijkbaar geen sturend effect, maar indien de respondenten vaak antwoorden met de gegeven voorbeeldantwoorden dan hebben de voorbeelden blijkbaar wel een sturend effect. Bij analyse bleek dat voor vier van de vijf vragen een dergelijk sturend effect inderdaad optrad.

De twee onderzoeken van (Houtkoop-Steenstra, 1991) en (Wijffels et al., 1992) illustreren hoe wetenschappelijke kennis zich ontwikkelt. (Houtkoop-Steenstra, 1991) constateert dat de vakliteratuur zich voornamelijk bezig heeft gehouden met schriftelijke interviews, en vraagt zich af of de effecten bij mondelinge 'face-to-face'-interviews hetzelfde zijn. Zij concludeert dat voorbeeldantwoorden niet sturend werken in deze 'face-to-face'-gesprekken. (Wijffels et al., 1992) onderzoeken dezelfde hypothese in een experiment, met mondelinge interviews per telefoon, en zij concluderen dat voorbeeldantwoorden wel degelijk sturend werken in deze telefonische gesprekken.

6.8 Factoriële ontwerpen

Tot nog toe hebben we het gehad over experimentele onderzoeksontwerpen waarbij één onafhankelijke variabele gemanipuleerd wordt. Veel onderzoekers zijn echter (ook) geïnteresseerd in de effecten van de gelijktijdige manipulatie van meerdere onafhankelijke variabelen. Ontwerpen waarin meerdere factoren gelijktijdig variëren noemen we factoriële ontwerpen. We kwamen deze al tegen bij het voormeting-nameting-controlegroep-ontwerp (§6.5 waar zowel de tijd als de behandeling varieert).

Voorbeeld 6.5: (Drake and Ben El Heni, 2003) onderzochten de waarneming van muzikale structuur. Die waarneming kan indirect gemeten worden door de luisteraar te vragen om mee te tikken met de muziek. Als een luisteraar de muzikale structuur niet begrijpt of herkent, is hij geneigd mee te tikken met iedere tel (analytisch luisteren). Naarmate een luisteraar de muzikale structuur beter begrijpt en herkent, is hij meer geneigd om mee te tikken met hogere nivo's (synthetisch of voorspellend luisteren): hij tikt dan niet bij iedere tel, maar bv $1 \times$ per maat of per muzikale frase. De tijdsafstand ('inter-onset-interval', IOI) tussen de tikken vormt aldus een indicatie van de waargenomen muzikale structuur. Aan het onderzoek van deden twee groepen luisteraars mee, in Frankrijk en in Tunesië¹. Alle proefpersonen luisterden naar 12 muziekstukken, waarvan 6 afkomstig uit de Franse en 6 uit de Tunesische muzikale culturen (de muziekstukken waren verschillend qua maatsoorten, tempi, en mate van bekendheid). De resultaten zijn grafisch samengevat in Figuur 6.1.

Uit deze resultaten blijkt dat er géén verschil optreedt tussen de groepen (Franse vs Tunesische luisteraars; de twee groepen hebben gemiddeld dezelfde IOI), en dat er ook géén verschil optreedt tussen de muzieksoorten (Franse vs Tunesische muziekstukken; de twee muzieksoorten resulteren in gemiddeld dezelfde IOI). Hebben de twee onafhankelijke variabelen dan geen enkel effect? Toch wel! De Franse luisteraars bleken langere IOI's tussen tikken te produceren als ze naar Franse muziek luisterden, terwijl de Tunesische luisteraars daarentegen langere IOI's produceerden als ze naar Tunesische muziek luisterden. Alle luisteraars blijken dus langere IOI's te produceren als ze luisteren naar een muzieksoort die voor hen bekend is, en kortere IOI's als ze luisteren naar een onbekende muzieksoort.

¹Merk op dat proefpersonen niet aselekt zijn toegewezen aan een van deze groepen, en dat dit dus strikt genomen een quasi-experimenteel onderzoek is (zie Hoofdstuk 1).




Figure 6.1: Figuur 6.1: Gemiddelde tijdsafstand tussen tikken (IOI, in ms) voor twee groepen luisteraars en twee muzieksoorten (ontleend aan Drake & Ben El Heni, 2003, Fig.2).

concluderen dat de luisteraars beter in staat zijn om muzikale structuur te herkennen en te begrijpen in muziek van hun eigen muzikale cultuur dan in die van een andere cultuur. Dit patroon van resultaten is een klassiek kruislings interactie-effect, waarbij het effect van de ene onafhankelijke variabele precies tegengesteld is in de verschillende condities van de andere onafhankelijke variabele.

Als er een interactie-effect blijkt op te treden, dan is het zinloos om een eventueel hoofdeffect te interpreteren. Dat werd al geïllustreerd in Voorbeeld 6.5 hierboven: we kunnen niet concluderen dat er géén verschil is tussen de muzieksoorten. Maar de grootte (en richting) van het verschil is afhankelijk van de andere onafhankelijke variabele(n), nl. van de groep/nationaliteit van de luisteraars. Veel onderzoek is er juist op gericht om interactie-effecten aan te tonen; niet de hoofdeffecten maar hun interactie vormt het onderwerp van onderzoek, net als in het bovenstaande voorbeeld 6.5.

Een factorieel onderzoeksontwerp is lastig om schematisch weer te geven, omdat er meerdere onafhankelijke variabelen (met elk weer meerdere niveaus) in voorkomen. We zouden deze schematisch kunnen representeren door de manipulatie, die we voorheen aangeduid hebben met een X , te indiceren. De eerste index (subscript) geeft dan het niveau aan voor de eerste onafhankelijke variabele of factor, en de tweede index geeft het niveau aan van de tweede factor. Het ontwerp van voorbeeld 6.5 wordt dan als volgt schematisch weergegeven:

| | | |
|---|---------------|----|
| R | $X_{\{1,1\}}$ | 01 |
| R | $X_{\{1,2\}}$ | 02 |
| R | $X_{\{2,1\}}$ | 03 |
| R | $X_{\{2,2\}}$ | 04 |

Het is vaak verleidelijk om meerdere factoren te combineren in één groot factorieel onderzoeksontwerp, zodat we kunnen onderzoeken hoe al die factoren op elkaar inwerken (interageren). Toch is het verstandig om dat *niet* te doen, en om het aantal factoren beperkt te houden. Ten eerste, zoals we later zullen zien, moet het aantal observaties ongeveer gelijke tred houden met het aantal verschillende combinaties van factoren. Als je meer combinaties van factoren toevoegt, dan zijn er daardoor ook veel meer proefpersonen nodig (of andere eenheden). Ten tweede is het moeilijker te garanderen dat alle combinaties van factoren perfect vergelijkbaar zijn (Shadish et al., 2002, p.266): zijn Tunesische deelnemers die in Tunesië luisteren naar Tunesische muziek wel goed vergelijkbaar met Franse deelnemers die in Frankrijk luisteren naar Franse muziek? De vergelijkbaarheid van combinaties wordt lastiger, naarmate er meer combinaties van factoren in het onderzoek voorkomen. Ten derde zijn interacties notoir moeilijk te interpreteren, en dat wordt eveneens lastiger naarmate de

interacties complexer zijn, en meer factoren omvatten. Om al deze redenen is het beter om effecten van meerdere factoren te bestuderen in verschillende afzonderlijke onderzoeken (Quené, 2010).

We zullen later terugkomen op de analyse en interpretatie van gegevens uit factoriële onderzoeksontwerpen (Hoofdstuk ??). Voorlopig concentreren we ons op ontwerpen met slechts één onafhankelijke variabele.

6.9 Afhankelijke- en onafhankelijke-groepen-ontwerp

In het begin van dit hoofdstuk hebben we gesproken over de manipulatie van een onafhankelijke variabele tussen danwel binnen proefpersonen (). In de meeste van de voorafgaande onderzoeksontwerpen werd voor elke waarde van de onafhankelijke variabele(n) een afzonderlijke groep geformeerd; we noemen dat een onafhankelijke-groepen-ontwerp. De onafhankelijke variabele varieert tussen proefpersonen.

Sommige onafhankelijke variabelen kunnen echter ook gevarieerd worden binnen proefpersonen. We meten dan herhaaldelijk bij (binnen) dezelfde proefpersonen uit dezelfde groep, onder verschillende condities van de onafhankelijke variabele. In het onderstaande voorbeeld wordt de onafhankelijke variabele ‘taal’ (moedertaal of vreemde taal) gevarieerd binnen proefpersonen. We noemen dat een afhankelijke-groepen-ontwerp.

Voorbeeld 6.6: (De Jong et al., 2015) onderzochten de vloeiendheid van de spraak van proefpersonen in hun moedertaal (Turks) en in een vreemde taal (Nederlands). De proefpersonen voerden eerst een aantal spreektaken uit in hun moedertaal, en enkele weken later in het Nederlands. Eén van de afhankelijke variabelen was het aantal gevulde pauzes (bijv. *eh*, *ehm*) per seconde spraak: hoe meer pauzes, hoe minder vloeiend. De sprekers bleken meer pauzes te produceren (d.w.z. minder vloeiend te spreken) in de vreemde taal dan in hun moedertaal, zoals ook te verwachten is. Eén van de doelen van het onderzoek was overigens om te onderzoeken in hoeverre individuele verschillen in vloeiendheid in de vreemde taal te herleiden zijn naar individuele verschillen in vloeiendheid in de moedertaal. De samenhang tussen de twee metingen bleek hoog (correlatie $r = 0.73$, meer hierover in Hoofdstuk 11. Sprekers die veel pauzeren in de vreemde taal, doen dat vaak ook in hun moedertaal. De onderzoekers bepleiten dat met deze correlatie rekening gehouden moet worden bij het aanleren en toetsen van spreekvaardigheid in een vreemde taal.

Het hier beschreven onderzoeksontwerp ziet er in schema als volgt uit:

X1 01 X2 02

Ondanks de vele mogelijke bedreigingen van de interne validiteit (o.a. geschiedenis, rijping, sturende werking van de voormeting) is zo'n ontwerp in veel gevallen nuttig. In het bovenstaande voorbeeld is het essentieel dat *dezelfde* proefpersonen spreektaken uitvoeren in beide talen (condities) — de onderzoeksvragen zijn niet met een andere methode te beantwoorden.

6.10 Onderzoek ontwerpen

Een onderzoeker die een onderzoek wil uitvoeren, moet bepalen op welke wijze hij zijn gegevens gaat verzamelen: hij moet een keuze maken voor een bepaald onderzoeksontwerp. Soms kan een standaard-ontwerp gekozen worden, zoals een van de hierboven behandelde ontwerpen. In andere gevallen zal de onderzoeker zelf het ontwerp moeten opstellen. Het ontwerp moet uiteraard goed aansluiten bij de onderzoeksvraag (Levin, 1999), en het moet zoveel mogelijk storende variabelen uitsluiten die de validiteit zouden kunnen bedreigen. Het ontwerpen van onderzoek is een vak dat onderzoekers al doende leren. In het onderstaande voorbeeld proberen we weer te geven welke redenering en argumenten een rol spelen bij de ontwikkeling van een onderzoeksontwerp.

Stel je voor dat we willen onderzoeken of de vorm waarin toetsvragen gesteld worden, als open vs. gesloten vragen, van invloed is op de scores op die toets. In een eenvoudig ontwerp nemen we eerst een toets af met open vragen, en daarna een vergelijkbare toets met gesloten vragen, bij dezelfde respondenten. Als de samenhang tussen de scores hoog genoeg is, dan wordt geconcludeerd dat beide toetsen hetzelfde meten, en dat de prestatie niet wezenlijk beïnvloed wordt door de vorm waarin de vragen worden gesteld. Schematisch is dit ontwerp als volgt weer te geven:

Open 01 Gesloten 02

Dit onderzoeksontwerp heeft echter diverse zwakke punten. Ten eerste is het onverstandig om eerst alle toetsen met open vragen op het eerste tijdstip af te nemen, en vervolgens alle toetsen met gesloten vragen op het tweede tijdstip. De prestaties op de tweede toets worden immers altijd beïnvloed door volgorde-effecten (transfer): de respondenten hebben iets onthouden en dus geleerd van de eerste meting. Deze transfer werkt nu altijd dezelfde kant op, met daardoor (vermoedelijk) relatief hogere prestaties bij de toets met gesloten vragen (op het tweede tijdstip). Het is dus beter om de toetsen met open en gesloten vragen at random te verdelen over het eerste en tweede tijdstip van afname.

Ten tweede kunnen alle respondenten beïnvloed zijn door eventuele gebeurtenissen tussen de twee tijdstippen (geschiedenis), bijvoorbeeld door een relevante instructie over het onderwerp van de toets. Omdat er geen controle-groep is, kan met zo'n effect geen rekening worden gehouden.

Een derde probleem is gelegen in de wijze waarop van bevindingen naar conclusie wordt geredeneerd. Zoals gezegd, houdt die redenering in dat, als de samenhang tussen de scores hoog genoeg is, dan beide toetsen hetzelfde meten. Als je daarover nadenkt, dan ben je het misschien met ons eens dat dat een vreemde redenering is. De onderzoeksvraag is eigenlijk, of de samenhang in prestaties op verschillende toetsen met verschillende vraagvormen even hoog is als de samenhang in prestaties op verschillende toetsen met dezelfde vraagvormen, waarvan we immers aannemen dat die hetzelfde meten. Daarmee hebben we in feite een controle-groep gedefinieerd, nl. respondenten die op beide tijdstippen toetsen maken met dezelfde vraagvorm. Voor alle zekerheid voegen we niet één maar twee controle-groepen toe, met open resp. gesloten toetsvragen op beide tijdstippen.

We hebben het ontwerp zo in tenminste twee opzichten verbeterd: (1) de toetsen zijn gerandomiseerd over de opname-tijdstippen, en (2) er zijn relevante controle-groepen toegevoegd. Schematisch ziet het onderzoeksontwerp er nu als volgt uit:

| | | | | |
|-----------------|----------|----|----------|----|
| Exp. groep 1 | Open | 01 | Gesloten | 02 |
| Exp. groep 2 | Gesloten | 03 | Open | 04 |
| Controlegroep 1 | Open | 05 | Open | 05 |
| Controlegroep 2 | Gesloten | 07 | Gesloten | 06 |

Voor alle vier de groepen kan nu de samenhang tussen de prestaties op het eerste en tweede tijdstip bepaald worden. Vervolgens kunnen we deze samenhang-resultaten uit de vier groepen vergelijken, en daarmee de onderzoeksvraag beantwoorden. Dit voorbeeld laat goed zien dat de conclusies die je uit de onderzoeksresultaten kunt trekken, direct afhankelijk zijn van het gekozen ontwerp (Levin, 1999). In het eerste ontwerp leidt een lage gevonden samenhang tot de conclusie dat de twee onderzochte toetsvormen *niet* een beroep doen op dezelfde intellectuele vaardigheden bij de respondenten. In het tweede ontwerp hoeft dezelfde lage samenhang in de derde groep (experimentele groep 1) echter niet tot dezelfde uitkomst te leiden! De conclusie hangt immers mede af van de mate van samenhang gevonden in de andere groepen.

6.11 Tenslotte

Ondanks alle beschikbare boeken, handleidingen, websites, en ander instructiemateriaal komen wij nog te vaak onderzoek tegen waar methodologisch iets mis is in de onderzoeksvragen, operationalisatie, onderzoeksopzet,

steekproeftrekking, en/of dataverwerking. Die problemen veroorzaken niet alleen een verspilling van tijd, geld en energie, maar ze resulteren ook in kennis die minder betrouwbaar, valide en robuust is dan mogelijk. De onderstaande ‘checklist’ voor goed onderzoek (deels ontleend aan <https://www.linkedin.com/groups/4292855/4292855-6093149378770464768>) kan veel ellende in latere stadia van een onderzoek voorkomen.

1. Denk goed na over je onderzoeksvragen, en formuleer ze helemaal uit. Als de vragen niet helder geformuleerd zijn, of als er veel deelvragen zijn, denk dan verder na.
2. Prioriteer de onderzoeksvragen. Dit helpt bij het maken van keuzes in onderzoeksontwerp, steekproeftrekking, operationalisatie, e.d.
3. Denk goed na over het ontwerp van het onderzoek. Volgens de overlevering levert ieder uur nadenken over je onderzoeksontwerp een toekomstige besparing van ongeveer 10 uren tijdens de data-analyse en interpretatie. Anders gezegd: een uur minder nadenken over je ontwerp kost je later 10 uur extra werk.
4. Bedenk ook alternatieve onderzoeksontwerpen, en denk na over de voordelen en nadelen van de diverse mogelijke ontwerpen.
5. Stel je de toekomst voor: je hebt het onderzoek uitgevoerd, de gegevens zijn geanalyseerd, en je hebt het verslag of de scriptie of het artikel geschreven. Welke boodschap wil je overbrengen op de lezers van dat verslag? Hoe draagt het onderzoeksontwerp bij aan die boodschap? Wat zou je kunnen veranderen in je ontwerp om die boodschap nog duidelijker te maken? Bedenk waar je naar toe wilt, niet alleen waar je nu staat.
6. Schrijf een onderzoeksplan, waarin je de verschillende methodologische aspecten beschrijft. Beargumenteer en expliciteer je onderzoeksvragen, onderzoeksontwerp, steekproef, meetmethode, data-verzameling, meetinstrumenten (bv. vragenlijst, software), andere benodigdheden (bv. laboratorium, vervoer), en statistische verwerking. Onderdelen van dit onderzoeksplan zijn later herbruikbaar in het onderzoeksverslag. Maak daarbij ook een tijdsplanning: wanneer zullen welke mijlpalen zijn bereikt?
7. Schrijf uit hoe je de verzamelde gegevens statistisch wilt analyseren, nog voordat je begint met de eigenlijke data-verzameling. Wees daarbij weer zo expliciet mogelijk (in een script, stappenplan, o.i.d.). Maak een mini-dataverzameling van een redelijk aantal fictieve observaties of werkelijke observaties uit de pilot-fase van het onderzoek, en analyseer deze gegevens alsof het de definitieve data-verzameling betreft. Maak eventueel aanpassingen in je onderzoeksplan.

8. Als je eenmaal doende bent gegevens te verzamelen, maak dan *geen* wijzigingen meer in het onderzoeksplan. Houd je aan dat plan en aan de bijbehorende tijdsplanning. Analyseer de gegevens op de wijze zoals vastgelegd in het (aangepaste) onderzoeksplan. Bespreek eventuele problemen die tijdens het onderzoek optraden wel in het onderzoeksverslag. Als er grote problemen optreden, breek dan het onderzoek af, en overweeg een verbeterde versie van je onderzoek.

Chapter 7

Steekproeven

Voor de generalisatie van de uitkomsten van een onderzoek naar de doelgroep of de steekproef, is de kwaliteit van de steekproef bepalend. Is de steekproef een adequate afspiegeling van de populatie? Om een extreem voorbeeld te geven: als een steekproef bestaat uit meisjes in de groep 8 van het basisonderwijs, dan kunnen de resultaten niet goed gegeneraliseerd worden naar de populatie van alle basisschoolleerlingen, want deze steekproef vormt geen goede afspiegeling van de populatie basisschoolleerlingen (die immers bestaat uit jongens en meisjes van alle groepen).

Afhankelijk van de methode die de onderzoekers gebruiken om de proefpersonen te selecteren, kunnen er vele soorten steekproeven onderscheiden worden. In dit hoofdstuk maken we een grove indeling in: (1) gelegenheidssteekproeven, (2) systematisch getrokken steekproeven, en (3) aselekt of willekeurig ('at random') getrokken steekproeven. Voor een verdere verdieping in de wijze waarop steekproeven getrokken kunnen worden en de problemen die daarbij een rol spelen verwijzen we naar standaardwerken hierover (Cochran, 1977; Thompson, 2012).

7.1 Gelegenheidssteekproeven

In veel sociaalwetenschappelijk onderzoek wordt gewerkt met steekproeven die zich nu eenmaal aandienen, zogenaamde *gelegenheidssteekproeven*. De onderzoeker voert het experiment uit met personen die hem min of meer toevallig ter beschikking staan. Voor sommige onderzoeken wordt gebruik gemaakt van al dan niet betaalde vrijwilligers. In andere onderzoeken worden studenten ingezet, die in het kader van hun studie verplicht zijn een aantal uren als proefpersoon aan onderzoek mee te werken, of soms moeten de studenten van een collega van de onderzoeker deelnemen aan het onderzoek. Een dergelijke steekproef is

niet zonder gevaren. De onderzoeker heeft de mate van generaliseerbaarheid naar de populatie op geen enkele manier meer in de hand. Natuurlijk heeft de onderzoeker wel een populatie op het oog, en zal hij proefpersonen uit het onderzoek weren die geen deel uit maken van de beoogde populatie (zoals niet-moedertaal-sprekers), maar de onderzoeker kan geen uitspraken doen over de representativiteit van de steekproef.

Met name in de psychologie heeft deze wijze van gelegenheidssteekproeftrekking ('convenience sampling') aanleiding gegeven tot verhitte discussies. Uit een telling bleek bijvoorbeeld dat 67% van de steekproeven uit gepubliceerde Amerikaanse psychologische studies uitsluitend bestond uit bachelor-studenten uit cursussen Psychologie aan Amerikaanse universiteiten (Henrich et al., 2010). Dergelijke steekproeven zijn natuurlijk verre van representatief. Gevolg daarvan is dat de op deze gegevens gebaseerde theorieën slechts een beperkte geldigheid hebben: de theorieën zouden vooral gelden voor het type personen (westers, jong, hoog opgeleid, blank) dat ook in de steekproeven sterk vertegenwoordigd is (Henrich et al., 2010). Ook in taalwetenschappelijk onderzoek is de steekproef van proefpersonen meestal een gelegenheidssteekproef. Kinderen die deelnemen als proefpersoon hebben vaak hoogopgeleide ouders (niet zelden zelf taalkundig geschoold, dus vermoedelijk bovengemiddeld verbaal begaafd), en volwassen proefpersonen zijn vaak studenten uit de omgeving van de onderzoekers, en dus ook bovengemiddeld hoog opgeleid en verbaal begaafd.

Ondanks de steekhoudende bezwaren die tegen dit type steekproef naar voren gebracht worden, dwingen de praktische omstandigheden vaak tot het gebruik van een zich aandienende gelegenheidssteekproef. Wij bevelen dan aan om na te gaan in hoeverre deze gelegenheidssteekproef zich onderscheidt van de populatie waarover de onderzoeker wil generaliseren. Tot slot van deze bespreking van zich aandienende steekproeven een voorbeeld over de gevaren van dit type steekproef.

Voorbeeld 7.1: Enige tijd geleden was er op televisie een wedstrijd te zien over wie van een negental kandidaten het beste kon zingen. De kijkers mochten hun voorkeur telefonisch kenbaar maken. Voor alle negen kandidaten was een aparte telefoonlijn geopend. Voor elke beller kreeg een kandidaat één punt. Degene die de meeste punten binnen een bepaalde tijdlimiet verzameld had was de winnaar. De reactie van het publiek was overweldigend: in grote delen van Nederland was het telefoonnet volledig overbezet. Al snel bleek één van de kandidaten een flinke voorsprong te hebben. In de loop van de avond werd deze voorsprong echter steeds kleiner. Uiteindelijk scheelde het nog maar enkele bellers met nummer twee. Opvallend was overigens dat naarmate de avond vorderde de verschillen tussen de deelnemers (relatief) steeds kleiner werden.

We kunnen deze stemprocedure beschouwen als een trekking van een steekproef van bellers c.q. stemmers. Deze steekproef is echter verre van representatief. Als veel kiezers willen stemmen op één kandidaat, dan zal de telefoonlijn voor die kandidaat overbezet raken. Dus: de zangers die veel bellers trekken, zullen relatief minder stemmen krijgen dan zangers die weinig bellers trekken, omdat de telefoonlijnen van de laatsten niet overbezet zullen zijn. Juist bij de populairste kandidaten is de kans het grootst dat een kiezer zijn stem *niet* kan laten gelden. In werkelijkheid zal er dus een veel groter verschil zijn in aantal stemmen per kandidaat, dan de organisator gemeten heeft. De organisator heeft deze systematische vertekening (bias) van de resultaten helaas zelf veroorzaakt, door voor elk van de negen kandidaten een eigen telefoonlijn te openen. De gegevens hadden veel representatiever kunnen zijn, als de organisator negen telefoonlijnen had geopend, met één gemeenschappelijk toegangsnummer. De steekproef van bellers die hun stem kunnen uitbrengen is dan representatief voor de populatie van alle bellers, en dat was nu niet het geval.

7.2 Systematische steekproeven

Wanneer de elementen in de *steekproefruimte* (d.i. de verzameling van mogelijke elementen in een steekproef) op de een of andere manier systematisch geordend zijn, dan kan met behulp van een *systematische trekkingsprocedure* van steekproefelementen een redelijk representatieve steekproef verkregen worden. Een ordening kan zijn bijvoorbeeld een namenlijst.

Voorbeeld 7.2: Laten we even aannemen dat we een onderzoek willen doen naar de taalvaardigheid van derdeklassers in het voortgezet onderwijs. De gehele populatie van derdeklassers is echter veel te groot om van alle derdeklassers de taalvaardigheid te meten (lezen, schrijven, spreken, en luisteren). In de derde klas zitten namelijk ongeveer 200.000 leerlingen. Er moet dus een steekproef genomen worden. Op het Ministerie van Onderwijs, Cultuur en Wetenschappen is een registratiesysteem beschikbaar waarin een lijst met de namen van alle scholen met derde klassen is opgenomen. Een voor de hand liggende werkwijze is nu deze lijst te nemen en elke 100ste school van die lijst in de steekproef op te nemen. Deze werkwijze resulteert vermoedelijk in een tamelijk representatieve steekproef.

Twee factoren kunnen echter roet in het eten gooien bij zo'n systematische steekproef: ten eerste de *responsiegraad*. Als een aanzienlijk deel van de

aangeschreven scholen geen medewerking verleent, dan hebben we in feite te maken met zelf-selectie (zie §5.4 punt 5) en dus met een zichzelf aandienende gelegenheidssteekproef (zie §7.1). Dat is een ongewenste situatie, want de scholen die wel meewerken hebben vermoedelijk een grotere ‘plichtsgetrouwheid’ dan de weigerende scholen of dan de gemiddelde school. Bovendien kunnen de leerlingen op de responderende en niet-responderende scholen van elkaar verschillen (zie §5.4 punt 5). De uiteindelijke steekproef is dan misschien niet meer representatief voor de populatie van alle derdeklassers. Het gevolg daarvan is weer dat de gemeten resultaten slecht generaliseerbaar zijn naar andere derdeklassers van andere scholen.

De tweede factor die de representativiteit van een systematische steekproef kan beïnvloeden is de *storende trendwerking*. Er is sprake van een storende trendwerking wanneer populatie-elementen met een bepaald relevant kenmerk meer kans hebben in de steekproef terecht te komen dan populatie-elementen die dit kenmerk niet hebben. In ons voorbeeld van de meting van de taalvaardigheid van derdeklassers hebben we met de storende trendwerking te maken. Niet alle leerlingen hebben namelijk een gelijke kans om in de steekproef te komen. Immers, elke individuele *school* (niet: leerling) heeft dezelfde kans als elke andere school om in de steekproef terecht te komen. Het gevolg is dat er relatief meer derdeklassers in de steekproef zullen komen van kleine scholen met relatief weinig leerlingen, en omgekeerd relatief minder derdeklassers van grote scholen met relatief veel leerlingen. Derdeklassers van grote scholen zijn ondervertegenwoordigd. Is dat erg? Misschien wel, want de taalvaardigheid (afhankelijke variabele) wordt deels beïnvloed door de vorm van onderwijs, en die onderwijsvorm wordt weer beïnvloed door de grootte van de school. De hierboven beschreven steekproef is dus niet representatief voor de populatie van derdeklassers. Wederom is het gevolg dat de gemeten resultaten slecht generaliseerbaar zijn naar andere derdeklassers van andere scholen.

7.3 Aselecte steekproeven

De hierboven beschreven storende trendwerking kunnen we voorkomen door random of *aselecte steekproeftrekking*. Aselecte steekproeftrekking kan op diverse manieren gebeuren, waarvan we er hier drie bespreken.

De eerste vorm is *simple random sampling*: hierbij krijgen alle elementen van de populatie een gelijke kans om getrokken te worden. Dit kan bijvoorbeeld gerealiseerd worden door alle elementen van een *random* nummer te voorzien en dan, afhankelijk van de gewenste steekproefgrootte, steeds het n -de element te selecteren. Voor de selectie van getallen staan de onderzoeker tabellen met toevalsgetallen ter beschikking (zie Appendix A). Ook rekenmachines, computers, spreadsheet-programma's e.d. kunnen random getallen genereren (zie secties hieronder). Het verdient aanbeveling om zulke random getallen te gebruiken, want een door mensen geconstrueerde “random” volgorde is niet werkelijk “ran-

dom”. Een voorwaarde voor de toepassing van deze methode is echter wel dat de elementen van de populatie (steekproefruimte) vooraf geregistreerd zijn (of worden), zodat ze op enigerlei wijze van een nummer voorzien kunnen worden.

Voorbeeld 7.3: We willen een steekproef trekken van $n = 400$ basisscholen. Dit is ongeveer 4% van de populatie van basisscholen. We vragen daarom bij het Ministerie van Onderwijs, Cultuur en Wetenschappen een lijst met alle 9000 basisscholen op; deze lijst vormt de steekproefruimte. Vervolgens voorzien we alle basisscholen van een volgnummer $(1, 2, 3, \dots, 9000)$. Tenslotte selecteren we alle basisscholen waarvan de laatste twee cijfers *toevallig* 36 of 43 of 59 of 70 zijn (zie Appendix A, eerste kolom, laatste twee cijfers). Met deze procedure selecteren we volgens het toeval 4 van de 100 mogelijke laatste-twee-cijfer-combinaties, ofwel 4% van de scholen.

De tweede vorm van aselecte steekproeftrekking is *stratified random sampling*. Daarvan is sprake als we van elk populatie-element de waarde van een kenmerk weten (bv. religieuze denominatie), en als we zorgen dat in de steekproef de elementen evenredig verdeeld zijn volgens dit kenmerk. We verdelen de steekproef daarvoor in zogenaamde ‘strata’ of lagen (Lat. *stratum*, ‘bedekking, laag’, verwant aan Ned. *straat*, ‘verharde weg’). Terug naar de basisschool om het een en ander te verhelderen. Om welke reden dan ook zijn we er nu in geïnteresseerd de steekproef (nog steeds 4% van de populatie van basisscholen) zo te maken dat openbare, katholieke en protestante scholen in gelijke mate vertegenwoordigd zijn. We stellen daarom drie lijsten op: voor alle drie de schooltype een aparte lijst. Binnen iedere lijst gaan we net zo te werk als bij simple random sampling. Uiteindelijk worden de drie deel-steekproeven van de drie strata gecombineerd.

Met *quota sampling* gaan we nog een stapje verder dan bij ‘stratified random sampling’: we verdisconteren nu ook het feit dat we weten wat de verdeling is van een bepaald kenmerk (bv. denominatie) in de populatie. Uit de lijst met basisscholen zou hebben kunnen blijken dat 35% van de scholen openbaar is, 31% katholiek, 31% protestant en dat 3% een andere signatuur heeft. We trekken uit de steekproefruimte nu meerdere aselecte ‘stratified’ steekproeven, en wel zo dat de verhouding van scholen in de strata een juiste afspiegeling vormt van de verhoudingen van dit kenmerk in de steekproefruimte (35 : 31 : 31 : 3).

7.3.1 SPSS

Voor het aanmaken van een kolom met random getallen:

Transform > Compute...

Selecteer een bestaande variabele (sleep naar Variable(s) paneel) of geef de naam voor een nieuwe variabele. Uit het paneel “Function Group”, kies “Random Numbers” en daarna `RV.UNIFORM`. Deze functie kiest aselekt (**random**) waarden (**values**) uit een vlakke (**uniforme**) kansverdeling, d.w.z. dat elk getal tussen de ondergrens en bovengrens een gelijke kans heeft om getrokken te worden. Kies als ondergrens 0 en als bovengrens 9999, of andere grenzen naar behoefte. Bevestig met OK.

Dit resulteert in een (nieuwe, of overschreven bestaande) kolom met random getallen.

Als je random getallen wilt genereren volgens een normale kansverdeling (zie Hoofdstuk 10), gebruik dan de functie `RV.NORMAL(mean,stdev)`.

We kunnen een eigen beginwaarde meegeven aan de “random number generator”, om zo reproduceerbare analyses te kunnen maken:

Transform > Random Number Generators...

Vink in het paneel “Active Generator Initialization” de optie **Set Starting Point** aan, en vul een eigen beginwaarde in, bijvoorbeeld je lievelingsgetal. Bevestig met OK.

Je kunt deze random getallen gebruiken om op aselekte wijze eenheden (bijv. proefpersonen) te kiezen voor een steekproef, maar uiteraard ook om op aselekte wijze de geselecteerde eenheden toe te wijzen aan condities, enzovoort.

7.3.2 R

In R kunnen we random getallen genereren met de functie `runif`. Deze functie kiest aselekt (**random**) waarden uit een vlakke (**uniforme**) kansverdeling, d.w.z. dat elk getal tussen de ondergrens en bovengrens een gelijke kans heeft om getrokken te worden. De standaard grenzen zijn (0,1). De waarden kunnen we afronden tot gehele getallen, zoals gedaan is voor Appendix A.

Als je random getallen wilt genereren volgens een normale kansverdeling (zie Hoofdstuk 10), gebruik dan de functie `rnorm(n,mean,sd)`.

Met de opdracht `set.seed` geven we een eigen beginwaarde mee aan de “random number generator”, om zo reproduceerbare analyses (en demonstraties) te kunnen maken.

```
set.seed(20200912) # reproduceerbaar voorbeeld (bijv datum als getal)
round ( runif( n=5, min=0, max=9999 ) )
```

```
## [1] 8193 7482 4206 1684 5653
```


Je kunt deze random getallen gebruiken om op aselechte wijze eenheden (bijv. proefpersonen) te kiezen voor een steekproef, maar uiteraard ook om op aselechte wijze de geselecteerde eenheden toe te wijzen aan condities, enzovoort.

7.4 Steekproefgrootte

Als je verschillende onderzoeksartikelen leest, dan is één van de eerste zaken die opvalt de enorme variatie in aantallen respondenten. In sommige onderzoeken worden enkele duizenden proefpersonen betrokken en in andere slechts enkele tientallen of soms nog minder. We zullen hier twee aspecten bespreken die van invloed zijn op de vereiste grootte van de steekproef: de homogeniteit van de populatie, en de aard van de steekproeftrekking. In volgende hoofdstukken zullen we nog twee andere aspecten bespreken die eveneens van invloed zijn op de gewenste steekproefgrootte, nl. de gewenste precisie (effectgrootte, §??) en de gewenste kans om een effect aan te tonen als dat in de populatie ook daadwerkelijk aanwezig is (power, §??).

Voorbeeld 7.4: Wanneer auto's getest worden (in een tijdschrift of op televisie), dan wordt van een type auto slechts één exemplaar getest. De resultaten van dit testexemplaar worden zonder voorbehoud gegeneraliseerd naar alle auto's van hetzelfde type en merk. Dit is mogelijk omdat de populatie auto's waarnaar gegeneraliseerd wordt bijzonder homogeen is: de fabrikant streeft er immers naar om de verschillende exemplaren zo gelijk mogelijk op de markt te brengen.

De vereiste steekproefgrootte hangt ten eerste af van de homogeniteit van de populatie. Als een populatie *homogeen* is, zoals de auto's in voorbeeld 7.4 hierboven, dan kunnen we met een kleine steekproef volstaan. Anders is het wanneer we bijvoorbeeld de conversatiepatronen van kleuters willen analyseren. In de conversatiepatronen van kleuters treffen we grote verschillen aan; er is een zeer grote variatie in conversatiepatronen. (Sommige kinderen praten voluit, en andere zwijgen vooral. Bovendien zijn er grote individuele verschillen in taalontwikkeling tussen kinderen.) Om een goed beeld te krijgen van de taalontwikkeling van kleuters, hebben we daarom een veel grotere steekproef nodig. De grootte van de benodigde steekproef neemt dus toe naarmate de populatie waarna gegeneraliseerd moet worden minder homogeen (heterogener) is.

Ten tweede hangt de vereiste steekproefgrootte ook af van de aard van de steekproef. Als er in een populatie duidelijke strata aanwezig zijn, maar we

passen – om welke reden dan ook – geen ‘stratified’ of ‘quota sampling’ toe, dan hebben we een grotere steekproef nodig dan wanneer we dit wel zouden doen. Immers, bij deze laatste twee methoden zorgt de onderzoeker zelf voor een gelijke dan wel evenredige vertegenwoordiging van strata in de steekproef, maar bij ‘simple random sampling’ wordt dat aan het toeval overgelaten. We doen dan dus een beroep op de “wet van de grote getallen” om te zorgen dat er voldoende elementen uit de verschillende strata in de steekproef terecht komen, om generalisatie van de resultaten naar die verschillende strata te rechtvaardigen. Uiteraard werkt die wet alleen bij een voldoende grote steekproef! Bij een kleine steekproef weten we allerm minst zeker dat de verschillende strata in voldoende mate in de steekproef vertegenwoordigd zijn.

Als we, om naar het basisschool-voorbeeld terug te keren, drie basisscholen zouden selecteren volgens ‘simple random sampling’, dan bestaat natuurlijk een kans dat dit precies één openbare, één katholieke en één protestante school oplevert in deze steekproef. Maar ook andere uitkomsten zijn zeer reëel, en zelfs meer waarschijnlijk. Bij ‘stratified’ en ‘quota sampling’ hebben we gegarandeerd van elke denominatie één element (school) in onze steekproef. Onze basis voor generalisatie is beter, en de externe validiteit is dus sterker.

Na al deze behartenswaardige aanbevelingen wordt het tijd om te bespreken hoe we onderzoeksgegevens goed kunnen beschrijven en analyseren om onze onderzoeksvragen te beantwoorden. Dat gebeurt in het volgende deel van dit boek.

Deel II: Beschrijvende statistiek

Chapter 8

Frequenties

8.1 Inleiding

Bij de analyse van gegevens wordt vaak een onderscheid gemaakt tussen kwalitatieve danwel kwantitatieve methoden. Bij de eerste methode worden waarnemingen (bijv. antwoorden in interviews) gerepresenteerd in woorden, en bij de tweede methode worden waarnemingen (bijv. spreekpauzes in interviews) gerepresenteerd in getallen. Naar onze mening bestaat het verschil tussen kwalitatieve en kwantitatieve methoden dus uit de aard van de representatie van de observaties, en daarmee uit de wijze van argumentatie op grond van die observaties. Soms is het ook mogelijk om dezelfde gegevens (bijv. interviews) zowel kwalitatief als kwantitatief te analyseren. De kwantitatieve methode heeft als grote voordelen dat de gegevens relatief eenvoudig samengevat kunnen worden (daarover gaat dit deel van de syllabus), en dat het relatief makkelijk is om zinvolle conclusies te trekken op basis van de observaties.

8.2 Frequenties

Kwantitatieve gegevens kunnen op allerlei manieren gerapporteerd worden. De eenvoudigste manier zou zijn om de ruwe gegevens te rapporteren, bij voorkeur gesorteerd naar de waarde van de geobserveerde variabele. Nadeel daarvan is dat een eventueel patroon in de observaties niet goed zichtbaar wordt.

Voorbeeld 8.1: Studenten ($N = 50$) in een eerstejaars cursus rapporteerden de volgende waarden voor hun schoenmaat, een variabele van het interval-meetniveau:

| hoofdklasse | onderklasse | aantal |
|-------------|-------------|--------|
| C | plos | 585999 |
| C | fric | 426097 |
| C | liq | 249275 |
| C | nas | 361742 |
| C | glide | 146344 |
| V | lang | 365887 |
| V | kort | 428832 |
| V | schwa | 341260 |
| V | diph | 61638 |
| V | rest | 1146 |

Eén van de studenten heeft geen antwoord opgegeven; dit ontbrekende antwoord is hier aangegeven als ??.

Tabel 8.2 geeft als tweede voorbeeld een frequentieverdeling van een continue variabele van *interval* meetniveau, nl. de al eerder genoemde schoenmaat van eerstejaars studenten (Voorbeeld 8.1).

Table 8.2: Frequentieverdeling van zelfgerapporteerde schoenmaten van $N = 50$ studenten in een eerstejaars cursus (zie Voorbeeld 8.1 hierboven).

| | | | | | | | | | | |
|------------|----|----|----|----|----|----|----|----|----|----|
| Schoenmaat | 36 | 37 | 38 | 39 | 40 | 41 | 42 | 43 | 44 | ?? |
| Aantal | 2 | 6 | 6 | 19 | 6 | 5 | 2 | 2 | 1 | 1 |

Als een numerieke variabele heel veel verschillende waarden kan aannemen, dan wordt de frequentieverdeling op deze manier toch groot en onoverzichtelijk. We voegen dan waarden in een bepaald interval bij elkaar, en maken daarna een frequentieverdeling over dat geringere aantal intervallen of klassen.

Voorbeeld 8.2: Toen Koningin Beatrix voor het laatst de Troonrede voorlas, op 18 september 2012, pauzeerde ze daarbij 305 \times . De frequentieverdeling van de duur van de pauze (gemeten in seconden) is weergegeven in Tabel 8.3.

Table 8.3: Frequentieverdeling van de duren van spreekpauzes (in seconden) in de Troonrede van 18 september 2012, voorgelezen door Koningin Beatrix ($N = 305$).

| Interval | Aantal |
|-----------|--------|
| 4.50–4.99 | 1 |
| 4.00–4.49 | 0 |
| 3.50–3.99 | 2 |
| 3.00–3.49 | 7 |
| 2.50–2.99 | 4 |
| 2.00–2.49 | 25 |
| 1.50–1.99 | 32 |
| 1.00–1.49 | 16 |
| 0.50–0.99 | 67 |
| 0.00–0.49 | 151 |

8.2.1 Intervallen

Voor een variabele van nominaal en ordinaal meetniveau gebruiken we doorgaans de oorspronkelijke categorieën om de frequentieverdeling te maken (zie

Tabel 8.1 (klankfreq)), al is het wel mogelijk om categorieën samen te voegen. Voor een variabele van interval- of ratio-meetniveau kan een onderzoeker zelf het aantal intervallen in de frequentieverdeling kiezen. Soms is dat niet nodig, bijvoorbeeld omdat de variabele een overzichtelijk aantal verschillende discrete waarden heeft (zie Tabel 8.2 (schoenmaat)). Maar soms sta je als onderzoeker voor de keuze hoeveel intervallen te onderscheiden, en hoe de grenzen van die intervallen te bepalen (zie Tabel 8.3). Daarbij gelden dan de volgende aanbevelingen (Ferguson and Takane, 1989, Ch.2):

- Zorg dat alle observaties (d.w.z. het gehele bereik) vallen binnen ruwweg 10 tot 20 intervallen.
- Zorg dat alle intervallen even breed zijn.
- Laat de ondergrens van het eerste of tweede interval samenvallen met de breedte van de intervallen (zie Tabel 8.3: ieder interval is 0.50 s breed, en de ondergrens van het tweede interval is ook 0.50).
- Orden de intervallen in een frequentieverdeling van beneden naar boven in toenemende volgorde (d.i. van boven naar beneden in afnemende volgorde, Eng. descending), zie Tabel 8.3).

Naarmate we de intervallen breder maken, verliezen we meer informatie over de precieze verdeling binnen elk interval.

8.2.2 SPSS

Analyze > Descriptive Statistics > Frequencies...

Selecteer variabele (sleep naar paneel "Variable(s)").

Vink aan: Display frequency tables.

Kies Format, kies: Order by: Descending values.

Bevestig met OK.

8.2.3 R

```
enq2011 <- read.table(
  file=url("http://www.hugoquene.nl/R/enq2011.txt"),
  header=TRUE )
table( enq2011$schoen, useNA="ifany" )
```


De uitvoer van bovenstaande `table` commando is weergegeven in Tabel 8.2. De code `NA` (Not Available) wordt in R gebruikt om ontbrekende gegevens aan te duiden.

```
table( cut( troon2012, breaks=seq(from=0,to=5,by=0.5) ) )
```

Ontleed deze opdracht van de binnenste haakjes naar buiten: (i) `seq`: maak een reeks (sequence) van 0 tot 5 (eenheden, hier: seconden) in stappen van 0.5 seconden, (ii) `cut`: hak de afhankelijke variabele `dur` op in intervallen op basis van deze reeks, (iii) `table`: maak een frequentieverdeling van deze intervallen.

De uitvoer van deze opdracht is weergegeven (in aangepaste vorm) in Tabel 8.3.

8.3 Staafdiagrammen

Een staafdiagram (Eng. ‘bar chart’) is de grafische weergave van de frequentieverdeling van een discrete, categorische variabele (van nominaal of ordinaal meetniveau). Een staafdiagram is opgebouwd uit rechthoeken. Alle rechthoeken zijn even breed, en de hoogte van de rechthoek correspondeert met de frequentie van die categorie. De oppervlakte van iedere rechthoek correspondeert dus ook met de frequentie van die categorie. In tegenstelling tot een histogram sluiten de rechthoeken *niet* op elkaar aan langs de horizontale as, om aan te geven dat we te maken hebben met discrete categorieën.

Een staafdiagram helpt ons om in één oogopslag de belangrijkste kenmerken te bepalen van de verdeling van een discrete variabele: de meest kenmerkende (meest voorkomende) waarde, en de spreiding over categorieën. Voor de klankfrequenties in het Nederlands (Figuur 8.1) zien we dat bij de medeklinkers de plosieven het meeste voorkomen, dat bij de klinkers de korte klinkers het meeste voorkomen, dat tweeklanken weinig gebruikt worden (zgn. diphthongs, de klinkers in *ei*, *ui*, *au*), en dat er meer medeklinkers dan klinkers gesproken worden.

Tip: Vermijd schaduwen en andere 3D-effecten in een staafdiagram! De breedte en hoogte van een rechthoek wordt daardoor minder goed leesbaar, en de zichtbare oppervlakte van een beschaduwde rechthoek of van een balk correspondeert niet meer goed met de frequentie.

8.4 Histogrammen

Een histogram is de grafische weergave van een frequentieverdeling van een continue, numerieke variabele (van interval- of ratio-meetniveau). Een histogram is opgebouwd uit rechthoeken. De breedte van elke rechthoek correspondeert met de intervalbreedte (een rechthoek kan ook 1 eenheid breed zijn) en de hoogte correspondeert met de frequentie van dat interval of van die waarde.




Figure 8.1: Staafdiagram van de frequentieverdeling van fonologische klasse van spraakklanken in het Corpus Gesproken Nederlands (C=consonant=medeklinker, V=vocaal=klinker).

De oppervlakte van iedere rechthoek correspondeert dus met de frequentie. In tegenstelling tot een staafdiagram sluiten de rechthoeken op elkaar aan langs de horizontale as.

Een histogram helpt ons om in één oogopslag de belangrijkste kenmerken te bepalen van de verdeling van een continue variabele: de meest kenmerkende (meest voorkomende) waarde, de mate van spreiding, het aantal pieken in de frequentieverdeling, de ligging van die pieken, en eventuele uitbijters (zie §9.4.2). Voor de pauzes in de Troonrede van 2012 (Figuur 8.2) zien we dat de meeste pauzes tussen 0.25 en 0.75 s duren (vermoedelijk zijn dat adempauzes), dat er twee pieken zijn in de verdeling (de tweede piek ligt bij 2 s), en dat er één extreem lange pauze is (met een duur van bijna 5 s).

Tip: Vermijd schaduwen en andere 3D-effecten in een histogram! De breedte en hoogte van een rechthoek wordt daardoor minder goed leesbaar, en de zichtbare oppervlakte van een beschaduwde rechthoek of van een balk correspondeert niet meer goed met de frequentie.

8.4.1 SPSS

Analyze > Descriptive Statistics > Frequencies...

Selecteer variabele (sleep naar paneel “Variable(s)").




Figure 8.2: Histogram van de dueren van spreekpauzes (in seconden) in de Troonrede van 18 september 2012, voorgelezen door Koningin Beatrix (N=305).

Kies Charts, kies daarna Chart type: Bar chart voor een staafdiagram of Chart type: Histogram voor een histogram (zie bovenstaande tekst voor het verschil tussen deze opties).

Bevestig met OK.

8.4.2 R

Een staafdiagram zoals Figuur 8.1 maak je in R met de volgende commando's:

```
# lees data
klankfreq <- read.table( file="data/klankfreq.txt", header=T )
# maak barplot van kolom `aantal` in dataset `klankfreq`
with( klankfreq, barplot( aantal, beside=T,
                          ylab="Aantal",
                          main="Klankfrequenties in het Nederlands (N=2968220)",
                          col=ifelse(klankfreq[,1]=="V","grey40","grey20") ) ) -> klankfreq_barplot
# maak labels langs onderste horizontale as
axis(side=1, at=klankfreq_barplot, labels=klankfreq$hoofdklasse)
axis(side=1, at=klankfreq_barplot, tick=F, line=1, labels=klankfreq$onderklasse )
# of eenvoudiger: with(klankfreq, barplot(aantal) ) # alle defaults
```

Een histogram zoals in Figuur 8.2 maak je in R met de volgende commando's:

```
# lees dataset
load(file="data/pauses6.Rda")
# haal daaruit pauzeduren (kolom 12) voor jaar 2012, in aparte dataset `troon2012`
troon2012 <- pauses6[ pauses6$jaar==2012, 12 ] # save col_12 as single vector
# maak histogram
hist( troon2012,
      breaks=seq(0, 5, by=0.25),
      col="grey80",
      xlab="Duur van pauze (s)", ylab="Aantal",
      main="Troonrede 2012 (N=305 pauzes)" ) -> troonrede2012pauzes_hist
```

Chapter 9

Centrum en spreiding

9.1 Inleiding

In het vorige hoofdstuk hebben we geleerd om observaties te tellen en te classificeren. Daarmee kunnen we de observaties van een variabele samenvatten, bijvoorbeeld in een tabel, een frequentieverdeling, of in een histogram. Vaak kunnen we de observaties nog verder samenvatten, in kenmerken die aangeven op welke wijze de observaties verdeeld zijn. In dit hoofdstuk maken we kennis met een aantal van dergelijke kenmerken. Sommige van die kenmerken zijn van toepassing op variabelen van alle meetniveau's (bv. modus), andere alleen op variabelen van interval- of ratio-niveau (bv. gemiddelde). Na een inleiding over het gebruik van symbolen bespreken we eerst hoe we het centrum van een verdeling kunnen beschrijven, en hoe we de spreiding kunnen beschrijven.

9.2 Symbolen

In de beschrijvende statistiek wordt veel gewerkt met symbolen. Die symbolen zijn verkorte aanduidingen voor een reeks van handelingen. Sommige van die symbolen zijn je reeds bekend: de exponent ² in de uitdrukking x^2 is een symbool met de betekenis “vermenigvuldig x met zichzelf”, ofwel $x^2 = x \times x$ (waarin ook \times weer een symbool is).

Vaak wordt een hoofdletter gebruikt om een variabele aan te duiden (X), en een kleine letter om een afzonderlijke score van die variabele aan te duiden (x). Als we de afzonderlijke scores willen onderscheiden, dan doen we dat met een subscript index: x_1 is de eerste observatie, x_2 is de tweede observatie, enz. Op deze manier geeft x_i de i 'de score aan, of de score van proefpersoon nummer i , van variabele X . Als we willen generaliseren over alle scores, dan kunnen we de

index weglaten, maar we kunnen ook een punt gebruiken als “lege” index: in de uitdrukking x_{\cdot} staat de punt-index voor iedere willekeurige index.

Het aantal observaties in een bepaalde groep geven we aan met kleine letter n , en het totaal aantal observaties van een variabele met de hoofdletter N . Als er maar één groep is, zoals in de voorbeelden in dit hoofdstuk, dan geldt dat $n = N$.

In de beschrijvende statistiek wordt veel opgeteld, en daarvoor is dan ook een apart symbool, \sum , de griekse hoofdletter Sigma, waarmee een sommering of optelling wordt aangeduid. We zouden kunnen zeggen “tel alle geobserveerde waarden van variabele X bij elkaar op”, maar dat doen we doorgaans korter:

$$\sum_{i=1}^n x_i, \text{ of korter } \sum x$$

Op deze wijze wordt aangegeven dat alle scores x_i bij elkaar moeten worden opgeteld (gesommeerd), voor alle waarden van i (vanaf $i = 1$, tenzij anders aangegeven) tot $i = n$. Alle n scores van de variabele x moeten dus worden opgeteld.

Als er haakjes gebruikt worden, let dan goed op: handelingen beschreven binnen een paar haakjes hebben voorrang, die moet je dus eerst uitvoeren. Ook als dat niet strikt nodig is, zullen we vaak haakjes gebruiken ter verduidelijking, zoals in $(2 \times 3) + 4 = 10$.

9.3 Centrummaten

9.3.1 gemiddelde

De meest bekende maat voor het centrum van een verdeling is wel het gemiddelde. Het gemiddelde is eenvoudig uit te rekenen door alle scores bij elkaar op te tellen, en vervolgens die som weer te delen door het aantal observaties. In symbolen:

$$\bar{x} = \frac{\sum x}{n} = \frac{1}{n} \sum_i^n x_i \quad (9.1)$$

We maken hier meteen kennis met een nieuw symbool, \bar{x} , vaak “x-bar” genoemd, waarmee het gemiddelde van x wordt aangeduid. Het gemiddelde wordt ook vaak aangeduid met het symbool M (Eng. mean), o.a. in artikelen in de APA-stijl.

Voorbeeld 9.1: In een winkel wordt bijgehouden hoe lang klanten moeten wachten bij de kassa, voordat ze aan de beurt zijn. Voor $N = 10$ klanten worden de volgende wachttijden geobserveerd, in minuten:

1, 2, 5, 2, 2, 2, 3, 1, 1, 3.

De gemiddelde wachttijd is $(\sum X)/N = 22/10 = 2.2$ minuten.

Het gemiddelde van X wordt meestal uitgedrukt met één decimaalcijfer meer dan de scores van X .

Het gemiddelde is op te vatten als het “balanspunt” van een verdeling: de observaties aan weerszijden houden elkaar “in evenwicht”, zoals geïllustreerd in Figuur 9.1, waar de “blokken” van het histogram precies “in evenwicht” zijn op het “balanspunt” bij het gemiddelde van 2.2. Het gemiddelde is ook de waarde ten opzichte waarvan de N observaties tezamen het minste verschillen, en het vormt dus een goed kenmerk voor het centrum van een kansverdeling.

Het gemiddelde is alleen bruikbaar bij variabelen van het interval- of ratio-meetniveau.

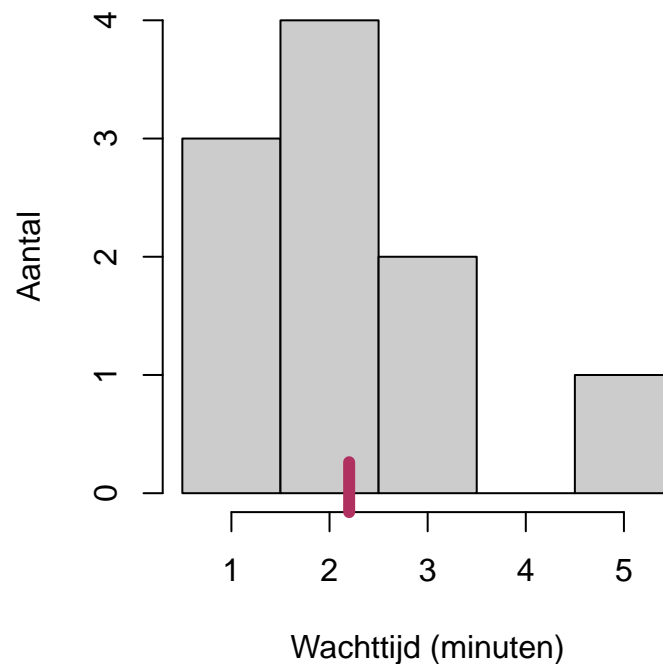


Figure 9.1: Histogram van $N=10$ wachttijden, met markering van het gemiddelde.

9.3.2 mediaan

De mediaan (symbool Md of \tilde{x}) is de observatie in het midden van de rangorde van observaties ¹. Als we de scores van X rangschikken van klein naar groot, dan is de mediaan het middenpunt van die gerangschikte reeks. De helft van de observaties is kleiner dan de mediaan, en de andere helft is groter dan de mediaan.

Bij een oneven aantal observaties is de middelste observatie de mediaan. Bij een even aantal observaties wordt de mediaan gevormd door het gemiddelde van de middelste twee observaties.

Voorbeeld 9.2: De wachttijden uit Voorbeeld 9.1 worden als volgt gerangschikt:

1, 1, 1, 2, 2, 2, 2, 3, 3, 5.

De mediaan is het gemiddelde van de middelste twee (cursieve) observaties, dus 2 minuten.

De mediaan is minder gevoelig dan het gemiddelde voor extreme waarden van x . In het bovenstaande voorbeeld is de extreme wachttijd van 5 minuten van aanzienlijke invloed op het gemiddelde. Als we die waarde zouden verwijderen, dan verandert het gemiddelde van 2.2 naar 1.9, maar de mediaan blijft nog steeds 2. Extreme waarden hebben dus een minder grote invloed op de mediaan dan op het gemiddelde. Pas als de rangschikking van de observaties verandert, kan ook de mediaan veranderen.

De mediaan is bruikbaar bij variabelen van het ordinale, interval- of ratio-meetniveau.

9.3.3 modus

De modus (bijv.nw. ‘modaal’) is de waarde of score van X die het meeste voorkomt.

Voorbeeld 9.3: Bij de wachttijden uit Voorbeeld 9.1 komt de score 2 het meeste voor (4×); dit is de modus.

¹In het Engels wordt de streep in het midden van een weg aangeduid als de “median”; deze streep verdeelt de weg in twee even brede helften.

Voorbeeld 9.4: In 2014 was het gemiddelde inkomen per huishouden in Nederland €34200. Het modale inkomen (per huishouden) lag tussen €18000 en €20000². In 2014 vielen de meeste huishoudens in Nederland dus in deze inkomens-klasse.

De modus is nog minder gevoelig dan de mediaan voor extreme waarden van x . In het bovenstaande voorbeeld 9.2 maakt het niet uit wat de waarde van de langste wachttijd is: ook al zou die observatie de waarde 10 of 1000 hebben, de modus blijft onveranderlijk 2 (ga dat zelf na).

De modus is bruikbaar bij variabelen van alle meetniveau's.

9.3.4 harmonisch gemiddelde

Als de afhankelijke variabele een breuk of verhouding of ratio voorstelt, zoals de snelheid waarmee een taak verricht wordt, dan vormt het (rekenkundig) gemiddelde van formule (9.1) eigenlijk niet een goede aanduiding voor de meest kenmerkende of centrale waarde. In dat geval kan je beter het harmonisch gemiddelde gebruiken:

$$H = \frac{1}{\frac{1}{n} \sum_i \frac{1}{x_i}} = \frac{n}{\sum_i \frac{1}{x_i}} \quad (9.2)$$

Voorbeeld 9.5: Een student schrijft $n = 3$ teksten. Over de eerste tekst (500 woorden) doet hij 2.5 uur, over de tweede tekst (1000 woorden) doet hij 4 uur, en over de derde tekst (300 woorden) doet hij 0.6 uur. Wat is de gemiddelde schrijfsnelheid van deze student? De schrijfsnelheden zijn resp. 200, 250, en 500 woorden per uur, en het “normale” (rekenkundig) gemiddelde daarvan is 317 woorden per uur. Het “eigenlijke” gemiddelde is echter $(500 + 1000 + 300)/(2.5 + 4 + 0.6) = 1800/7.1 = 254$ woorden per uur. De hoge schrijfsnelheid van de korte tekst telt voor $1/n$ deel mee in het rekenkundig gemiddelde, hoewel die tekst slechts $300/1800 = 1/6$ van het totaal aantal woorden bevat.

²<http://www.cbs.nl/nl-NL/menu/themas/inkomen-bestedingen/cijfers/extra/inkomensverdeling.htm>

Omdat de afhankelijke variabele een breuk is (snelheid, woorden/uur), vormt het harmonische gemiddelde hier een betere centrummaat. Eerst rekenen we de snelheid (woorden per tijdseenheid) om naar de inverse daarvan (zie (9.2), in noemer, binnen somteken), d.w.z. naar *tijd* per woord: 0.005, 0.004, en 0.002 (tijdseenheden per woord, zie voetnoot³). Ten tweede middelen we deze tijden, tot gemiddeld 0.00366 uur per woord, en tenslotte nemen we daarvan wederom de inverse. De harmonisch gemiddelde schrijfsnelheid is dan $1/0.00366 = 273$ woorden per uur, dichter bij het “eigenlijke” gemiddelde van 254 woorden per uur.

9.3.5 gewinsoriseerde gemiddelde

De grote gevoeligheid van het gewone (rekenkundige) gemiddelde voor uitbijters kan ingeperkt worden, door de meest extreme observaties te wijzigen naar de minder extreme, meer centrale observaties. Het gemiddelde van deze (deels gewijzigde) observaties wordt het *gewinsoriseerde* gemiddelde genoemd (“winsorized mean”;).

Voorbeeld 9.6: De wachttijden uit Voorbeeld 9.1 worden als volgt gerangschikt:

1, 1, 1, 2, 2, 2, 2, 3, 3, 5.

Voor het 10% gewinsoriseerde gemiddelde worden (na rangordening) de 10% kleinste observaties gelijk gesteld aan de eerstvolgende grotere waarde, en de 10% grootste observaties worden gelijk gesteld aan de laatst voorafgaande kleinere waarde (gewijzigde waarden zijn hier cursief):

1, 1, 1, 2, 2, 2, 2, 3, 3, *3*.

Het winsorized gemiddelde over deze gewijzigde waarden is $\bar{x}_w = 2$ minuten.

9.3.6 getrimde gemiddelde

Een nog drastischer ingreep is om de meest extreme observaties geheel te verwijderen. Het gemiddelde van de overblijvende observaties wordt het *getrimde*

³Dit is vergelijkbaar met sporten als roeien, zwemmen, wielrennen, schaatsen, e.d., waar ook de tijd over een afgesproken afstand gemeten en vergeleken wordt, en niet de snelheid over een afgesproken tijd.

gemiddelde genoemd (“trimmed mean”). Bij een 10% trim verwijderen we de onderste 10% *en* de bovenste 10% van de observaties; er resteren dan dus nog slechts $(1 - (2 \times (10/100)) \times n$ observaties (Wilcox, 2012).

Voorbeeld 9.7: De wachttijden uit Voorbeeld 9.1 worden weer als volgt gerangschikt:

1, 1, 1, 2, 2, 2, 2, 3, 3, 5.

Voor het 10% getrimde gemiddelde worden (na rangordening) de 10% kleinste observaties verwijderd, en de 10% grootste observaties worden eveneens verwijderd:

1, 1, 2, 2, 2, 2, 3, 3.

Het getrimde gemiddelde over deze $10 - (.2)(10) = 8$ resterende waarden is hier $\bar{x}_t = 2$ minuten.

9.3.7 vergelijking van centrummaten

Figuur 9.2 illustreert de verschillen tussen de diverse centrummaten, voor asymmetrisch verdeelde observaties.

Het rekenkundig gemiddelde is het meest gevoelig voor extreme waarden: de extreme waarden “trekken” erg hard aan het gemiddelde. Deze invloed van extreme waarden wordt getemperd in het gewinsoriseerde gemiddelde, en wordt nog meer getemperd in het getrimde gemiddelde. Naarmate de trimfactor (het percentage van de observaties dat wordt gewijzigd of verwijderd) toeneemt, gaan de gewinsoriseerde en getrimde gemiddelden meer lijken op de mediaan. Immers, bij een trimfactor van 50% resteert er van alle observaties nog maar één (ongewijzigde) observatie, en dat is de mediaan (ga dat zelf na). In §9.7 gaan we verder in op de keuze voor een passende maat voor het centrum van een verdeling.

9.4 Kwartielen en boxplots

De verdeling van een variabele wordt niet alleen gekenmerkt door het centrum van die verdeling, maar ook door de mate van spreiding rondom het centrum, d.w.z. hoe groot het verschil is van de observaties t.o.v. het gemiddelde. We willen bijvoorbeeld niet alleen weten wat het gemiddelde inkomen is, maar ook hoe groot de *verschillen* in inkomen zijn.




Figure 9.2: Histogram van een variabele met positief scheve (asymmetrische) frequentieverdeling, met daarin aangegeven (1) de mediaan, (2) het 10% getrimde gemiddelde, (3) het 10% gewinsoriseerde gemiddelde, en (4) het rekenkundig gemiddelde. De geobserveerde scores zijn gemarkeerd langs de horizontale as.

9.4.1 Kwartielen

Een eenvoudige en bruikbare maat daarvoor zijn de kwartielen (Tukey, 1977). We delen de gerangschikte observaties in twee helften op; de grens daartussen is de mediaan. Vervolgens halveren we weer elke helft, tot kwarten. De kwartielen worden gevormd door de grenzen tussen deze kwarten; er zijn dus drie kwartielen. Het eerste kwartiel Q_1 is de mediaan van de onderste helft, Q_2 is de mediaan van alle n observaties, en het derde kwartiel Q_3 is de mediaan van de bovenste helft. De helft van de observaties (nl. het tweede en derde kwart) ligt tussen Q_1 en Q_3 . De afstand tussen Q_1 en Q_3 wordt de “interquartile range” genoemd (IQR). Deze IQR vormt een eerste bruikbare maat voor de spreiding van observaties ten opzichte van hun centrale waarde.

Voor de uitleg maken we gebruik van de fictieve scores op een leestoets, gegeven in Tabel 9.1.

Table 9.1: Scores van $N=10$ leerlingen op drie onderdelen van de CITO-toets, afgenomen in groep 8 van het basisonderwijs.

| Leerling | Lezen | Rekenen | Wereldoriëntatie |
|----------|-------|---------|------------------|
| 1 | 18 | 22 | 55 |
| 2 | 32 | 36 | 55 |
| 3 | 45 | 34 | 38 |

| Leerling | Lezen | Rekenen | Wereldoriëntatie |
|-----------|-------|---------|------------------|
| 4 | 25 | 25 | 40 |
| 5 | 27 | 29 | 48 |
| 6 | 23 | 20 | 44 |
| 7 | 29 | 27 | 49 |
| 8 | 26 | 25 | 42 |
| 9 | 20 | 25 | 57 |
| 10 | 25 | 27 | 47 |
| $\sum x$ | 270 | 270 | 475 |
| \bar{x} | 27.0 | 27.0 | 47.5 |

Voorbeeld 9.8: De scores bij het onderdeel Lezen in Tabel 9.1 zijn als volgt gerangschikt:

18, 20, 23, 25, 25, 26, 27, 29, 32, 45.

De mediaan is $Q_2 = 25.5$ (tussen de 5e en 6e observatie in deze ranglijst). De mediaan van de onderste helft is $Q_1 = 23$ en die van de bovenste helft is $Q_3 = 29$. De interquartile range is $IQR = 29 - 23 = 6$.

9.4.2 Uitbijters

In de leesscores in Tabel 9.1 treffen we een extreme waarde aan, nl. de score 45, die opvallend veel verschilt van het gemiddelde. Zo'n opvallende waarde wordt aangeduid als een "uitbijter" (in het Engels als "outlier"). De grens voor wat we beschouwen als een uitbijter ligt doorgaans bij $1.5 \times IQR$. Als een waarde meer dan $1.5 \times IQR$ boven Q_3 of onder Q_1 ligt, dan beschouwen we die observatie als een uitbijter. Controleer deze observaties nog eens (denk aan het principe van zorgvuldigheid, zie §3.1).

Voorbeeld 9.9: Voor de eerder genoemde leesscores in Tabel 9.1 vonden we $Q_1 = 23$, $Q_3 = 29$, en $IQR = Q_3 - Q_1 = 29 - 23 = 6$. De bovenste grenswaarde voor uitbijters is $Q_3 + 1.5 \times IQR = 29 + 1.5 \times 6 = 29 + 9 = 38$. De observatie met score 45 ligt boven deze grenswaarde, en wordt daarom beschouwd als uitbijter.

9.4.3 Boxplots

De frequentieverdeling van een variabele kunnen we nu weergeven met vijf kenmerken, de zgn. “five-number summary”, nl. de kleinste waarde, Q_1 , mediaan, Q_3 , en grootste waarde. Deze vijf kenmerken worden grafisch weergegeven in een zgn. “boxplot”, zie Figuur 9.3 voor een voorbeeld (Tukey, 1977, §2C).




Figure 9.3: Boxplots van scores van $N = 10$ leerlingen op de onderdelen Lezen en Rekenen van de CITO-toets (zie Tabel 9.1), met uitbijters als open cirkels gemarkeerd. De geobserveerde scores zijn gemarkeerd langs de verticale assen.

De box omspanst het gebied van (bij benadering) Q_1 tot Q_3 , en omspanst dus de centrale helft van de observaties. De dikkere lijn in de box markeert de mediaan. De lijnen strekken zich uit naar de kleinste en grootste waarden *die géén uitbijters zijn*⁴. De afzonderlijke uitbijters worden hier met een apart symbool aangeduid.

⁴In een klassieke boxplot strekken de lijnen zich uit naar het minimum en maximum (Tukey, 1977) en worden uitbijters niet apart aangeduid.

9.5 Spreidingsmaten

9.5.1 variantie

Een andere manier om de spreiding van de observaties aan te geven, zou zijn om te kijken naar de afwijking van iedere observatie ten opzichte van het gemiddelde, dus $(x_i - \bar{x})$. Maar als we al die afwijkingen optellen, dan is de som daarvan altijd nul! De positieve en negatieve afwijkingen heffen elkaar immers op (ga dat zelf na in Tabel 9.1). Daarom middelen we niet de afwijkingen zelf, maar de kwadraten van die afwijkingen. Zowel de positieve als de negatieve afwijkingen resulteren in positieve gekwadrateerde-afwijkingen. Van al die gekwadrateerde-afwijkingen berekenen we het gemiddelde, d.w.z. we tellen ze op en delen door $(n - 1)$, zie voetnoot⁵. Het resultaat noemen we de *variantie*, aangeduid met symbool s^2 :

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1} \quad (9.3)$$

De teller van deze breuk wordt wel aangeduid als de “sum of squared deviations” of “sum of squares” (SS) en de noemer wordt wel aangeduid als het aantal vrijheidsgraden of “degrees of freedom” van de teller (d.f.; zie §9.6).

De variantie rekenen we tegenwoordig altijd uit met een rekenmachine of computer.

9.5.2 standaarddeviatie

Om de bovenstaande variantie te berekenen, hebben we de afwijkingen van de observaties gekwadrateerd. De variantie is dus een grootte die niet wordt uitgedrukt in de oorspronkelijke eenheden (bijv. seconden, cm, score), maar in gekwadrateerde eenheden (bijv. s^2 , cm^2 , score^2). Teneinde weer terug te keren naar de oorspronkelijke eenheden, nemen we de wortel uit de variantie. Het resultaat noemen we de *standaarddeviatie*, aangeduid met symbool s :

$$s = \sqrt{s^2} = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}} \quad (9.4)$$

⁵We delen door $n - 1$ en niet door n , om een betere schatting te krijgen van de spreiding in de *populatie*. Op deze manier houden we rekening met het feit dat we één kenmerk van de steekproef (nl. het gemiddelde) gebruiken om de spreiding te bepalen. Als je alleen geïnteresseerd bent in de spreiding in je *steekproef* van observaties, en niet in de populatie, deel dan door n .

Voorbeeld 9.10: Het gemiddelde van de eerder genoemde leesscores in Tabel 9.1 is 27.0, en de afwijkingen zijn als volgt:

-9, 5, 18, -2, 0, -4, 2, -1, -7, -2.

De gekwadrateerde afwijkingen zijn 81, 25, 324, 4, 0, 16, 4, 1, 49, 4.

De som van deze gekwadrateerde afwijkingen is 508, en de variantie is dan $s^2 = 508/9 = 56.44$. De standaarddeviatie is de wortel van de variantie, dus $s = \sqrt{508/9} = 7.5$.

De variantie en standaarddeviatie zijn alleen bruikbaar bij variabelen van het interval- of ratio-meetniveau. Ook de variantie en standaarddeviatie kunnen weer gebaseerd zijn op de gewinsoriseerde of getrimde verzameling van observaties.

De standaarddeviatie hebben we nodig (a) als we de ruwe observaties willen omzetten naar standaardscores (zie §9.8 hieronder), (b) als we een variabele willen beschrijven die normaal verdeeld is (zie §10.3, en (c) als we hypothesen willen toetsen met behulp van een normaal verdeelde variabele (zie §@ref(sec:ttoets.onesample) e.v.).

9.5.3 MAD

Behalve de standaarddeviatie is er ook een robuuste tegenhanger daarvan, die niet gebruik maakt van het gemiddelde. Deze maat is daarom minder gevoelig voor uitbijters (robuuster), wat soms handig is.

We kijken hiervoor naar de afwijking van iedere observatie ten opzichte van de mediaan (niet t.o.v. het gemiddelde). Van deze afwijkingen nemen we de absolute waarde⁶ (niet het kwadraat). Van deze absolute afwijkingen bepalen we tenslotte weer de mediaan (niet het gemiddelde). Het resultaat noemen we de “median absolute deviation” (MAD):

$$\text{MAD} = k \cdot \text{Md}(|x_i - \text{Md}(x)|) \quad (9.5)$$

Hierbij gebruiken we meestal $k = 1.4826$ als constante; door deze schaalfactor komt de MAD ruwweg overeen met de standaarddeviatie s indien x normaal verdeeld zou zijn (§10.3).

Voorbeeld 9.11: De mediaan van de eerder genoemde leesscores in Tabel 9.1 is 25.5, en de afwijkingen van die mediaan zijn als volgt:

⁶Positieve afwijkingen blijven ongewijzigd, van negatieve afwijkingen wordt het teken omgekeerd.

-7.5, 6.5, 19.5, -0.5, 1.5, -2.5, 3.5, 0.5, -5.5, -0.5.

De gerangschikte, absolute afwijkingen zijn

0.5, 0.5, 0.5, 1.5, 2.5, 3.5, 5.5, 6.5, 7.5, 19.5.

De mediaan van deze 10 absolute afwijkingen is 3, en $\text{MAD} = 1.4826 \times 3 = 4.4478$. Merk op dat de MAD kleiner is dan de standaarddeviatie, o.a. omdat de MAD minder gevoelig is voor de extreme waarde $x_3 = 45$.

9.6 Over significante cijfers

9.6.1 Gemiddelde en standaarddeviatie

Een gemiddelde uitkomst wordt weergegeven in een beperkt aantal significante cijfers, d.i. een beperkt aantal cijfers, van links naar rechts geteld, zonder acht te slaan op het decimaalteken. Het aantal significante cijfers van een gemiddelde uitkomst moet gelijk zijn aan het aantal significante cijfers van het *aantal observaties* waarover is gemiddeld. (Overige cijfers in de gemiddelde uitkomst zijn niet nauwkeurig bepaald.) De gemiddelde uitkomst moet eerst afgerond worden tot het gepaste aantal significante cijfers, voordat de uitkomst verder geïnterpreteerd wordt, zie Tabel 9.2.

Table 9.2: Het aantal significante cijfers in het gerapporteerde gemiddelde is gelijk aan het aantal significante cijfers van het aantal observaties.

| aant.obs. | aant.signif.cijfers | voorbeeld gemiddelde | rapporteer als |
|---------------|---------------------|------------------------|----------------|
| 1 ... 9 | 1 | $21/8 = 2.625$ | 3 |
| 10 ... 99 | 2 | $57/21 = 2.714286$ | 2.7 |
| 100 ... 999 | 3 | $317/120 = 2.641667$ | 2.64 |
| 1000 ... 9999 | 4 | $3179/1234 = 2.576175$ | 2.576 |

Het aantal significante cijfers in de gerapporteerde standaarddeviatie is hetzelfde als in het gemiddelde, volgens Tabel 9.2.

9.6.1.1 Achtergrond

Laten we aannemen dat ik de afstand van mijn huis naar mijn werk langs een vaste route een aantal keren heb gemeten. Het gemiddelde van die metingen bedraagt zogenaamd 2.954321 km. Door het gemiddelde te rapporteren met 7 cijfers suggereer ik hier dat ik precies weet dat de afstand 2954321 millimeter is,

en ten hoogste 1 mm meer of minder: het laatste cijfer is geschat of afgerond. Het aantal significante cijfers (in dit voorbeeld 7) geeft de mate van nauwkeurigheid aan. In dit voorbeeld is de gesuggereerde nauwkeurigheid van 1 mm duidelijk onjuist, o.a. omdat beginpunt en eindpunt niet tot op de millimeter bepaald zijn. Het is daarom gebruikelijk om de gemiddelde gemeten afstand te rapporteren met een aantal significante cijfers dat de nauwkeurigheid van die metingen en van het gemiddelde aangeeft, bijv. 3.0 km (per auto of fiets) of 2.95 km (te voet).

Dezelfde gedachtengang is van toepassing bij de meting van een kenmerk door middel van een enquête-vraag. Met $n = 15$ respondenten zou de gemiddelde score $43/15 \approx 2.86667$ kunnen zijn. Maar de nauwkeurigheid is in dit voorbeeld niet zo goed als dit decimale getal suggereert. In feite zorgt hier één afwijkend antwoord al voor een afwijking van ± 0.06667 in het gemiddelde. Bovendien is een gemiddelde score altijd het resultaat van een deling, en “(bij) delen en vermenigvuldigen geldt de regel dat de uitkomst evenveel significante cijfers bevat als de meetwaarde met het kleinste aantal significante cijfers.”⁷ In dit voorbeeld bestaan de teller (43) en de noemer (15) van het gemiddelde beide uit 2 significante cijfers, en dient de uitkomst dus ook uit 2 significante cijfers te bestaan. De gemiddelde score dient gerapporteerd te worden als 2.9 punten, met slechts één cijfer achter het decimaalteken.

9.6.2 Percentages

Een percentage is een verhouding of breuk, vermenigvuldigd met 100. Gebruik en rapporteer een afgerond percentage (d.i. twee significante cijfers) alleen indien de noemer van de verhouding of breuk groter is dan 100. Deze noemer geeft het aantal waarnemingen of gevallen. Als de noemer kleiner is dan 100 (waarnemingen, gevallen), dan zijn percentages misleidend, zie Tabel 9.3.

Table 9.3: Het aantal significante cijfers in de gerapporteerde proportie (of percentage) hangt samen met het aantal significante cijfers van het aantal observaties in de noemer van de breuk.

| aant.obs.(noemer) | aant.signif.cijfers | voorbeeld breuk | rapporteer als |
|-------------------|---------------------|----------------------|----------------|
| 1 ... 9 | 1 | $3/8 = 0.4$ | 3/8 |
| 10 ... 99 | 2 | $21/57 = 0.36$ | 21/57 |
| 100 ... 999 | 3 | $120/317 = 0.378$ | 38% |
| 1000 ... 9999 | 4 | $1234/3179 = 0.3882$ | 38.8% |

⁷https://nl.wikipedia.org/wiki/Significant_cijfer

9.6.2.1 Achtergrond

De regels voor percentages vloeien voort uit die in §9.6.1 toegepast op delingen. Als de noemer groter is dan 100 is het percentage (met twee significante cijfers) het gevolg van een schaalverandering “naar beneden” (van een noemer groter dan 100 naar een noemer van precies 100 percentagepunten). De percentageschaal is minder nauwkeurig dan de oorspronkelijke verhouding; de percentages zijn afgerond tot op twee significante cijfers; het laatste significante cijfer van het percentage is dus geborgd.

Als de noemer echter kleiner is dan 100 dan is het percentage (met twee significante cijfers) het gevolg van een “oprekking naar boven” (van een noemer kleiner dan 100 naar een noemer van precies 100 percentagepunten). De percentageschaal suggereert dan een pseudo-nauwkeurigheid die er niet was in de oorspronkelijke verhouding, en de nauwkeurigheid van de percentageschaal is vals. Als de noemer kleiner is dan 100, zijn percentages dus misleidend.

Voorbeeld 9.12: In een cursus van 29 studenten zijn er 23 studenten geslaagd. We spreken dan vaak van een cursusrendement van $23/29 = 79\%$. Toch is zo’n weergave als percentage in dit geval misleidend. Laten we daarvoor eens kijken naar de 6 gezakten. Je kunt beredeneren dat het aantal van 6 gezakten een eigen afrondingsfout heeft van $1/2$ student; bij omzetting naar de percentageschaal wordt ook deze afrondingsfout mee vergroot, zodat de percentages minder nauwkeurig zijn dan de hele percentages (2 significante cijfers) suggereren. Of anders gezegd: het aantal van 6 gezakten (d.i. een getal met één significant cijfer) noopt ons om ook de verhouding weer te geven met slechts één significant cijfer, en dus niet als percentage. Rapporteer bij voorkeur de verhouding zelf ($23/29$), of eventueel de “odds” ($23/6 = 4$) afgerond tot het juiste aantal significante cijfers⁸.

Op grond van dezelfde overwegingen is een percentage met een decimaal cijfer (d.i. met drie significante cijfers, bv. “36.1%”) alleen zinnig als de noemer van de verhouding of breuk groter is dan 1000.

Voorbeeld 9.13: In 2013 startten 154 studenten met een tweejarige research master. Na 2 jaar waren 69 daarvan afgestudeerd. Het

⁸Deze “odds” geeft aan dat er 23 geslaagden zijn op 6 gezakten, d.i. afgerond 4 geslaagden voor iedere gezakte.

nominaal rendement voor dit cohort is dan $69/154 = 0.448052$, af te ronden en te rapporteren als 44% (niet als 44.81%).

9.7 Keuzemoment

De verdeling van een variabele kun je op verschillende manieren beschrijven. Als variabele X gemeten is op het interval- of ratio-meetniveau, begin dan altijd met een histogram (§8.4) en een boxplot (§9.4.3).

De centrummaten en spreidingsmaten zijn te ordenen zoals in Tabel 9.4.

Table 9.4: Overzicht van besproken centrummaten en spreidingsmaten.

| Verdeling | Centrummaat | Spreidingsmaat |
|-------------|----------------------------|-----------------------------|
| alle | mediaan | kwartielen, IQR, MAD |
| ... | getrimde of gewins.gemidd. | getrimde of gewins.std.dev. |
| (a & b & c) | gemiddelde | standaarddeviatie |

De meest **robuste** maten staan bovenin (mediaan, kwartielen, IQR, MAD). Deze maten zijn robuust: ze zijn weinig gevoelig voor uitbijters of voor eventuele *asymmetrie* in de frequentieverdeling, zoals de voorbeelden in dit hoofdstuk laten zien.

De meest **efficiënte** maten staan onderin in Tabel 9.4: gemiddelde en standaarddeviatie. Deze maten zijn efficiënt: ze geven het centrum en de spreiding het beste weer, ze hebben zelf de kleinste standaarddeviatie, en ze hebben daarvoor relatief het kleinste aantal observaties nodig. De andere maten nemen een tussenpositie in: de getrimde maten zijn wat robuuster, en de gewinsoriseerde maten wat efficiënter.

De meest efficiënte maten vereisen echter ook de meest vèrgaande assumpties (en de meest robuuste maten vereisen de minste assumpties). Deze efficiënte maten zijn alleen zinnig, indien de verdeling van X voldoet aan drie assumpties: (a) de verdeling is min of meer symmetrisch, d.w.z. de linker- en rechter-helft van het histogram resp. de bovenste en onderste helft van de boxplot lijken elkaars spiegelbeeld, (b) de verdeling is unimodaal, d.w.z. de verdeling heeft één modus, en (c) de verdeling bevat geen of nauwelijks uitbijters. Inspecteer deze assumpties in het histogram en de boxplot van X . Als aan één van deze assumpties niet is voldaan, dan doe je er beter aan om meer robuuste maten te gebruiken om de verdeling te beschrijven.

9.8 Standaardscores

Soms kan het handig zijn om scores te vergelijken die gemeten zijn op verschillende schalen. Bijvoorbeeld: Jan had een 8 als eindcijfer voor wiskunde op het VWO, en zijn IQ is 136. Is de afwijking van Jan ten opzichte van het gemiddelde even groot op beide schalen? Om zo'n vraag te beantwoorden moeten we de scores van de twee variabelen uitdrukken op dezelfde meetschaal. Dat doen we door de ruwe scores om te rekenen naar standaard-scores, of z-scores. Hiervoor nemen we de afwijking van iedere score ten opzichte van het gemiddelde, en we delen die afwijking door de standaarddeviatie:

$$z_i = \frac{(x_i - \bar{x})}{s_x} \quad (9.6)$$

De standdaardscore of z-score representeert dus de afstand van de i 'de observatie tot het gemiddelde van x , uitgedrukt in eenheden standaarddeviatie. Bij een standdaardscore van $z = -1$ is de geobserveerde score precies $1 \times s$ beneden het gemiddelde \bar{x} . Bij een standdaardscore van $z = +2$ dan is de geobserveerde score precies $2 \times s$ boven het gemiddelde⁹.

De z-scores zijn ook handig om twee variabelen te vergelijken die weliswaar op dezelfde schaal gemeten zijn (bijvoorbeeld een schaal van 1 ... 100), maar die toch verschillende gemiddelden en/of verschillende standaarddeviaties hebben, zoals de scores in Tabel 9.1. In Hoofdstuk 10 zullen we verder werken met z-scores.

De standdaardscore of z-score heeft twee handige eigenschappen die je moet onthouden. Ten eerste is het gemiddelde altijd gelijk aan nul: $\bar{z} = 0$, en ten tweede is de standaarddeviatie gelijk aan 1: $s_z = 1$. (Deze eigenschappen volgen uit de definitie in formule (9.6); het wiskundige bewijs laten we hier achterwege.) Dus de transformatie van een verzameling observaties naar standdaardscores of z-scores levert altijd een verdeling op met een gemiddelde van nul en een standaarddeviatie van één. Bedenk wel dat deze transformatie naar standdaardscores alleen zinnig is, indien en voor zover het gemiddelde en de standaarddeviatie ook zinnige maten zijn om de verdeling van x te beschrijven (zie §9.7).

9.9 SPSS

Voor **histogram**, **percentielen** en **boxplot**:

Analyze > Descriptive Statistics > Explore...

⁹Check: $z = +2 = \frac{(x_i - \bar{x})}{s_x}$, dus $2s = (x_i - \bar{x})$, dus $x_i = \bar{x} + 2s$.

Selecteer variabele (sleep naar Variable(s) paneel)
Kies **Plots**, vink aan: **Histogram**, en bevestig met **Continue**
Kies **Options**, vink aan: **Percentiles**, en bevestig met **Continue** en daarna met **OK**.
De uitvoer bevat zowel beschrijvende statistiek als histogram en boxplot.
Voor **kenmerkende getallen**:

Analyze > Descriptive Statistics > Descriptives...

Selecteer variabele (sleep naar Variable(s) paneel)
Kies **Options**; vink aan: **Mean**, **Sum**, **Std.deviation**, **Variance**, **Minimum**, **Maximum**, en bevestig met **Continue** en daarna met **OK**.
De uitvoer bevat de gevraagde statistische kenmerken van de verdeling van de variabele.

Voor **mediaan**:

Analyze > Compare Means > Means...

Selecteer variabele (sleep naar Variable(s) paneel)
Kies **Options**; vink aan: **Mean**, **Number of cases**, **Standard deviation**, **Variance**, **Minimum**, **Maximum** en ook **Median**, en bevestig met **Continue** en daarna met **OK**.
De uitvoer bevat de gevraagde statistische kenmerken van de verdeling van de variabele.

Standaardcores uitrekenen en bewaren in nieuwe kolom:

Analyze > Descriptive Statistics > Descriptives...

Selecteer variabele (sleep naar Variable(s) paneel)
Vink aan: **Save standardized values as variables** en bevestig met **OK**.
De nieuwe variabele(n) met z-scores worden toegevoegd als nieuwe kolom(men) aan het databestand.

9.10 R

Voor **kwartielen** en **boxplot** zoals Figuur 9.3 gebruiken we de commando's **fivenum**, **quantile**, en **boxplot**:


```
require(foreign) # for foreign::read.spss
cito <- read.spss("data/cito.sav")
fivenum(cito$Lezen) # minimum, Q1, mediaan, Q3, maximum
```

```
## [1] 19 22 26 29 44
```

```
quantile(cito$Lezen, c( 1/4, 3/4 ) ) # Q1 en Q3, anders berekend
```

```
## 25% 75%
## 22.75 28.75
```

```
op <- par(mar=c(4,4,1,2)+0.1) # smaller margins
with(cito,
  boxplot(Lezen, Rekenen, col="grey80", lwd=2, lty=1, ylab="Score", ylim=c(17,45) )
)
axis(side=1, at=c(1,2), labels=c("Lezen", "Rekenen") )
plotrix::axis.break(axis=2) # break in linker Y-as
rug(cito$Lezen, side=2) # markeringen linker Y-as
rug(cito$Rekenen, side=4) # markeringen rechter Y-as
```



Veel **centrummaten** zijn als functie in R voorgeprogrammeerd:

```
mean(cito$Lezen) # gemiddelde
```

```
## [1] 27.2
```

```
psych::winsor.mean(cito$Lezen, trim=.1) # gewinsoriseerde gemiddelde, uit psych package
```

```
## [1] 26.3
```

```
mean(cito$Lezen, trim=.1) # getrimde gemiddelde
```

```
## [1] 26.125
```

```
median(cito$Lezen) # mediaan
```

```
## [1] 26
```

Ook diverse **spreidingsmaten** zijn voorgeprogrammeerd:

```
var(cito$Lezen) # variantie
```

```
## [1] 50.17778
```

```
sd(cito$Lezen) # standaarddeviatie, sd(x) = sqrt(var(x))
```

```
## [1] 7.083627
```

```
mad(cito$Lezen) # MAD
```

```
## [1] 5.1891
```

Daarentegen moeten we **standaardscores** zelf uitrekenen, en zelf bewaren als nieuwe variabele, hier **zLezen** genoemd (let op de haakjes in de eerste regel):

```
zLezen <- (cito$Lezen - mean(cito$Lezen)) / sd(cito$Lezen) # z-scores
head(zLezen) # eerste paar observaties van variabele zLezen
```

```
## [1] -1.1575990 0.6776189 2.3716662 -0.3105753 0.1129365 -0.7340872
```


Chapter 10

Kansverdelingen

10.1 Kansen

Bellen achter het stuur vergroot de kans op een ongeluk (Bhargava and Pathania, 2013). De gemiddelde kans op neerslag in Nederland is 7%. Mijn bestelling heeft 10% kans om een dag later dan beloofd afgeleverd te worden. Kansen en waarschijnlijkheden spelen een belangrijke rol in ons dagelijks leven, en ook in het wetenschappelijk onderzoek. Immers, veel hypothesen zijn probabilistisch van aard (zie Hoofdstuk 2): de hypothesen doen uitspraken over een verschil in *kansen* van uitkomsten. Om conclusies te kunnen trekken ten aanzien van die probabilistische hypothesen hebben we enige kennis nodig over waarschijnlijkheden, kansberekening, en kansverdelingen. Daarover gaat dit hoofdstuk.

Laten we ter inleiding eens kijken naar een Nederlands *Scrabble*-spel. Het spel bevat een zakje met daarin 102 fiches, met op elke fiche een letter¹. Van de 102 fiches zijn er 6 met de letter A. Als ik uit een vol en goed gemengd zakje één fiche neem, wat is dan de kans dat ik de letter A tref? Die kans-op-uitkomst-A wordt aangeduid als $P(A)$, met de P van *Probabilitas* (Lat. “kans, waarschijnlijkheid”), en is te bepalen als

$$P(A) = \frac{\text{aantal A's}}{\text{totaal aantal fiches}} = \frac{6}{102} = 0.0588 \quad (10.1)$$

De kans op een gebeurtenis wordt uitgedrukt als een proportie, een getal tussen 0 en 1, of als een percentage, d.w.z. een proportie in eenheden van 1/100. Een kans kan dus nooit kleiner zijn dan 0 en kan nooit groter zijn dan 1: de kans is immers de verhouding tussen (teller) aantal specifieke uitkomsten en (noemer) totaal aantal mogelijke uitkomsten (zie formule (10.1)), waarbij deze teller nooit groter kan zijn dan deze noemer (Schuurman and De Kluiver, 2001).

¹Twee van de fiches zijn echter zonder letter; later in deze paragraaf zullen we deze blanco fiches verwijderen uit het zakje.

Als twee uitkomsten elkaar wederzijds uitsluiten, zoals bij de uitkomsten A of B in ons Scrabble-voorbeeld, dan mogen we de kansen van die uitkomsten *optellen* (somregel). De kans op uitkomst A *of* uitkomst B (waarbij de uitkomsten A en B elkaar uitsluiten), is de *som* van $P(A)$ en $P(B)$:

$$P(A \text{ of } B) = P(A) + P(B) \quad (10.2)$$

Voorbeeld 10.1: In ons Scrabble-voorbeeld is $P(A) = \frac{6}{102}$ en $P(B) = \frac{2}{102}$. De kans op uitkomst A-of-B is dan $P(A \text{ of } B) = P(A) + P(B) = \frac{6}{102} + \frac{2}{102} = \frac{8}{102} = .0784$.

Als ik uit een vol en goed gemengd zakje één fiche neem, dan zijn er twee complementaire uitkomsten mogelijk: ik tref een A, of ik tref *niet* een A. De uitkomsten sluiten elkaar weer wederzijds uit, dus ook de kansen op deze uitkomsten mogen we optellen. Bovendien zijn de uitkomsten complementair, d.w.z. de uitkomst kan alleen maar één van deze twee mogelijke uitkomsten zijn. De respectievelijke kansen op deze complementaire gebeurtenissen zijn dan ook complementair, d.w.z. deze respectievelijke kansen tellen op tot precies 1 = 100% (complementregel). Er is immers 100% kans dat de uitkomst één van de twee mogelijke uitkomsten van de trekking is. Als we $P(A)$ al kennen kunnen we de kans op de complementaire uitkomst makkelijk uitrekenen:

$$\begin{aligned} P(A) + P(\text{niet-A}) &= 1 \\ P(A) &= 1 - P(\text{niet-A}) \\ P(\text{niet-A}) &= 1 - P(A) \end{aligned}$$

Voorbeeld 10.2: In ons Scrabble-voorbeeld is $P(A) = \frac{6}{102}$. De kans op uitkomst niet-A is dan $P(\text{niet-A}) = 1 - P(A) = 1 - \frac{6}{102} = \frac{96}{102} = .9412$.

Laten we als gedachten-experiment nu een tweede Scrabble-spel pakken, en daaruit een tweede zakje met fiches pakken, eveneens vol en goed gemengd. Uit elk zakje nemen we nu blind één letterfiche. Er zijn nu twee gebeurtenissen of uitkomsten, nl. de uitkomst van de eerste trekking (uit het eerste zakje), en de uitkomst van de tweede trekking (uit het tweede zakje). Deze twee uitkomsten sluiten elkaar niet wederzijds uit, want de twee uitkomsten hebben geen

wederzijdse invloed op elkaar. De uitkomst uit het tweede zakje wordt immers niet beïnvloed door de uitkomst van het eerste zakje, of omgekeerd. We zeggen dan dat deze uitkomsten *onafhankelijk* van elkaar zijn. Als de uitkomsten inderdaad onafhankelijk van elkaar zijn, dan berekenen we de kans op een combinatie van uitkomsten door de kansen te *vermenigvuldigen* (productregel). De kans op de combinatie van uitkomst A *en* uitkomst B (waarbij de uitkomsten A en B onafhankelijk van elkaar zijn), is het *product* van $P(A)$ en $P(B)$:

$$P(A \text{ en } B) = P(A) \times P(B) \quad (10.3)$$

Voorbeeld 10.3: In ons Scrabble-voorbeeld is $P(A) = \frac{6}{102}$ en $P(B) = \frac{2}{102}$. De kans op uitkomst A bij het eerste zakje *en* B bij het tweede zakje is dan $P(A \text{ en } B) = P(A) \times P(B) = \frac{6}{102} \times \frac{2}{102} = .0012$.

Voorbeeld 10.4: In ons Scrabble-voorbeeld is $P(\text{klinker}) = \frac{38}{102}$. De kans om een klinker (A, E, I, O, U, Y) te trekken uit het eerste zakje *en* een klinker uit het tweede zakje is dan $P(\text{klinker-en-klinker}) = P(\text{eerste klinker}) \times P(\text{tweede klinker}) = \frac{38}{102} \times \frac{38}{102} = (\frac{38}{102})^2 = .1388$.

10.2 Binomiale kansverdeling

Voor het vervolg van dit hoofdstuk brengen we twee wijzigingen aan in het Scrabble-spel. Ten eerste verwijderen we de 2 blanco fiches zonder letter uit het zakje. Er blijven dan precies 100 fiches over, waarvan 38 met een klinker (vocaal, V) en 62 met een medeklinker (consonant, C). Er blijven dus slechts twee mogelijke categorieën van uitkomsten over, die elkaar wederzijds uitsluiten. Zo'n variabele van het nominale meetnivo, met precies twee categorieën, noemen we bi-nomiaal ('twee-namig'). We beschouwen de klinkers als treffers, en de medeklinkers als missers. Deze twee mogelijke uitkomsten zijn complementair: $P(V) = .38$ (afgekort als p) en $P(C) = .62$ (afgekort als $q = 1 - p$).

Ten tweede leggen we het getrokken letterfiche voortaan terug in het zakje, nadat we de getrokken letter genoteerd hebben. Op die manier hebben we niet tientallen complete letterzakjes nodig, maar slechts één letterzakje dat na elke teruglegging weer compleet en goed gemengd is. We beschouwen de uitkomsten van opeenvolgende trekkingen als onafhankelijk.

Terzijde: De uitkomst van een bepaalde trekking is dus onafhankelijk van de uitkomst van vorige trekkingen. Als er zojuist $100 \times$ achtereen een klinker

getrokken is, dan heeft dat geen enkele invloed op (de uitkomst van) de eerstvolgende trekking uit het letterzakje. Het letterzakje, of de hand van de trekker, heeft immers geen geheugen. Bij *elke* trekking is de kans op een treffer $p = .38$, ook als er zojuist $100\times$ of $1000\times$ een klinker is getrokken. Hetzelfde geldt voor de opeenvolgende uitkomsten bij roulette: bij elke ronde is de kans op een treffer $1/37$, ook als het balletje zojuist $100\times$ op eenzelfde getal terecht is gekomen².

Laten we met bovengenoemde wijzigingen nu $n = 3$ trekkingen uitvoeren (met teruglegging, zie boven), en voor elke mogelijke uitkomst de kans op die uitkomst bepalen, zie Tabel 10.1.

Table 10.1: Kansen van mogelijke uitkomsten van $n = 3$ trekkingen van klinkers, $p = .38$, met teruglegging (zie tekst).

| uitkomst | aantal klinkers | kans |
|----------|-----------------|--------------|
| CCC | 0 | $qqq = q^3$ |
| VCC | 1 | $pqq = pq^2$ |
| CVC | 1 | $qpq = pq^2$ |
| CCV | 1 | $qqp = pq^2$ |
| VVC | 2 | $ppq = p^2q$ |
| VCV | 2 | $pqp = p^2q$ |
| CVV | 2 | $qpp = p^2q$ |
| VVV | 3 | $ppp = p^3$ |

Het aantal treffers (klinkers) in de $n = 3$ trekkingen heeft de *kansverdeling* zoals samengevat in Tabel 10.2 (eerste en laatste kolom) en Figuur 10.1 (horizontale en verticale as). In zo'n kansverdeling zien we voor elke mogelijke uitkomst van x (hier: aantal klinkers) hoe groot de kans op die uitkomst is.

Table 10.2: Kansverdeling van een binomiale variabele met $n = 3$ en $p = .38$.

| aantal klinkers | kans | kans |
|-----------------|-------------|------------|
| 0 | $1q^3$ | $= .2383$ |
| 1 | $3pq^2$ | $= .4383$ |
| 2 | $3p^2q$ | $= .2686$ |
| 3 | $1p^3$ | $= .0549$ |
| som | $(p + q)^3$ | $= 1.0000$ |

De kansverdeling van een binomiale variabele noemen we de binomiale kansverdeling, ook aangeduid als binomiale verdeling of binomiaalverdeling. De

²Roulettespelers kunnen gokken op 36 van de 37 mogelijke uitkomsten, dus op de lange termijn ontvangt het casino $1/37$ deel van alle inzetten.




Figure 10.1: Kansverdeling van een binomiale variabele x met $n=3$ en $p=.38$.

exacte kansen van de binomiale kansverdeling kan je uitrekenen met formule (10.4) hieronder.

10.2.1 formules

De kans op een x aantal treffers in n trekkingen is gegeven als

$$P(x \text{ treffers}) = \binom{n}{x} p^x (1-p)^{n-x} \quad (10.4)$$

waarbij n is het aantal trekkingen of pogingen, x is het aantal treffers (tussen 0 en n), en p is de kans op een treffer.

De coëfficiënt $\binom{n}{x}$ geeft het aantal verschillende ordeningen aan waarin we een combinatie (greep) van x elementen uit n kunnen kiezen. Bij $x = 1$ klinker uit $n = 3$ trekkingen zijn er drie mogelijkheden: de ene klinker zou getrokken kunnen zijn in de eerste trekking, of de tweede trekking, of de derde trekking, zie Tabel 10.1. Het aantal verschillende mogelijke ordeningen is gegeven als

$$\binom{n}{x} = \frac{n!}{x!(n-x)!} \quad (10.5)$$

waarbij $x! = x(x-1)(x-2)\cdots \times 2 \times 1$, dus $4! = 4 \times 3 \times 2 \times 1 = 24$.

Voorbeeld 10.5: Er staan 4 stoelen voor 2 personen. Op een stoel mag maximaal 1 persoon plaatsnemen. Hoeveel verschillende ordeningen van $x = 2$ personen over $n = 4$ stoelen zijn er mogelijk?

Antwoord: Er zijn $\binom{4}{2} = \frac{4 \times 3 \times 2 \times 1}{2 \times 1 \times 2 \times 1} = \frac{24}{4} = 6$ mogelijke ordeningen, namelijk 1100, 1010, 1001, 0110, 0101, en 0011.

Deze binomiaal-coëfficiënten, die het aantal verschillende mogelijke ordeningen aangeven, zijn snel terug te vinden in de zogenaamde Driehoek van Pascal, afgebeeld in Tabel 10.3. Het aantal verschillende ordeningen van $x = 2$ personen over $n = 4$ stoelen vinden we in rij $n = 4$. De bovenste rij is die voor $n = 0$. De vijfde rij is die voor $n = 4$ en we zien daar achtereenvolgens de binomiaal-coëfficiënten voor $x = 0, 1, 2, 3, 4$. Voor $\binom{4}{2}$ vinden we daar de binomiaalcoëfficiënt 6. Iedere coëfficiënt is de som van de twee bovenliggende coëfficiënten³, en iedere coëfficiënt is op te vatten als het aantal mogelijke wegen afdalend van de top van de driehoek naar die cel.

³Dus $\binom{n}{x} = \binom{n-1}{x} + \binom{n-1}{x-1}$, (Weisstein, 2015).

| | | | | | | | | | | |
|----------|---|---|----|----|-----|-----|----|----|---|---|
| ## [3,] | 1 | 2 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 0 |
| ## [4,] | 1 | 3 | 3 | 1 | 0 | 0 | 0 | 0 | 0 | 0 |
| ## [5,] | 1 | 4 | 6 | 4 | 1 | 0 | 0 | 0 | 0 | 0 |
| ## [6,] | 1 | 5 | 10 | 10 | 5 | 1 | 0 | 0 | 0 | 0 |
| ## [7,] | 1 | 6 | 15 | 20 | 15 | 6 | 1 | 0 | 0 | 0 |
| ## [8,] | 1 | 7 | 21 | 35 | 35 | 21 | 7 | 1 | 0 | 0 |
| ## [9,] | 1 | 8 | 28 | 56 | 70 | 56 | 28 | 8 | 1 | 0 |
| ## [10,] | 1 | 9 | 36 | 84 | 126 | 126 | 84 | 36 | 9 | 1 |

De driehoek van Pascal is te vinden links onder de diagonaal van deze matrix.

10.3 Normale kansverdeling

Naarmate de steekproefgrootte n toeneemt, gaat de binomiale kansverdeling minder trapsgewijs verspringen, en wordt de kansverdeling meer vloeiend, zoals te zien in Figuur 10.2.




Figure 10.2: Kansverdeling van een binomiale variabele x met $n=50$ (links) en $n=500$ (rechts) en $p=.38$.

Bij een nog grotere steekproef wordt de kansverdeling een vloeiende lijn. Deze kansverdeling komt zo vaak voor, dat dit de *normale kansverdeling* of 'normale verdeling' wordt genoemd. De verdeling wordt ook wel aangeduid als de Gaussische verdeling (vernoemd naar de wiskundige Carl Friedrich Gauss, 1777–1855), of de 'bell curve' (naar de vorm). Heel veel variabelen volgen bij benadering deze

kansverdeling: geboortegewicht, lichaamslengte, omvang van woordenschat, IQ, inhoud van een pak melk van 1 liter E, duur van een telefoongesprek, enz. enz. Voor al deze variabelen hebben observaties dicht bij het gemiddelde een hoge kans om voor te komen, en observaties die sterk afwijken van het gemiddelde zijn relatief zeldzaam (lage kans).




Figure 10.3: Normale kansverdeling van een variabele x met gemiddelde 0 en standaarddeviatie 1.

De normale kansverdeling van variabele X met gemiddelde μ en standaarddeviatie σ heeft de volgende kenmerken (zie Figuur 10.3):

- de verdeling is symmetrisch rond het gemiddelde μ ,
- de verdeling is asymptotisch, d.w.z. de staarten lopen eindeloos door,
- het gemiddelde, de mediaan en de modus vallen samen,
- de totale oppervlakte onder de curve, d.i. de totale kans op één van de mogelijke uitkomsten, is gelijk aan 1,
- de oppervlakte onder de curve geeft de kans aan op een waarde van X binnen een bepaald interval,
- de buigpunten van de curve (van hol naar bol en v.v.) liggen bij $X = \mu - \sigma$ en $X = \mu + \sigma$,
- ongeveer $2/3$ van de observaties ligt tussen $X = \mu - \sigma$ en $X = \mu + \sigma$ (donkergrijs gebied; $P(-1 < x/\sigma < 1) = .6827$ of 68%) en ongeveer 95% van de observaties ligt tussen -2σ en $+2\sigma$ (donkergrijs plus lichtgrijze

gebieden; $P(-2 < x/\sigma < 2) = .9546$), dit staat bekend als de Empirical Rule.

Een normale kansverdeling met $\mu = 0$ en $\sigma = 1$ wordt aangeduid als de standaard-normale kansverdeling. Zoals we al eerder zagen (§9.8) kunnen we een normaal-verdeelde variabele x standaardiseren, d.w.z. de observaties transformeren naar een standaardscore of z -score: $z = (x - \bar{x})/s$. De kansverdeling in Figuur 10.3 is die van de standaard-normale kansverdeling van Z , oftewel de kansverdeling van $(X - \mu)/\sigma$.

De kansverdeling van een normaal verdeelde variabele X zou je zelf kunnen uitrekenen met behulp van formule (10.7) hieronder. Maar het is handiger om daarvoor een tabel te gebruiken; die staat in Bijlage B. In grafische vorm uitgelegd geven die tabellen je, voor verschillende oppervlakten ofwel kansen p aan de rechter zijde onder de curve, de positieve waarde van Z^* die de linkergrens vormt van die oppervlakte. Dat betekent dus dat je precies de kans p hebt om een waarde te vinden van Z die even groot als of groter dan deze ondergrens Z^* is (mits de variabele inderdaad normaal verdeeld is).

Voorbeeld 10.7: Aan de rechterzijde van Figuur 10.3 zien we een klein wit oppervlak onder de curve. Dit oppervlak geeft de kans weer dat $Z > 2$. Het oppervlak heeft een omvang van 0.0228. De kans om een waarde van $Z > 2$ te vinden is dus 0.0228 ofwel iets minder dan 2.5%. (Tip: relateer deze kans aan de bovengenoemde Empirical Rule).

In Bijlage B vind je gemakshalve niet een maar twee tabellen, elk bestaande uit meerdere kolom-aanduidingen en één rij van cellen. De eerste tabel geeft je, voor verschillende ‘afgeronde’ kansen p (kolommen), de kritieke waarde Z^* (cellen) waarvoor geldt dat de kans p om een waarde van Z te vinden die even groot als of groter dan deze kritieke waarde Z^* is, precies gelijk is aan de waarde p bovenaan de kolom. De tweede tabel werkt net zo, maar dan voor ‘afgeronde’ waarden van Z^* in de cellen, en precieze kansen p in de kolom-aanduidingen.

Wat is de kans p dat $Z > 1$? In de tweede deeltabel, tweede kolom, vinden we $p = 0.1587$. We weten daarmee ook dat $P(Z < 1)$ wel $1 - 0.1587 = 0.8413$ moet zijn. Bovendien weten we dat de verdeling symmetrisch is (zie hierboven), dus weten we dat $P(Z < -1)$ ook .1587 moet zijn. Wat is de kans p dat $Z > 3$ is? In de tweede deeltabel vinden we voor grenswaarde $Z^* = 3$ de overschrijdingskans $p = 0.0013$. Voor een normaal verdeelde variabele Z is er dus een overschrijdingskans $p = 0.0013$ om een waarde van Z te vinden die tenminste drie standaarddeviaties boven het gemiddelde ligt.

Vaak willen we het omgekeerde weten: als we een bepaalde overschrijdingskans kiezen, welke grenswaarde Z^* hoort daar dan bij? Welke grenswaarde onderscheidt de hoogste 5% van de observaties van de onderste 95% ($p = 0.05$)? In de eerste deeltabel vinden we voor overschrijdingskans $p = 0.05$ de grenswaarde $Z^* = 1.645$. Deze grenswaarde, teruggerekend naar de oorspronkelijke variabele, wordt dan vaak aangeduid als het 95e percentiel of ‘P95’ van de verdeling. Wie tenminste deze score heeft behaald, behoort bij de beste 5% en heeft het dus beter gedaan dan 95% van de deelnemers.

Voorbeeld 10.8: Extreme waarden komen bij een normaal-verdeelde variabele per definitie weinig voor. Maar wat is de grens voor een extreme waarde? Laten we aannemen dat we niet meer dan 5% van alle observaties als extreem willen beschouwen. De normale kansverdeling is symmetrisch, dus van die 5% is te verwachten dat de ene helft (2.5%) ligt aan het linker uiteinde van de verdeling, en de andere 2.5% aan de rechterzijde. Welke grenswaarde Z^* correspondeert met deze overschrijdingskans $p = 0.025$?

In Bijlage B nemen we de eerste deeltabel. In de kolom voor overschrijdingskans $p = 0.025$, vinden we grenswaarde $Z^* = 1.960$. Als we een observatie vinden met $Z \geq 1.960$ of met $Z \leq -1.960$ dan beschouwen we dat als een extreme, zeldzame observatie.

Voorbeeld 10.9: Intelligentie wordt uitgedrukt als een IQ-score, een variabele met een normale kansverdeling met $\mu = 100$ en $\sigma = 15$. “Membership of Mensa is open to persons who have attained a score within the upper two percent of the general population on an approved intelligence test that has been properly administered and supervised” (www.mensa.org). Welke IQ-score moet je tenminste behalen om lid te kunnen worden?

Antwoord: Het 98e percentiel van een standaard-normaal verdeelde variabele ligt bij $Z^* = +2.0537$, en dus met $x = \bar{x} + 2.0537s = 100 + 30.8 = 130.8$. Naar boven afgerond moet je dus een IQ-score behalen van 131 punten of hoger.

Voorbeeld 10.10: Verifieer de bovengenoemde Empirical Rule met behulp van Bijlage B.

10.3.1 formules

Als variabele X een normale kansverdeling heeft, met gemiddelde μ en standaarddeviatie σ , dan wordt dat aangegeven als

$$X \sim \mathcal{N}(\mu, \sigma) \quad (10.6)$$

De normale kansverdeling van variabele X met gemiddelde μ en standaarddeviatie σ is


$$P(X) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}. \quad (10.7)$$

De standaard-normale kansverdeling van variabele Z met gemiddelde $\mu = 0$ en standaarddeviatie $\sigma = 1$ is

$$P(Z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \quad (10.8)$$

10.4 Heeft mijn variabele een normale kansverdeling?

Het langste nummer in mijn digitale muziekbibliotheek duurt ongeveer 50 minuten (dat is een klassiek-indiaas muziekstuk, een ‘morning raga’). Een histogram van de duren van alle muzieknummers zie je in Figuur ??.



Dit histogram laat zien dat deze duren duidelijk *niet* een normale kansverdeling volgen: de verdeling is niet symmetrisch, en de onderste staart loopt niet eindeloos door (er zijn geen muzieknummers met negatieve duren).

Ook het gemiddelde $\bar{x} = 4.698$ en standaarddeviatie $s = 5.11$ wijzen op een niet-normale kansverdeling: bij een normale verdeling verwachten we dat slechts $(68/2) + 50 = 84\%$ van de duren langer duurt dan $\bar{x} - s \approx 0$ minuten, maar in werkelijkheid duurt 100% (dus een groter deel dan verwacht) langer dan 0 minuten.

Een veel gebruikte manier om te inspecteren of een variabele X een normale kansverdeling heeft, is om een grafiek te maken met de geobserveerde waarden langs de ene as (hier de horizontale), en de corresponderende z -scores langs de andere as. Zo'n figuur wordt een quantile-quantile-plot of QQ-plot genoemd; de QQ-plot voor de duren in mijn muziekbibliotheek zie je in Figuur 10.4.




Figure 10.4: Quantile-quantile-plot van de duren van muzieknummers in mijn digitale muziekbibliotheek.

Als de duren een normale kansverdeling zouden hebben (normaal zouden zijn verdeeld), dan zouden er een aantal negatieve duren moeten zijn, en er zouden dan veel meer duren tussen 8 en 14 minuten moeten zijn (i.p.v. tussen 8 en 50 minuten). De afwijkingen van de rechte lijn in Figuur 10.4 geven dus aan dat de geobserveerde duren niet een normale kansverdeling volgen, zoals we al zagen in het histogram (Figuur ??).

Er zijn ook verschillende statistische toetsen om te onderzoeken of een variabele een normale kansverdeling heeft. De twee meest gebruikte zijn de Shapiro-Wilk-toets (met toetsingsgrootheid W) voor normaliteit, en de Kolmogorov-Smirnov-toets (met toetsingsgrootheid D) voor normaliteit. Beide toetsen onderzoeken de $H_0: X \sim \mathcal{N}(\bar{X}, s)$ (zie formule (10.6)).

10.4.1 SPSS

Analyze > Descriptive Statistics > Explore...

Selecteer variabele Time (sleep naar Dependent List paneel).

Kies knop Plots, en vink aan **Normality plots with tests**, dat betekent ‘als je een QQ-plot oftewel Normality plot maakt, voer dan ook toetsen op normaliteit uit’. Bevestig met **Continue** en daarna met **OK**. De uitvoer bevat eerst de resultaten van de Shapiro-Wilks-toets en de Kolmogorov-Smirnov toets. Volgens beide toetsen is de kans om deze verdeling te vinden, als H_0 waar is, bijna nul — zie echter de waarschuwing in §@ref(#sec:pgroterdannul)! We verwerpen daarom H_0 en concluderen dat de duren van muzieknnummers niet normaal verdeeld zijn. Na deze toetsresultaten volgt o.a. een QQ-plot.

10.4.2 R

```
itunes <- read.table( file="data/itunes20120511.txt", header=TRUE )
# Size in bytes, Time in ms
qqnorm(itunes$Time/60000, datax=T, plot.it=FALSE) # normally we'd use plot.it=TRUE
# qqline(itunes$Time/60000, datax=T, col="purple", lwd=T) # see QQ-plot above

shapiro.test(itunes$Time/60000)

##
##  Shapiro-Wilk normality test
##
## data:  itunes$Time/60000
## W = 0.50711, p-value < 2.2e-16
```

Volgens deze toets is de kans om deze verdeling te vinden, als H_0 waar is, bijna nul, nl. kleiner dan 2.2×10^{-16} (d.i. kleiner dan het kleinste getal dat het analysepakket hier kan weergeven). We verwerpen daarom H_0 en concluderen dat de duren van muzieknnummers niet normaal verdeeld zijn.

10.5 Wat als mijn variabele niet normaal verdeeld is?

In Deel III zullen we diverse statistische toetsen bespreken. De toetsen die we bespreken in hoofdstukken ?? en ?? en ?? vereisen echter dat de afhankelijke variabele een normale kansverdeling heeft. Als een variabele *niet* een (ongeveer)

normale kansverdeling heeft, dan kan die variabele dus niet zomaar gebruikt worden voor statistische toetsing met de daar behandelde statistische toetsen, of exacter gezegd, de conclusies uit zo'n statistische toetsing zijn dan niet valide. Wat te doen? Er zijn dan twee mogelijkheden.

Ten eerste is het mogelijk om de afhankelijke variabele y te transformeren, d.w.z. dat we er een rekenkundige bewerking op loslaten. Als het goed is, resulteert dat in een variabele y' die wél bij benadering normaal verdeeld is. Veel gebruikte transformaties zijn: logaritmiseren ($y' = \log y$), worteltrekken ($y' = \sqrt{y}$), of inverteren ($y' = 1/y$). Vervolgens wordt de getransformeerde afhankelijke variabele y' gebruikt voor de statistische toetsing. Uiteraard moet je wel controleren of de nieuwe afhankelijke variabele y' inderdaad (bij benadering) normaal verdeeld is. Ook moet je bij de interpretatie van de resultaten van de analyse rekening houden met de uitgevoerde transformatie!

Ten tweede is het soms mogelijk om een andere statistische toets te gebruiken, die niet vereist dat de afhankelijke variabele normaal verdeeld is. Dat worden non-parametrische toetsen genoemd. We gaan er nader op in in de hoofdstukken ?? en ?. Die toetsen hebben wel als nadeel dat ze minder statistische power hebben (voor een bespreking van power, zie hoofdstuk ??): ze zijn minder gevoelig, en vereisen dus grotere steekproeven om een effect vast te stellen.

10.6 Kansverdeling van gemiddelde

In deze paragraaf beschouwen we de muzieknnummers in mijn digitale muziekbibliotheek als een *populatie*. We nemen nu een willekeurige steekproef van $n = 50$ nummers, en bepalen de gemiddelde duur over deze 50 muzieknnummers in de steekproef: stel $\bar{x} = 4.401$ minuten. Opvallend genoeg ligt dit gemiddelde van de steekproef dicht bij het gemiddelde van de populatie ($\mu = 4.615$ minuten, zie hierboven). Deze operatie herhalen we $250\times$: we krijgen zo 250 steekproefgemiddelden. De frequentieverdeling van die 250 steekproefgemiddelden zie je in Figuur 10.5.

Opvallend genoeg vertonen deze *gemiddelden* van (de afhankelijke variabele X in) de steekproeven *wel* een min of meer normale kansverdeling, of de variabele X in de populatie nu wel of niet normaal verdeeld is. Anders gezegd, de kansverdeling van een steekproefgemiddelde benadert *altijd* de normale kansverdeling, ongeacht de kansverdeling van de betreffende variabele in de populatie, indien tenminste de steekproef voldoende groot was. (Dit staat bekend als het Centraal Limiet Theorema). Lees de bovenstaande zinnen nog eens aandachtig door. Als vuistregel geldt dat de omvang van de steekproef, n , tenminste 30 moet zijn. Naarmate de steekproef groter is, wijkt de kansverdeling van de steekproefgemiddelden minder af van de normaalverdeling.

De normale kansverdeling van de steekproefgemiddelden heeft een eigen gemid-

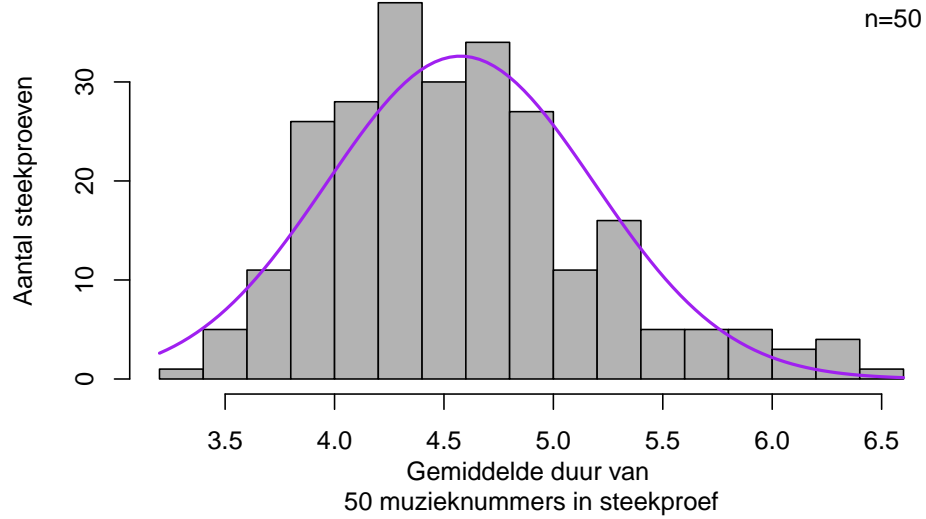


Figure 10.5: Frequentieverdeling van 250 gemiddelden, elk over een willekeurige steekproef van $n = 50$ muzieknummers (de afhankelijke variabele is de duur van een muzieknummer, in minuten). De bijpassende normaalverdeling is aangegeven als een vloeiende curve.

delde, $\mu_{\bar{X}}$, en een eigen standaarddeviatie, $s_{\bar{X}}$. Hiervoor geldt:

$$\mu_{\bar{X}} = \mu_X \quad (10.9)$$

en

$$s_{\bar{X}} = \frac{s}{\sqrt{n}} \quad (10.10)$$

De standaarddeviatie van het gemiddelde, $s_{\bar{X}}$, staat ook bekend als de ‘standard error of the mean’. De steekproefgemiddelden \bar{X} hebben minder spreiding dan de afzonderlijke observaties X , en de gemiddelden variëren ook minder naarmate er gemiddeld is over een grotere steekproef, zoals ook blijkt uit formule (10.10). Je kunt deze standard error of the mean goed beschouwen als de ‘foutmarge’ bij de schatting van het populatiegemiddelde uit het steekproefgemiddelde.

Het bijzondere is nu, dat we niet 250 herhaalde willekeurige steekproeven hoeven te trekken en te analyseren. We weten immers dat de steekproefgemiddelden een normale kansverdeling hebben met $\mu_{\bar{X}} = \mu_X$ en $s_{\bar{X}} = \frac{s}{\sqrt{n}}$. De kansverdeling van het gemiddelde kunnen we dus afleiden uit slechts één steekproef van n observaties, met één steekproefgemiddelde \bar{X} en één standaarddeviatie s (Cumming, 2012). Lees ook deze alinea nog eens aandachtig door.

10.7 Betrouwbaarheidsinterval van het gemiddelde

Zoals hierboven uitgelegd, kunnen we het gemiddelde van de steekproef, \bar{X} , gebruiken als een goede schatting van het onbekende gemiddelde in de populatie, μ . Op grond van het Centraal Limiet Theorema (§10.6) weten we ook dat de gemiddelden van herhaalde steekproeven (van n observaties) een normale verdeling volgen: $\mu_{\bar{X}} \sim \mathcal{N}(\mu_X, \sigma/\sqrt{n})$, en dus dat 95% van deze herhaalde steekproefgemiddelden zullen liggen tussen $\mu_X - 1.96\sigma/\sqrt{n}$ en $\mu_X + 1.96\sigma/\sqrt{n}$. Dit interval wordt het 95%-betrouwbaarheidsinterval genoemd. We weten met 95% betrouwbaarheid dat het populatiegemiddelde μ in dit interval ligt — mits n voldoende groot is, en mits de standaarddeviatie, σ , in de populatie bekend is.

Aan die laatste voorwaarde wordt in de praktijk echter zelden of nooit voldaan. De standaarddeviatie in de populatie is doorgaans niet bekend, en deze σ wordt daarom ook geschat uit de steekproef. We gebruiken de steekproef van n observaties dus niet alleen om μ_X te schatten, maar ook om σ_X te schatten. We mogen dan het betrouwbaarheidsinterval niet meer bepalen op grond van de standaard-normale kansverdeling. In plaats daarvan gebruiken we een aangepaste versie daarvan, de zgn. t -verdeling (Figuur 10.6). Deze kansverdeling van t is iets breder, d.w.z. met een iets lagere top en met iets dikkere staarten, dan de standaard-normale kansverdeling van Z in Figuur 10.3. De gedachte daarbij is dat de schatting van μ wat onzekerder is (dus de kansverdeling is breder) omdat niet alleen μ maar ook de standard error of the mean (s/\sqrt{n}) geschat wordt op grond van de steekproef. In allebei de schattingen kunnen afwijkingen zitten, waardoor iets meer kans is om een steekproefgemiddelde te vinden dat afwijkt van het populatiegemiddelde. Zoals we al zagen wordt de schatting van μ beter naarmate n groter is: de t -verdeling benadert dan de standaard-normale kansverdeling.

Voor de t -verdeling moeten we dus weten hoe groot de steekproef was; deze n bepaalt immers de precieze kansverdeling van t , en daarmee de kritieke waarde t^* . We gaan daar nader op in in §???. We volstaan hier met een uitgewerkt voorbeeld.

Voorbeeld 10.11: Soms wil een onderzoeker weten hoe snel het Nederlands eigenlijk gesproken wordt, en hoe groot de variatie tussen sprekers is in deze spreeknelheid. Deze variabele, spreeknelheid, wordt uitgedrukt als het aantal seconden dat een lettergreep duurt (meestal < 1 seconde). Hoewel (Quené, 2008) schat dat $\mu = 0.220$ s en $\sigma = 0.0225$ s, doen we alsof we deze populatieparameters niet kennen — net als echte onderzoekers, die deze populatieparameters meestal ook niet kennen.




Figure 10.6: Kansverdeling volgens de t -verdeling van een variabele x met gemiddelde 0 en standaarddeviatie 1, voor $n=600$ en $n=6$.

Voor een steekproef van $n = 30$ sprekers vinden we $\bar{x} = 0.215$ en $s = 0.0203$ seconden. Daaruit schatten⁴ we $\hat{\mu} = 0.215$ en $\hat{\sigma} = 0.0203$. Omdat σ niet bekend is, gebruiken we de t -verdeling om het betrouwbaarheidsinterval te bepalen. We gebruiken de t -verdeling voor $n = 30$ en vinden een kritieke waarde $t^* = 2.05$ (zie Bijlage ??, voor $B = 95\%$). Volgens formule (10.11) weten we dan met 95% betrouwbaarheid dat het onbekende populatiegemiddelde μ ligt tussen $\bar{x} - 2.05 \times s_{\bar{x}}$ en $\bar{x} + 2.05 \times s_{\bar{x}}$, oftewel tussen $0.215 - 2.05 \times 0.0037$ en $0.215 + 2.05 \times 0.0037$, oftewel tussen 0.208 en 0.223 seconde.

In Figuur 10.7 zie je de resultaten van een computer-simulatie om dit te illustreren. We hebben $100 \times$ denkbeeldige steekproeven getrokken van $n = 30$ moedertaalsprekers van het Standaard Nederlands, en de spreeknelheid vastgesteld van deze sprekers. Voor elke steekproef hebben we het 95% betrouwbaarheidsinterval getekend. Voor 95 van de 100 steekproeven valt het populatiegemiddelde $\mu = 0.220$ inderdaad binnen het interval, maar voor 5 van de 100 steekproeven ten onrechte niet (deze zijn gemarkeerd langs de rechterkant).

⁴Schattingen van parameters worden aangegeven met een “dakje” erboven.




Figure 10.7: 95%-Betrouwbaarheidsintervallen en steekproefgemiddelden, over 100 gesimuleerde steekproeven ($n=30$) uit een populatie met gemiddelde 0.220 en s.d. 0.0225; zie tekst.

10.7.1 formules

Het tweezijdige $B\%$ betrouwbaarheidsinterval voor het populatie-gemiddelde is

$$\bar{X} \pm t_{n-1}^* \times \frac{s}{\sqrt{n}} \quad (10.11)$$

waarbij t^* met $n - 1$ vrijheidsgraden gevonden wordt met behulp van Bijlage ??, zie §?? voor meer uitleg hierover.

Chapter 11

Samenhang

11.1 Inleiding

Het meeste empirische onderzoek is gericht op het vaststellen van samenhang tussen variabelen. In experimenteel onderzoek gaat het dan primair om de samenhang tussen onafhankelijke en afhankelijke variabelen. In het volgende deel gaan we nader in op diverse manieren om vast te stellen of er een “significant” (beduidend, betekenisvol, niet toevallig) verband bestaat tussen de onafhankelijke en afhankelijke variabele. Daarnaast kan de onderzoeker geïnteresseerd zijn in de onderlinge samenhang tussen meerdere afhankelijke variabelen, bijvoorbeeld de samenhang tussen de oordelen van meerdere beoordelaars (zie ook Hoofdstuk 12).

In quasi-experimenteel onderzoek is het onderscheid tussen onafhankelijke en afhankelijke variabelen doorgaans minder duidelijk. Er worden meerdere variabelen geobserveerd, en de onderzoeker is vooral geïnteresseerd in de onderlinge samenhang tussen die geobserveerde variabelen. Wat is bijvoorbeeld de samenhang tussen de scores voor lezen, rekenen, en wereldoriëntatie in het CITO-onderzoek (zie Tabel 9.1)? In dit hoofdstuk gaan we nader in op de manieren om die samenhang of correlatie uit te drukken in een getal: een correlatie-coëfficiënt. Afhankelijk van de meetniveau's van de variabelen zijn er verschillende correlatie-coëfficiënten, die we verder in dit hoofdstuk zullen behandelen.

Het is raadzaam om altijd eerst een grafische weergave te maken van de samenhang tussen de variabelen, in de vorm van een zgn. *spreidingsdiagram* (ook vaak aangeduid als scattergram of scatterplot), zoals in Figuur 11.1. Ieder punt in dit spreidingsdiagram correspondeert met een leerling (of algemener, met een eenheid van de steekproef). De positie van ieder punt (leerling) wordt bepaald door de geobserveerde waarden van twee variabelen (hier is X score bij leestoets, Y is score bij rekentoets). Zo'n spreidingsdiagram helpt om een eventueel verband te

interpreteren, en om te inspecteren of de observaties wel voldoen aan de randvoorwaarden om een correlatie te berekenen uit die observaties. Kijk in ieder geval naar (a) de aanwezigheid van een eventueel verband, (b) de vorm van dat verband (lineair, exponentieel, ...), (c) eventuele uitbijters (extreme observaties, zie §9.4.2), en (d) de verdeling van de twee variabelen, zie §9.7.




Figure 11.1: Spreidingsdiagram van de scores van een leestoets en een reken-toets; zie tekst.

Dit spreidingsdiagram laat zien (a) dat er een verband bestaat tussen de scores bij lezen en bij rekenen. Het verband is (b) bij benadering lineair, d.w.z. te beschrijven als een rechte lijn; we komen daar op terug in §11.3. Het verband helpt ons ook om de spreiding in de twee variabelen te verklaren. Immers, de spreiding in de rekenscores is voor een deel te begrijpen of te verklaren uit de spreiding in de leestoets: leerlingen die een relatief goede score behalen bij lezen, doen dat ook bij rekenen. De observaties van de twee variabelen verschaffen dus niet alleen informatie over die twee variabelen zelf, maar bovendien over de samenhang tussen die variabelen. In dit spreidingsdiagram zien we overigens ook (c) dat de hoogste leesscore een uitbijter vormt (zie ook Fig.9.3); zulke uitbijters kunnen onevenredig grote invloed hebben op het gevonden verband.

11.2 Pearson product-moment-correlatie

De Pearson product-moment-correlatiecoëfficiënt wordt aangeduid met symbool r (in het geval van twee variabelen). Deze coëfficiënt is te gebruiken als beide variabelen geobserveerd zijn op het interval-meetniveau (§4.4), en als beide variabelen bij benadering normaal-verdeeld zijn (§10.3). De berekening doen we tegenwoordig per computer.

Voor de observaties in het spreidingsdiagram in Fig.11.1 vinden we een correlatie van $r = +.79$. De correlatie-coëfficiënt is een getal dat per definitie ligt tussen -1 en $+1$. Een positieve correlatiecoëfficiënt wijst op een positief verband: een grotere waarde van X correspondeert met een grotere waarde van Y . Een negatieve coëfficiënt wijst op een negatief verband: een grotere waarde van X correspondeert met een kleinere waarde van Y . Een waarde van r dicht bij nul wijst op een zwak of afwezig verband: de spreiding in X heeft niets te maken met de spreiding in Y ; er is geen of alleen zwakke correlatie. Een correlatie van $.4 < r < .6$ (of $-.6 < r < -.4$) noemen we middelmatig. Een correlatie van $r > .6$ (of $r < -.6$) wijst op een sterke samenhang. Als $r = 1$ (of $r = -1$) dan liggen alle observaties precies op een rechte lijn. Figuur 11.2 toont meerdere spreidingsdiagrammen met de bijbehorende correlatiecoëfficiënten.




Figure 11.2: Meerdere spreidingsdiagrammen van observaties met bijbehorende correlatiecoëfficiënten.

De correlatie die we zien tussen de scores van de twee variabelen (zoals $r = .79$ tussen scores bij leestoets en rekentoets, Fig.11.1) zou ook het gevolg kunnen zijn van toevallige variaties in de observaties. Het is immers mogelijk dat de

leerlingen met een goede score op de leestoets, zuiver door toeval, ook een goede score op de rekentoets hebben behaald — ook als er in de populatie eigenlijk *niet* samenhang is tussen de twee variabelen. De onbekende correlatie in de populatie duiden we aan met de griekse letter ρ (“rho”); het is dus ook mogelijk dat $\rho = 0$. Ook als $\rho = 0$ is het mogelijk om $n = 10$ leerlingen in de steekproef te hebben die hoge scores op het ene onderdeel *toevallig* combineren met hoge scores op het andere onderdeel (en om toevallig niet leerlingen in de steekproef te hebben die hoge scores op het ene onderdeel combineren met lage scores op het andere onderdeel). We kunnen schatten wat de kans p is om deze correlatie van $r = 0.79$ of sterker te vinden in een steekproef van $n = 10$ leerlingen, indien de samenhang in de populatie eigenlijk nihil is (d.i. indien $\rho = 0$). Deze kans p noemen we de *significantie* van de correlatiecoëfficiënt; we komen in Hoofdstuk ?? uitgebreider terug op dit begrip ‘significantie’. Daarop vooruitlopend: als deze kans p kleiner is dan .05, dan nemen we aan dat de gevonden correlatie r *niet toevallig*, d.i. *significant* is. Vaak zien we een kleine kans p bij een sterke correlatie r . De correlatiecoëfficiënt r geeft de richting en sterkte van het verband aan, en de significantie p geeft de kans aan om dit verband bij toeval te vinden als $\rho = 0$ in de populatie. We rapporteren deze bevindingen als volgt¹:

Voorbeeld 11.1: De scores van de $n = 10$ leerlingen op de deoltoetsen van de CITO-toets in Tabel 9.1 laten een sterke correlatie zien tussen de scores bij de onderdelen Lezen en Rekenen: Pearson $r = 0.79$, $p = .007$. Leerlingen met een relatief hoge score bij het ene onderdeel behalen in het algemeen ook een relatief hoge score bij het andere onderdeel.

In veel onderzoeken zijn we geïnteresseerd in de correlaties tussen meer dan twee variabelen. Die correlaties tussen variabelen worden dan vaak gerapporteerd in een zgn. correlatiematrix zoals Tabel 11.1, dat is een tabel waar de correlaties vermeld worden van alle paren van correlaties (Eng. ‘pairwise correlation matrix’).

¹Als de gevonden correlatie r *niet* significant is, dan kan die dus ook toevallig zijn, en dan laten we een interpretatie van de samenhang dus achterwege. We vermelden in ons verslag dan wel de gevonden correlatiecoëfficiënt en de gevonden significantie daarvan.

Table 11.1: Correlaties tussen de drie onderdelen van de CITO-toets, zoals samengevat in Tabel 9.1, met bijbehorende significantie-niveau tussen haakjes.

| | Lezen | Rekenen | Wereldoriëntatie |
|------------------|--------------|--------------|------------------|
| Lezen | 1.00 | | |
| Rekenen | 0.79 (.007) | 1.00 | |
| Wereldoriëntatie | -0.51 (.131) | -0.01 (.970) | 1.00 |

In deze matrix is alleen de onderste (linker) helft van de volledige matrix weergegeven. Dat is ook voldoende, want de cellen zijn gespiegeld rond de diagonaal: de correlatie tussen Lezen (kolom 1) en Rekenen (rij 2) is immers hetzelfde als de correlatie tussen Rekenen (rij 2) en Lezen (rij 1). De correlatiematrix bevat in de cellen op de diagonaal altijd de waarde 1.00, omdat een variabele altijd perfect met zichzelf correleert. We rapporteren deze bevindingen als volgt:

Voorbeeld 11.2: De paarsgewijze correlaties tussen scores van de $n = 10$ leerlingen op de drie deoltoetsen van de CITO-toets zijn samengevat in Tabel 11.1. We zien een sterke correlatie tussen de scores bij de onderdelen Lezen en Rekenen: leerlingen met een relatief hoge score bij het onderdeel Lezen behalen in het algemeen ook een relatief hoge score bij het onderdeel Rekenen. De overige correlaties waren niet significant.

11.2.1 Formules

De eenvoudigste formule voor de Pearson product-moment-correlatiecoëfficiënt r maakt gebruik van de standaard-normaal-scores die we al eerder gebruikt hebben (§9.8):

$$r_{XY} = \frac{\sum z_X z_Y}{n - 1} \quad (11.1)$$

Net als bij het berekenen van de variantie (formule (9.3)) delen we weer door $(n - 1)$ om een schatting te maken van de samenhang in de populatie.

11.2.2 SPSS

Voor Pearson's product-moment-correlatiecoëfficiënt:

Analyze > Correlate > Bivariate...

Kies **Pearsons** correlatiecoëfficiënt, vink aan: **Flag significant correlations**. Bevestig met **OK**. De resulterende uitvoer (tabel) voldoet niet aan de stijl-eisen; je moet de gegevens dus overnemen in of omzetten naar een eigen tabel die daar wel aan voldoet.

11.2.3 R

```
cito <- read.table(file="data/cito.txt", header=TRUE)
cor( cito[,2:4] ) # correlatie-matrix van kolommen 2,3,4
```

```
##                Lezen    Rekenen Wereldoriëntatie
## Lezen          1.000000  0.74921033      -0.50881738
## Rekenen        0.7492103  1.00000000       0.06351024
## Wereldoriëntatie -0.5088174 0.06351024      1.00000000
```

```
with( cito, cor.test( Lezen, Rekenen ) )
```

```
##
##  Pearson's product-moment correlation
##
## data:  Lezen and Rekenen
## t = 3.1994, df = 8, p-value = 0.01262
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
##  0.2263659 0.9368863
## sample estimates:
##          cor
## 0.7492103
```

11.3 Regressie

Het meest eenvoudige verband dat we kunnen onderscheiden en beschrijven is een lineair verband, d.w.z. een rechte lijn in het spreidingsdiagram (zie Fig.11.2). Deze rechte lijn geeft aan welke waarde van Y_i voorspeld wordt, op basis van

de waarde van X_i . Deze voorspelde waarde van Y_i wordt genoteerd als \widehat{Y}_i (“Y-hat”). De beste voorspelling \widehat{Y}_i is gebaseerd op de waarde van X_i en op het lineaire verband tussen X en Y :

$$\widehat{Y}_i = a + bX_i \quad (11.2)$$

De rechte lijn wordt beschreven met twee parameters, nl. het begingetal a (Eng. ‘intercept’) en de hellingscoëfficiënt b (Eng. ‘slope’)². De rechte lijn die het lineaire verband beschrijft wordt ook aangeduid als de “regressielijn”; we proberen immers om de geobserveerde waarden van Y te herleiden tot deze lineaire functie van de waarden van X .

Het verschil tussen de geobserveerde waarde Y en de voorspelde waarde \widehat{Y} ($Y - \widehat{Y}$) wordt het *residu* genoemd (symbool e). Anders gezegd, de geobserveerde waarde wordt beschouwd als de optelsom van twee componenten, nl. de voorspelde waarde en het residu:

$$Y = \widehat{Y} + e \quad (11.3)$$

$$= a + bX + e \quad (11.4)$$

Bovenstaande gedachtengang wordt geïllustreerd in het spreidingsdiagram in Figuur 11.3. De stippellijn geeft het lineaire verband aan tussen de twee toetsen:

$$\widehat{\text{Rekenen}} = 12.97 + 0.52 \times \text{Lezen} \quad (11.5)$$

Deze stippellijn geeft dus aan wat de voorspelde waarde \widehat{Y} is voor iedere waarde van X . Voor de tweede leerling met $X_2 = 32$ voorspellen we zo $\widehat{Y}_2 = 12.97 + (0.52)(32) = 29.61$ (voorspelde waarde, groene lijnstuk). Voor alle observaties die niet precies op deze regressielijn liggen (stippellijn), is er een afwijking tussen de voorspelde score \widehat{Y} en de geobserveerde score Y (residu, rode lijnstuk). Voor de tweede leerling is deze afwijking $e_2 = (Y_2 - \widehat{Y}_2) = (36 - 29.61) = 6.49$ (residu, rode lijnstuk).

Zoals gezegd worden de geobserveerde waarden van Y beschouwd als de optelsom van twee componenten, de voorspelde waarde \widehat{Y} (groen) en het residu e (rood). Op dezelfde wijze kan ook de totale *variantie* van Y beschouwd worden als de optelsom van de twee *varianties* van deze componenten:

$$s_Y^2 = s_{\widehat{Y}}^2 + s_e^2 \quad (11.6)$$

Van de totale variantie s_Y^2 van Y is dus het ene deel ($s_{\widehat{Y}}^2$) te herleiden tot c.q. te verklaren uit de variantie van X , via het lineaire verband beschreven

²In schoolboeken wordt deze vergelijking ook wel beschreven als $Y = aX + b$, met a als hellingscoëfficiënt en b als begingetal; we houden ons hier echter aan de internationaal gangbare notatie.




Figure 11.3: Spreidingsdiagram van de scores van een leestoets en een reken-toets. In het diagram is tevens aangegeven de regressielijn (stippellijn), de voorspelde waarde (groen) en residu (rood) van de rekentoets voor leerling 2, de gemiddelden (plus-symbool), en markeringen voor leerling 2 en 3; zie tekst.

met parameters a en b (zie formule (11.2)), en het andere deel (s_e^2) is niet te herleiden of te verklaren. Dat tweede deel, de niet-voorspelde variantie van de residuen, wordt ook wel de ‘residuele variantie’ of ‘ruis’ genoemd.

Als we Y goed kunnen voorspellen uit X , d.w.z. als de Pearson product-moment-correlatiecoëfficiënt r hoog is (Fig. 11.2, links), dan zijn de residuen e dus relatief klein, de observaties liggen dicht rond de regressielijn in het spreidingsdiagram, en dan is dus ook de residuele variantie s_e^2 relatief gering. Omgekeerd, als we Y *niet* goed kunnen voorspellen uit X , d.w.z. als de correlatiecoëfficiënt r relatief laag is (Fig. 11.2, rechts), dan zijn de residuen e dus relatief groot, de observaties liggen wijd verspreid rond de regressielijn in het spreidingsdiagram, en dan is dus ook de residuele variantie s_e^2 relatief groot. Het kwadraat van de Pearson product-moment-correlatiecoëfficiënt r geeft aan wat de relatieve omvang is van de twee variantie-componenten, ten opzichte van de totale variantie:

$$r^2 = \frac{s_Y^2}{s_Y^2} \quad (11.7)$$

$$= 1 - \frac{s_e^2}{s_Y^2} \quad (11.8)$$

Deze grootte r^2 wordt ook wel aangeduid als de “proportie verklaarde variantie” of als de “determinatie-coëfficiënt”.

De waarden van de lineaire parameters a en b in formule (11.2) worden zo gekozen dat de verzamelde residuen zo klein mogelijk zijn, d.w.z. dat de residuele variantie s_e^2 zo klein mogelijk is (“least squares fit”), en dus r^2 zo groot mogelijk (zie §11.3.1). Op die manier vinden we een rechte lijn die het beste past bij de observaties van X en Y .

Een lineaire regressie kan worden gerapporteerd als volgt:

Voorbeeld 11.3: Uit een lineaire-regressie-analyse blijkt dat de score bij Rekenen samenhangt met die bij Lezen: $b = 0.51, r = .79, p_r = .007$, over $n = 10$ leerlingen. Dit lineaire regressiemodel verklaart $r^2 = .51$ van de totale variantie in de rekencores (de residuele standaarddeviatie is $s_e = \sqrt{82.803/(n - 1 - 1)} = 3.217$).

11.3.1 Formules

Bij lineaire regressie van y op x proberen we de coëfficiënten a en b zodanig te schatten dat (het kwadraat van) de afwijking tussen de voorspelde waarde \hat{y} en

de geobserveerde waarde y zo klein mogelijk is, m.a.w. dat het kwadraat van de residuen $(y - \hat{y})$ zo klein mogelijk is. Dit wordt de “least squares” methode genoemd (zie <http://www.itl.nist.gov/div898/handbook/pmd/section4/pmd431.htm>).

De beste schatting voor b is

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

De beste schatting voor a is

$$a = \bar{y} - b\bar{x}$$

11.3.2 SPSS

Voor lineaire regressie:

Analyze > Regression > Linear...

Kies **Dependent variable**: Rekenen en kies **Independent variable**: Lezen. Onder de knop **Statistics**, vink aan **Model fit**, vink aan **R squared change**, kies **Estimates**, en daarna **Continue**.

Onder de knop **Plot**, vink aan **Histogram** en vink ook aan **Normal probability plot**; deze keuzes zijn vereist om een numerieke(!) samenvatting te krijgen over de residuals.

Onder de knop **Options**, kies **Include constant** om ook de constante coëfficiënt a te laten berekenen. Bevestig alle keuzes met **OK**.

De resulterende uitvoer omvat meerdere tabellen en figuren; deze kan je niet rechtstreeks overnemen in je verslag. De tabel getiteld *Model Summary* bevat de correlatie-coëfficiënt, hier aangeduid met hoofdletter $R = .749$.

De tabel getiteld *Coefficients* bevat de regressie-coëfficiënten. De regel met aanduiding (**Constant**) vermeldt coëfficiënt $a = 13.25$; de regel getiteld **Lezen** vermeldt coëfficiënt $b = 0.51$.

De tabel getiteld *Residual Statistics* geeft informatie over zowel de voorspelde waarden als de residuen. Controleer of het gemiddelde van de residuen inderdaad nul is. In deze tabel zien we ook (regel 2, kolom 4) dat de standaarddeviatie van de residuen 3.212 is.

11.3.3 R

```
summary( m1 <- lm( Rekenen~Lezen, data=cito ) )
```

```
##
## Call:
## lm(formula = Rekenen ~ Lezen, data = cito)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -5.5332 -1.1167 -0.5332  1.7168  6.3384
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.2507     4.4910   2.950  0.0184 *
## Lezen         0.5128     0.1603   3.199  0.0126 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.406 on 8 degrees of freedom
## Multiple R-squared:  0.5613, Adjusted R-squared:  0.5065
## F-statistic: 10.24 on 1 and 8 DF,  p-value: 0.01262
```

Het command `lm` specificeert een lineair regressiemodel, met **Rekenen** als afhankelijke variabele en **Lezen** als predictor. Dit model wordt bewaard als een object genaamd `m1`, en dat wordt meteen weer gebruikt als argument (invoer) om te rapporteren. In die rapportage van model `m1` wordt de constante coëfficiënt a aangeduid als **Intercept**.

```
sd( resid( m1 ) ) # s.d. van residuen volgens `m1`
```

```
## [1] 3.211533
```

11.4 Invloedrijke observaties

In de vorige paragraaf zagen we dat in een correlatie-analyse of een regressie-analyse gestreefd wordt naar een minimale residuele variantie. Eerder zagen we al ook dat uitbijters of extreme observaties, per definitie, relatief veel bijdragen aan de variantie. Bij elkaar leidt dat ertoe, dat uitbijters of extreme observatie grote invloed kunnen hebben op de hoogte van de correlatie, of op de gevonden regressie (het gevonden lineaire verband). Dat is ook te zien in Fig.11.3. Leerling 3 heeft een extreem hoge score bij Lezen (zie ook Fig.9.3). Als we deze leerling 3 buiten beschouwing laten dan zou er niet veel veranderen aan de correlatie ($r_{-3} = .79$) maar wel aan de helling van de regressielijn ($b = 0.84$, ruim anderhalf keer zo groot als met leerling 3). Deze observatie “trekt” dus hard aan de regressielijn, juist omdat deze observatie een extreme waarde heeft voor X en daardoor veel invloed heeft.

Ook niet-extreme observaties kunnen toch van grote invloed zijn op de correlatie en regressie, als ze ver verwijderd zijn van de regressielijn en dus een grote bijdrage leveren aan de residuele variantie. Ook dat is te zien in Fig.11.3. Leerling 2 heeft geen extreme scores, maar heeft wel het grootste residu. Als we deze leerling 2 buiten beschouwing laten dan zou de correlatie aanzienlijk hoger zijn ($r_{-2} = .86$) maar de helling van de regressielijn zou slechts weinig veranderen ($b = 0.45$).

Bij een correlatie-analyse of regressie-analyse moet je daarom altijd een spreidingsdiagram maken en bestuderen, om te kijken in hoeverre de resultaten beïnvloed zijn door een of enkele observaties. Let daarbij speciaal op observaties die ver verwijderd zijn van het gemiddelde, voor elk van beide variabelen, en op observaties die ver verwijderd zijn van de regressielijn.

11.5 Spearmans rangorde-correlatie

De beide variabelen waarvan we de correlatie willen onderzoeken, zijn niet altijd uitgedrukt op het interval-meetniveau (§4.4), of de onderzoekers willen of kunnen niet aannemen dat de beide variabelen bij benadering normaal-verdeeld zijn (§10.3). In dat geval is de product-moment-correlatie minder geschikt om de samenhang te kwantificeren. Indien de gegevens wel op ordinaal meetniveau zijn uitgedrukt, dan kunnen we wel andere correlatiecoëfficiënten gebruiken om de samenhang uit te drukken: Spearmans rangorde-correlatiecoëfficiënt (r_s) en Kendalls τ (de griekse letter “tau”). Deze beide coëfficiënten zijn gebaseerd op de rangordening van de observaties; deze correlaties kunnen we dus altijd uitrekenen als we de observaties kunnen ordenen. Ook deze berekening doen we tegenwoordig per computer. In dit hoofdstuk bespreken we alleen de Spearmans rangorde-correlatiecoëfficiënt.

De Spearman rangorde-correlatiecoëfficiënt is gelijk aan de Pearson product-moment-correlatiecoëfficiënt toegepast op de *rangnummers* van de observaties. We zetten iedere observatie van een variabele om naar het volgorde-nummer, van de kleinste geobserveerde waarde (volgnummer 1) naar de grootste geobserveerde waarde (volgnummer n). Als twee of meer observaties dezelfde waarde hebben, dan krijgen ze ook hetzelfde (gemiddelde) rangnummer. In Tabel 11.2 zie je de rangnummers van de scores voor Lezen en Rekenen, hier geordend volgens de rangnummers voor Lezen.

Table 11.2: Rangnummers van de scores van 10 leerlingen op onderdelen van een toets, zoals samengevat in Tabel 9.1, met verschil v_i tussen de twee rangnummers per leerling.

| Leerling | 1 | 9 | 6 | 4 | 10 | 8 | 5 | 7 | 2 | 3 |
|----------|---|---|---|-----|-----|---|---|-----|----|----|
| Lezen | 1 | 2 | 3 | 4.5 | 4.5 | 6 | 7 | 8 | 9 | 10 |
| Rekenen | 2 | 4 | 1 | 4 | 6.5 | 4 | 8 | 6.5 | 10 | 9 |

| | | | | | | | | | | |
|----------------|----|----|---|-----|----|---|----|-----|----|---|
| Leerling | 1 | 9 | 6 | 4 | 10 | 8 | 5 | 7 | 2 | 3 |
| verschil v_i | -1 | -2 | 1 | 0.5 | -2 | 2 | -1 | 1.5 | -1 | 1 |

De ordening in Tabel 11.2 maakt in één oogopslag duidelijk dat de drie leerlingen met de laagste score voor Lezen (nrs. 1, 9, 6) ook bijna de laagste scores voor Rekenen behaalden. Dat wijst op een positief verband. De twee beste lezers (nrs. 2 en 3) zijn ook de twee beste rekenaars. Ook dat wijst op een positief verband. Er is echter geen sprake van een perfect positief verband (dus hier $r_s < 1$), want dan zouden de beide rangordeningen perfect overeen komen.

Bedenk zelf hoe Tabel 11.2 er uit zou zien, als er een perfect negatief verband zou zijn ($r_s = -1$) tussen de scores bij Lezen en Rekenen, en hoe de tabel er uit zou zien als er geen enkel verband zou zijn ($r_s = 0$) tussen deze scores.

11.5.1 Formules

De samenhang tussen de rangnummers van twee variabelen wordt uitgedrukt in de Spearman rangorde-correlatiecoëfficiënt:

$$r_s = 1 - \frac{6 \sum v_i^2}{n(n^2 - 1)} \quad (11.9)$$

waarin v_i staat voor het verschil in rangnummers op beide variabelen voor respondent i . De breuk in deze formule wordt groter, en r_s wordt dus kleiner, naarmate de verschillen tussen de rangnummers groter zijn. Deze formule is echter alleen bruikbaar als er geen “ties” (gedeelde rangnummers) zijn in de variabelen; voor de gegevens in Tabel 11.2 met “ties” in beide variabelen moeten we een andere formule gebruiken.

Zoals blijkt is de Spearmans rangorde-correlatie r_s niet gelijk aan de Pearson product-momentcorrelatie r bij deze geobserveerde scores. Indien voldaan wordt aan de voorwaarden voor de Pearson coëfficiënt, dan geeft deze Pearson product-moment-correlatiecoëfficiënt een betere schatting van de samenhang dan de Spearman rangorde-correlatiecoëfficiënt. Maar als er *niet* aan die voorwaarden voldaan wordt, dan is de Spearman coëfficiënt weer te prefereren. De Spearman coëfficiënt is onder andere minder gevoelig voor invloedrijke extreme observaties — dergelijke uitschieters leggen immers minder gewicht in de schaal, nadat we de ruwe scores vervangen hebben door de rangnummers.

11.5.2 SPSS

Voor Spearmans rangorde-correlatiecoëfficiënt:

```
Analyze > Correlate > Bivariate...
```

Kies `Spearman` rangorde-correlatiecoëfficiënt, vink aan: `Flag significant correlations`. Bevestig met `OK`. De resulterende uitvoer (tabel) voldoet niet aan de stijl-eisen; je moet de gegevens dus overnemen in of omzetten naar een eigen tabel die daar wel aan voldoet, en rapporteren volgens de gebruikelijke conventies voor correlatie-analyse.

11.5.3 R

```
with(cito, cor.test( Lezen,Rekenen, method="spearman" ) )
```

```
## Warning in cor.test.default(Lezen, Rekenen, method = "spearman"): Cannot
## compute exact p-value with ties
```

```
##
## Spearman's rank correlation rho
##
## data: Lezen and Rekenen
## S = 25.229, p-value = 0.00198
## alternative hypothesis: true rho is not equal to 0
## sample estimates:
## rho
## 0.8470988
```

11.6 Phi

De beide variabelen waarvan we de samenhang willen onderzoeken, zijn zelfs niet altijd uitgedrukt op het ordinale meetniveau (Hoofdstuk 4). Zelfs als beide variabelen alleen op nominaal niveau gemeten zijn, dan kan er nog een correlatie berekend worden, nl. de phi-correlatiecoëfficiënt (symbool r_{Φ} , met griekse letter “Phi”). Deze correlatiecoëfficiënt is ook bruikbaar als één van de twee variabelen op nominaal niveau gemeten is, en de andere op ordinaal niveau.

Laten we bij ons voorbeeld met de CITO-toets aannemen dat de eerste vijf leerlingen uit een grote stad komen, en de laatste vijf van het platteland. De herkomst van de leerling vormt een nominale variabele, met 2 categorieën, hier willekeurig aangeduid als 1 resp. 0 (zie §4.2; een nominale variabele met precies 2 categorieën wordt ook een binomiale of dichotome variabele genoemd). We vragen ons nu af of er enige samenhang is tussen de herkomst van een leerling en de score bij het onderdeel Rekenen van de CITO-toets. De tweede variabele is van interval-niveau. We zetten deze om naar een nominaal meetniveau. Dat kan op vele manieren, en het is aan de onderzoeker om daarbij een verstandige keuze te maken. Wij kiezen hier voor de vaak gebruikte ‘mean split’: de ene categorie

(laag, code 0) bestaat uit scores kleiner dan of gelijk aan het gemiddelde (§9.3.1), en de andere categorie uit scores groter dan het gemiddelde (hoog, code 1). De aantallen leerlingen in elk van de 2×2 categorieën vatten we samen in een kruistabel (Tabel 11.3).

Table 11.3: Kruistabel van $n = 10$ leerlingen, onderverdeeld naar herkomst (stad=1, platteland=0) en naar categorie van score bij het onderdeel Rekenen van een CITO-toets ('mean split', laag=0, hoog=1), met letter-aanduiding voor de aantallen observaties; zie tekst.

| herkomst | laag (0) | hoog (1) | totaal |
|----------------|----------|----------|--------------|
| platteland (0) | 5 (A) | 0 (B) | 5 (A+B) |
| stad (1) | 2 (C) | 3 (D) | 5 (C+D) |
| totaal | 7 (A+C) | 3 (B+D) | 10 (A+B+C+D) |

De nominale correlatiecoëfficiënt r_Φ is gelijk aan de Pearson product-moment-correlatiecoëfficiënt als we die zouden toepassen op de binomiale codes (0 en 1) van de observaties. Alle 5 de leerlingen van het platteland hebben een score bij Rekenen gelijk aan of lager dan gemiddeld ($\bar{y} = 27.2$); van de leerlingen uit de stad hebben er 2 een score (gelijk aan of) lager dan gemiddeld. Er is dus samenhang tussen de binomiale codes van de rijen (herkomst) en die van de kolommen (score-categorieën) in Tabel 11.3. Die samenhang wordt gekwantificeerd in de correlatiecoëfficiënt $r_\Phi = 0.65$ voor deze gegevens.

11.6.1 Formules

De nominale correlatiecoëfficiënt r_Φ wordt berekend als volgt, waarbij de letters verwijzen naar de aantallen in de cellen van een kruistabel (zie Tabel 11.3):

$$r_\Phi = \frac{(AD - BC)}{\sqrt{(A+B)(C+D)(A+C)(B+D)}} \quad (11.10)$$

Voor het hierboven besproken voorbeeld vinden we dan

$$r_\Phi = \frac{(15 - 0)}{\sqrt{(5)(5)(7)(3)}} = \frac{15}{22.91} = 0.65$$

11.6.2 SPSS

De dataset `cito` bevat al een variabele `StadPlat` die de herkomst van de leerlingen aangeeft. Maar volledigheidshalve leggen we toch uit hoe je zo'n variabele zelf kunt construeren.

Transform > Recode into different variables...

Kies **Leerling** als oude variabele en vul als nieuwe naam **StadPlat2** in voor de nieuwe variabele. Geef aan dat de oude waarden in **Range** van 1 t/m 5 (oud) omgezet moeten worden naar de nieuwe waarde 1, en evenzo dat leerlingen 6 t/m 10 de nieuwe waarde 0 moeten krijgen voor de nieuwe variabele **StadPlat**.

Voor **Rekenen** is het wat ingewikkelder. Je moet eerst je eerdere omzettingsregels verwijderen (die betrekking hadden op **StadPlat**). Maak dan op dezelfde wijze weer een nieuwe variabele, genaamd **Rekenen2**. Alle waarden vanaf de laagste waarde tot het gemiddelde (27.2) worden omgezet naar nieuwe waarde 0 voor die nieuwe variabele. Alle waarden vanaf het gemiddelde (27.2) tot de hoogste waarde worden omgezet naar nieuwe waarde 1.

Na dit voorbereidend werk kunnen we eindelijk r_Φ gaan berekenen.

Analyze > Descriptives > Crosstabs...

Selecteer de variabelen **StadPlat2** (in “Rows” paneel) en **Reken2** (in “Columns” paneel) voor kruistabel 11.3.

Kies **Statistics...** en vink optie **Phi and Cramer's Vaan!**

Bevestig eerst met **Continue** en daarna nogmaals met **OK**.

11.6.3 R

De dataset **cito** bevat al een variabele **StadPlat** die de herkomst van de leerlingen aangeeft. Maar volledigheidshalve laten we toch zien hoe je zo'n variabele zelf kunt construeren.

```
StadPlat2 <- ifelse( cito$Leerling<6, 1, 0) # 1=stad, 0=plat
Reken2 <- ifelse( cito$Rekenen>mean(cito$Rekenen), 1, 0 ) # 1=hoog, 0=laag
```

Maak een nieuwe variabele **Reken2**, met de waarde 1 indien de score voor **Rekenen** groter is dan het gemiddelde, en anders de waarde 0.

Ook in R maken we eerst een kruistabel (Tabel 11.3) en daarna berekenen we de r_Φ over die kruistabel.

```
print( table(StadPlat2,Reken2) -> citokruistabel ) # maak en bewaar en toon kruistabel
```

```
##           Reken2
## StadPlat2 0 1
##           0 5 0
##           1 2 3
```


```
if (require(psych)) { # voor psych::phi
  phi(citokruistabel) # eerder gemaakte kruistabel is hier invoer!
}
```

```
## [1] 0.65
```

11.7 Tenslotte

Bij het einde van dit hoofdstuk willen we nog eens benadrukken dat een samenhang of correlatie tussen twee variabelen niet noodzakelijkerwijs betekent dat er ook een causaal verband is tussen de variabelen, m.a.w. een samenhang betekent niet dat de ene variabele (bijv. behandeling) de oorzaak is en de andere variabele (bijv. genezing) het gevolg daarvan. De gangbare zegswijze daarvoor is “correlation does not imply causation,” zie ook Voorbeeld 6.1 (Hoofdstuk 6) en bijgaande Figuur 11.7.

```
\begin{figure}
```



```
\caption{Correlation does not imply causation, ontleend met toestemming aan
http://xkcd.com/552.} \end{figure}
```


Chapter 12

Betrouwbaarheid

12.1 Inleiding

In Hoofdstuk 5 hebben we het onder andere gehad over construct-validiteit, de afstand tussen het bedoelde (theoretische) concept of construct enerzijds, en de onafhankelijke of afhankelijke variabele anderzijds. In dit hoofdstuk gaan we in op een ander zeer belangrijk aspect van de afhankelijke variabele, nl. de *betrouwbaarheid*. Deze betrouwbaarheid kan worden geschat op basis van de samenhang of correlatie tussen observaties van hetzelfde construct. We zullen ook ingaan op de relaties tussen betrouwbaarheid en constructvaliditeit.

Vaak worden validiteit en betrouwbaarheid in één adem genoemd, en in opeenvolgende hoofdstukken besproken. Daar is wat voor te zeggen, want beide begrippen gaan over hoe je je variabelen definieert en operationaliseert. Toch hebben we hier gekozen voor een andere volgorde. Betrouwbaarheid komt pas aan bod nadat we samenhang besproken hebben (Hoofdstuk 11), omdat betrouwbaarheid gebaseerd is op de samenhang of correlatie tussen observaties.

12.2 Wat is betrouwbaarheid?

Een betrouwbaar persoon is stabiel en voorspelbaar: wat hij of zij vandaag doet is consistent met wat hij of zij vorige week deed, je kunt op deze persoon vertrouwen — in tegenstelling tot een onbetrouwbaar persoon, die instabiel is en zich onvoorspelbaar gedraagt. Volgens *Van Dale* is *betrouwbaarheid* “...de mate waarin iets of iem. te betrouwen of geloofwaardig is”. Betrouwbare metingen kunnen de basis vormen voor een “justified true belief” (zie §2.4); onbetrouwbare metingen daarentegen zijn per definitie niet waard om geloof aan te hechten.

Metingen vertonen altijd enige mate van fluctuatie of variatie of inconsistentie.

Die variabiliteit kan ten dele worden toegeschreven aan de variatie in het gedrag dat gemeten wordt. Immers, zelfs als we hetzelfde construct meten bij dezelfde persoon, dan nog zien we variatie ten gevolge van de momentane mentale of fysieke toestand van de proefpersoon, die nu eenmaal fluctueert.

Bovendien is er variatie in het gebruikte meet-instrument (thermometer, vragenlijst, sensor), en zijn er wellicht inconsistenties in de wijze waarop wordt gemeten of beoordeeld. Met de kwantificering van zulke consistenties en inconsistenties betreden we het terrein van de betrouwbaarheidsanalyse.

Het begrip ‘betrouwbaarheid’ heeft in wetenschappelijk onderzoek eigenlijk twee betekenissen, die we afzonderlijk behandelen. Ten eerste wordt met betrouwbaarheid de *precisie* of *nauwkeurigheid* van een meting bedoeld. Dit aspect heeft betrekking op de vraag in hoeverre de meting beïnvloed wordt door toevallige factoren (waardoor de meting niet uitsluitend het onderzochte construct weergeeft). Als we *niet* nauwkeurig meten, dan weten we ook niet wat de verkregen meetwaarden eigenlijk weergeven — misschien het onderzochte construct, maar misschien ook niet. Als we wel nauwkeurig meten, dan verwachten we, als we dezelfde meting nogmaals zouden uitvoeren, dat we dan dezelfde uitkomst zouden meten. Naarmate een meting minder precies is, zal er meer variatie of inconsistentie zijn tussen de eerste meting en de herhaalde meting, en zijn de metingen dus minder betrouwbaar.

Voorbeeld 12.1: Als we de leesvaardigheid van leerlingen in het eindexamen willen meten, dan leggen we hen een tekstbegriptoets met een bijbehorend aantal vragen voor. De mate waarin de verschillende vragen *hetzelfde* construct meten, hier het construct ‘leesvaardigheid’, wordt de betrouwbaarheid, precisie of homogeniteit genoemd.

In het vervolg zullen we, om verwarring te voorkomen, deze vorm van betrouwbaarheid dan ook aanduiden met de term *homogeniteit* (vs. heterogeniteit). Bij een heterogene (niet-homogene) toets kan de totaal-score moeilijk geïnterpreteerd worden. Bij een perfect homogene test hebben mensen met dezelfde totaalscore ook dezelfde vragen correct beantwoord. Maar als we menselijk (taal)gedrag meten, komen zulke perfect homogene toetsen eigenlijk nooit voor: respondenten die wel dezelfde totaalscore behalen, hebben toch niet allen dezelfde vragen correct beantwoord (bv. in de leesvaardigheidstoets van het eindexamen, voorbeeld 12.2). Dit houdt in dat de vragen niet exact hetzelfde gemeten hebben. Dat is ook zo: de ene vraag betrof een parafrase van een alinea, terwijl een andere vraag betrekking had op een

verwijswoord-antecedent-relatie. De vragen of items waren dus niet perfect homogeen!

Ten tweede wordt met betrouwbaarheid de *stabieleit* van een meting bedoeld. Om je gewicht te meten ga je op een weegschaal staan. Die meting is stabiel: vijf minuten later zal dezelfde weegschaal met dezelfde persoon onder dezelfde omstandigheden ook (bijna) dezelfde meetwaarde opleveren. De stabiliteit wordt veelal uitgedrukt in een zogenaamde correlatiecoëfficiënt (een maat voor samenhang, zie Hoofdstuk 11). Deze correlatiecoëfficiënt kan alle waarden aannemen tussen +1 en -1 . Hoe meer de eerste en tweede meting gelijk zijn, des te hoger de samenhang, en des te hoger de correlatie tussen eerste en tweede meting. Omgekeerd, hoe lager de samenhang tussen eerste en tweede meting, des te lager ook de correlatie.

Stabiele metingen komen echter zelden voor in onderzoek naar (taal)gedrag. Als een toets tweemaal afgenomen wordt, dan is er vaak een aanzienlijk verschil in scores op het eerste meetmoment en scores op het tweede meetmoment.

Voorbeeld 12.2: Bij het eindexamen Nederlands moeten leerlingen een opstel schrijven, dat wordt beoordeeld door twee beoordelaars. De beoordelaars zijn stabiel, als zij na enige tijd dezelfde oordelen toekennen aan dezelfde opstellen. Dus: als beoordelaar A eerst een 8 geeft aan een opstel, en bij een tweede beoordeling enige tijd later ook een 8 geeft voor hetzelfde opstel, dan is deze beoordelaar (zeer) stabiel. Als dezelfde beoordelaar A bij de tweede beoordeling echter een 4 geeft aan hetzelfde opstel, dan is de beoordelaar niet stabiel in zijn oordelen.

Nu is het beoordelen van opstellen een lastige taak: de criteria zijn niet scherp beschreven en er is relatief veel ruimte voor interpretatieverschillen. De stabiliteit van de oordelen is dan ook laag; in het verleden is zelfs een stabiliteitscoëfficiënt van 0.40 gerapporteerd.

Om de stabiliteit van een toets te berekenen, moet dezelfde toets tweemaal worden afgenomen; de mate van samenhang tussen de eerste en tweede meting wordt de *toets-hertoets-betrouwbaarheid* genoemd. Zo'n herhaalde afname van een toets gebeurt in de praktijk zelden, vanwege de relatief hoge kosten en relatief geringe opbrengst.

Voorbeeld 12.3: (Lata-Caneda et al., 2009) ontwikkelden een Spaanstalige vragenlijst van 39 vragen, bedoeld voor afasiepatiënten om de kwaliteit van hun leven te bepalen. De kwaliteit van leven wordt omschreven als “the patient perception about, either the effects of a given disease, or the application of a certain treatment on different aspects of life, especially regarding its consequences on the physical, emotional and social welfare” (Lata-Caneda et al., 2009, p.379). De nieuwe vragenlijst werd tweemaal afgenomen bij een steekproef van 23 Spaanstalige patiënten met afasie t.g.v. hersenbloeding. De gerapporteerde test-hertest-stabiliteit voor deze vragenlijst was 0.95.

Zowel de homogeniteit als stabiliteit wordt uitgedrukt als een coëfficiënt met een waarde tussen 0 en 1 (negatieve coëfficiënten komen in de praktijk niet voor). Hoe moeten we de gerapporteerde coëfficiënten nu interpreteren? In het algemeen geldt natuurlijk: hoe hoger de coëfficiënt, hoe hoger (beter) de betrouwbaarheid. Maar hoe groot moet de betrouwbaarheid minimaal zijn voordat we een toets “betrouwbaar” mogen noemen? Daar zijn geen eenduidige regels voor. Als er afwegingen over personen gemaakt moeten worden, dan moet de toets een betrouwbaarheid van minimaal 0.90 hebben, volgens het Nederlands Instituut van Psychologen (NIP). Dat geldt bijvoorbeeld voor toetsen die worden gebruikt om te bepalen of een kind wel of niet in aanmerking komt voor een zgn. dyslexie-verklaring. Voor onderzoeksdoeleinden hoeft niet zo’n strenge eis aan de betrouwbaarheid van een toets te worden gesteld. Vaak wordt als ondergrens voor de betrouwbaarheidscoëfficiënt de waarde 0.70 gehanteerd.

12.3 Testtheorie

De klassieke testtheorie heeft betrekking op de meting van variabele x bij het i -de element van een steekproef van willekeurige leden uit een populatie. De testtheorie poneert dat elke meting x_i samengesteld is uit twee componenten, nl een ware score t_i (‘true score’) en een foutscore of afwijking e_i (‘error score’):

$$x_i = t_i + e_i \quad (12.1)$$

Stel dat je “in het echt” $t = 72.0$ kg weegt, en stel dat je gemeten gewicht $x = 71.6$ kg is, dan bedraagt de foutscore $e = -0.4$ kg.

Een eerste belangrijke aanname in de klassieke testtheorie is dat de afwijkingen e_i elkaar neutraliseren of opheffen (d.w.z. gemiddeld nul zijn, en dus niet systematisch afwijken van de ware score t), en dat grotere afwijkingen naar boven of beneden minder vaker voorkomen dan kleinere afwijkingen. Dat

houdt in dat wordt aangenomen dat de afwijkingen normaal verdeeld zijn (zie §10.3), met $\mu_e = 0$ als gemiddelde:

$$e_i \sim \mathcal{N}(0, s_e^2) \quad (12.2)$$

Een tweede belangrijke aanname in de klassieke testtheorie is dat er geen verband is tussen de ware scores t_i en de foutcores e_i . Omdat de component e_i geheel door het toeval wordt bepaald, dus zonder enig verband met x_i , is de correlatie tussen de ware score en de foutcore nul:

$$r_{(t,e)} = 0 \quad (12.3)$$

De totale variantie van x is daarom¹ gelijk aan som van de variantie van de ware scores en de variantie van de foutcores:

$$s_x^2 = s_t^2 + s_e^2 \quad (12.4)$$

Als de geobserveerde variantie s_x^2 verhoudingsgewijs veel fout-variantie bevat (d.i. variantie van afwijkingen), dan zijn de geobserveerde scores goeddeels bepaald door toevallige afwijkingen. Dat is natuurlijk geen wenselijke zaak. We zeggen dan dat de geobserveerde scores niet betrouwbaar zijn; er zit veel “ruis” in de geobserveerde scores. Als de fout-variantie daarentegen relatief gering is, dan geven de geobserveerde scores goed weer wat de ware scores zijn, en dan zijn de geobserveerde verschillen wel goed betrouwbaar, d.w.z. ze worden weinig bepaald door toevallige afwijkingen.

We kunnen de betrouwbaarheid (symbool ρ) dan ook definiëren als de verhouding tussen ware-score-variantie en totale variantie:

$$\rho_{xx} = \frac{s_t^2}{s_x^2} \quad (12.5)$$

We kunnen deze formule (12.5) echter in de praktijk niet gebruiken om de betrouwbaarheid vast te stellen, omdat we s_t^2 niet kennen. We moeten dus eerst schatten wat de ware-score-variantie is — of wat de fout-variantie is, die is immers het complement van de ware-score-variantie (zie formule @ref(eq:var.true.error))².

De tweede aanname (in formule (12.3)) dat er geen verband is tussen de ware score en de fout-score, is in de praktijk niet altijd gerechtvaardigd. Dat wordt misschien inzichtelijk als we kijken naar de uitslagen van een toets, op een schaal van 1.0 tot 10.0. De studenten met scores van 9 of 10 hebben ook een hoge ware score (zij beheersen de stof zeer goed) en dus doorgaans een geringe

¹ $s_{(t+e)}^2 = s_t^2 + s_e^2 + 2r_{(t,e)}s_t s_e$, met hier $r_{(t,e)} = 0$ volgens formule (12.3).

²Een uitzondering hierop vormt de situatie indien $s_x^2 = 0$, en dus $s_t^2 = 0$, ergo betrouwbaarheid $\rho = 0$; de afhankelijke variabele x is dan niet goed geoperationaliseerd.

fout-score. De studenten met scores van 1 of 2 hebben ook een lage ware score (zij beheersen de stof zeer slecht) en dus ook doorgaans een geringe fout-score.

Voor de studenten met scores van 5 of 6 ligt de situatie anders: misschien beheersen ze de stof redelijk goed maar hebben ze net een fout antwoord gegeven, of ze beheersen de stof niet goed maar ze hebben toevallig een goed antwoord gegeven. Voor deze studenten met een geobserveerde score in het midden van de schaal zijn de fout-scores relatief groter dan voor de studenten met een score bij de uiteinden van de schaal. In andere domeinen, bv bij reactietijden, zien we andere verbanden, bv dat de foutscore min of meer evenredig toeneemt met de score zelf; er is dan een positief verband tussen de ware score en de foutscore ($\rho_{(t,e)} > 0$). Desalniettemin zijn de voordelen van de klassieke testtheorie zo groot dat we deze theorie handhaven als uitgangspunt.

Uit de formules (12.4) en (12.5) hierboven volgt ook dat de standaard meetfout ('standard error of measurement',) gerelateerd is aan de standaarddeviatie en aan de betrouwbaarheid:

$$s_e = s_x \sqrt{1 - r_{xx}} \quad (12.6)$$

Deze standaard meetfout is op te vatten als de standaarddeviatie van de foutscores e_i , nog steeds aannemende dat de foutscores normaal verdeeld zijn (formule (12.2)).

Voorbeeld 12.4: Externe inspecteurs betwijfelen of docenten de eindwerkstukken van hun studenten wel goed beoordelen. Als een student een 6 heeft gekregen, zou dat werkstuk dan misschien eigenlijk als onvoldoende beoordeeld moeten worden?

Laten we aannemen dat de gegeven oordelen een standaarddeviatie $s_x = 0.75$ vertonen, en laten we eveneens aannemen dat een analyse van de betrouwbaarheid heeft laten zien dat $r_{xx} = 0.9$. De standaard meetfout bedraagt dan $s_e = 0.24$ punt (naar boven afgerond). De kans dat de ware score t_i kleiner of gelijk is aan 5.4 (onvoldoende), bij een geobserveerde score van $x_i = 6.0$ en $s_e = 0.24$, is slechts 0.006 (voor uitleg, zie §?? hieronder). De voldoende beoordeling van het eindwerkstuk is met grote waarschijnlijkheid juist.

12.4 Interpretaties

Voordat we ingaan op verschillende berekeningswijzen van de betrouwbaarheid is het zinvol om stil te staan bij verschillende interpretaties van betrouwbaarheidsschattingen.

Ten eerste kan de betrouwbaarheid geïnterpreteerd worden als de proportie ware-score-variantie (zie formule @ref (eq:rho-betrouwbaarheid)), oftewel als de proportie van variantie die “systematisch” is. Dit is vanzelfsprekend nog lang niet hetzelfde als de proportie variantie ten gevolge van het begrip-zoals-bedoeld, de “valide” variantie (zie Hoofdstuk 5). De variantie ten gevolge van het begrip-zoals-bedoeld maakt deel uit van de proportie ware-score-variantie. Echter, tal van andere factoren kunnen op systematische wijze van invloed zijn op de scores van de respondenten, zoals verschillen in toets-ervaring. Indien twee studenten i en j een concept (zeg: taalvaardigheid) in dezelfde mate bezitten, dan nog kan de ene student beter scoren omdat hij of zij vaker taalvaardigheidstoetsen heeft afgelegd dan de andere student. Er is dan geen verschil in het begrip zoals bedoeld (taalvaardigheid $T_i = T_j$), maar wel in een andere factor (ervaring), en daardoor ontstaat een verschil tussen de studenten in hun ‘ware’ scores ($t_i \neq t_j$) die we meten met een valide en betrouwbare taalvaardigheidsmeting. Bij die meting treden afwijkingen en meetfouten op (e_i en e_j), waardoor de geobserveerde verschillen tussen de studenten ($x_i - x_j$) groter of kleiner kunnen zijn dan hun verschillen in ‘ware’ score ($t_i - t_j$). Vandaar dat een betrouwbaarheidsschatting altijd de bovengrens vormt van de validiteit.

Een tweede interpretatie van de betrouwbaarheid (formule (12.5)) is die van de theoretisch te verwachten correlatie (zie §11.2) tussen de metingen, bij vele herhalingen van die metingen. Gemakshalve nemen we aan dat geheugen- en vermoeidheidseffecten geen enkel effect hebben bij de tweede en latere metingen. Als we dezelfde personen met hetzelfde instrument driemaal zouden meten, zonder effecten van geheugen of vermoeidheid, dan zouden de scores van de eerste en tweede meting, en van de eerste en derde meting, en van de tweede en derde meting, steeds dezelfde correlatie ρ vertonen. Die correlatie geeft dus aan in hoeverre de herhaalde metingen consistent zijn, d.w.z. dezelfde onbekende ware score representeren.

In deze interpretatie drukt de betrouwbaarheid dus de verwachte samenhang uit tussen scores bij herhaalde afname van dezelfde toets. De betrouwbaarheidscoefficiënt ρ interpreteren we dan als de correlatie tussen twee metingen met hetzelfde instrument.

Ten derde kan de betrouwbaarheid geïnterpreteerd worden als het verlies van efficiëntie in het schatten van de gemiddelde score \bar{X} (Ferguson and Takane, 1989, p.474). Stel dat we de gemiddelde score van een groep van $n = 50$ proefpersonen willen vaststellen, en we gebruiken daarbij een meetinstrument met betrouwbaarheid $\rho_{xx} = 0.8$. Er is dan onzekerheid in de schatting, deels afkomstig van variatie in de ware scores t_i van de proefpersonen, maar ook deels afkomstig van de toevallige afwijkingen e_i bij de metingen. Als het meetinstrument perfect betrouwbaar zou zijn ($\rho = 1$) dan zouden we slechts $\rho_{xx} \times n = 0.8 \times 50 = 40$ proefpersonen nodig hebben gehad voor dezelfde nauwkeurigheid van de schatting van \bar{X} (Ferguson and Takane, 1989, p.474). We hebben dus als het ware 10 proefpersonen verspeeld om te compenseren

voor de onbetrouwbaarheid van het meetinstrument.

Hierboven hebben we gesproken over metingen met behulp van meet-instrumenten, en hieronder zullen we spreken over beoordelingen gedaan door beoordelaars. De benadering van de notie ‘betrouwbaarheid’ is in deze situaties steeds gelijk. Betrouwbaarheid speelt een rol in alle situaties waarin elementen uit een steekproef worden gemeten of beoordeeld door meerdere beoordelaars of instrumenten. Ook tentamina en vragenlijsten kunnen zulke meetinstrumenten zijn: een tentamen of een vragenlijst is goed te beschouwen als een samengesteld instrument waarmee we een abstracte eigenschap of construct van de deelnemers proberen te meten. Iedere vraag is dan te beschouwen als een “meetinstrument” of “beoordelaar” van de eigenschap of gesteldheid van de respondent. Alle bovenvermelde inzichten en interpretaties aangaande testtheorie, meetfout en betrouwbaarheid zijn daarbij evengoed van toepassing.

12.5 Methoden om betrouwbaarheid te schatten

De betrouwbaarheid van een meting kan op verschillende manieren worden bepaald. De belangrijkste zijn de volgende:

- De *toets-hertoets-methode*
We voeren alle metingen tweemaal uit, en berekenen daarna de correlatie tussen de eerste en de tweede meting. Naarmate de metingen minder meetfouten en afwijkingen bevatten, is de correlatie hoger en dus ook de betrouwbaarheid hoger. Deze methode is tijdrovend, maar kan ook worden toegepast op een kleine portie van de metingen. In spraak-onderzoek wordt deze methode wel gebruikt om de betrouwbaarheid van fonetische transcripties vast te stellen: een deel van de spraak-opnamen wordt door een tweede beoordelaar getranscribeerd, en vervolgens worden de beide transcripties vergeleken.
- De *parallele-toetsvorm-methode*
We hebben een grote verzameling meet-instrumenten die goed vergelijkbaar zijn en hetzelfde construct meten. We voeren alle metingen herhaaldelijk uit, de eerste keer door de metingen van enkele willekeurig getrokken meet-instrumenten te combineren (zeg A en B en C) en tweede keer met gebruik van andere willekeurige instrumenten (zeg D en E en F). Omdat de meetinstrumenten ‘parallel’ zijn en hetzelfde construct worden geacht te meten, is de correlatie tussen de eerste en de tweede meting een indicatie voor de betrouwbaarheid van de meting.
- De *split-half-methode*

Deze methode lijkt op de parallelle-toetsvorm-methode. De k vragen of instrumenten worden in twee helften verdeeld, waarna de score bepaald wordt binnen elke helft. Uit de correlatie r_{hh} tussen de scores op de twee halve toetsen kan de betrouwbaarheid van de gehele toets afgeleid worden, $r_{xx} = \frac{2r_{hh}}{1+r_{hh}}$.

12.6 Betrouwbaarheid tussen beoordelaars

Laten we als voorbeeld eens kijken naar metingen van de spreekvaardigheid van studenten in een vreemde taal. Dit construct ‘spreekvaardigheid’ wordt in dit voorbeeld gemeten door middel van twee beoordelaars, die onafhankelijk van elkaar elk een cijfer tussen 1 en 100 geven aan de student (hoger is beter). Bij de beoordeling treden echter ook meetfouten op, waardoor de oordelen niet alleen de onderliggende ware score weergeven, maar ook een afwijking daarvan, met alle hierboven genoemde aannames. Laten we eerst alleen kijken naar de oordelen door de eerste en tweede beoordelaar (zie Tabel 12.1). Het eindoordeel over een student is vooralsnog het gemiddelde van de oordelen van de eerste en tweede beoordelaar.

Table 12.1: Oordelen over spreekvaardigheid van $n = 10$ studenten (rijen) door $k = 3$ beoordelaars (kolommen).

| student | B1 | B2 | B3 |
|-------------|------|------|------|
| 1 | 67 | 64 | 70 |
| 2 | 72 | 75 | 74 |
| 3 | 83 | 89 | 73 |
| 4 | 68 | 72 | 61 |
| 5 | 75 | 72 | 77 |
| 6 | 73 | 73 | 78 |
| 7 | 73 | 76 | 72 |
| 8 | 65 | 73 | 72 |
| 9 | 64 | 68 | 71 |
| 10 | 70 | 82 | 69 |
| \bar{x}_i | 71.0 | 74.4 | 71.7 |
| s_i | 5.6 | 7.0 | 4.7 |

De oordelen van alleen de eerste en de tweede beoordelaar vertonen een onderlinge correlatie van $r_{1,2} = .75$. Dit houdt in (volgens formule (12.5)) dat 75% van de totale variantie in de oordelen van deze twee beoordelaars toe te schrijven is aan verschillen tussen de beoordeelde studenten, en dus 25% aan meetfouten (we hebben immers aangenomen dat er geen systematische verschillen zijn tussen beoordelaars). Het aandeel van de meetfouten lijkt nogal hoog. We mogen echter wel hoop putten uit één van onze eerdere

aannames, nl dat de meetfouten van de beoordelaars niet gecorreleerd zijn. De *combinatie* van de twee beoordelaars — de gemiddelde score per student over de twee beoordelaars — geeft dus beter betrouwbare metingen dan elk van de beoordelaars afzonderlijk kunnen doen. Immers, de meetfouten van de twee beoordelaars hebben de neiging om elkaar op te heffen (zie formule (12.2)).

Lees de laatste twee zinnen nog eens aandachtig door.

De betrouwbaarheid wordt vaak uitgedrukt als *Cronbach's Alpha* (Cortina, 1993). Dat getal is een maat voor de consistentie of homogeniteit van de metingen, en het geeft dus ook de mate aan waarin de twee beoordelaars hetzelfde construct hebben beoordeeld. De eenvoudigste definitie is gebaseerd op \bar{r} , de gemiddelde correlatie tussen metingen van k verschillende beoordelaars³.

$$\alpha = \frac{k\bar{r}}{1 + (k-1)\bar{r}} \quad (12.7)$$

Invullen van $k = 2$ beoordelaars en $\bar{r} = 0.75$ geeft $\alpha = 0.86$ (SPSS en R gebruiken hiervoor een wat complexere formule, en rapporteren $\alpha = 0.84$). Deze maat voor betrouwbaarheid wordt niet alleen aangeduid als Cronbach's Alpha, maar ook als de Spearman-Brown-formule of als Kuder-Richardson-formule 20 (KR20)⁴.

De gevonden waarde van Cronbach's Alpha is wat lastig te evalueren, omdat die mede afhankelijk is van het aantal instrumenten of beoordelaars of vragen in de toets (Cortina, 1993; Gliner et al., 2001). Voor wetenschappelijk onderzoek wordt vaak een ondergrens van 0.75 of 0.80 gehanteerd. Indien de uitslag van de toets of meting van groot belang is voor de betrokkene, zoals bij medische of psychische diagnostiek van patiënten, of bij werving en selectie van personeel, dan wordt een nog hogere betrouwbaarheid van $\alpha = .9$ aanbevolen (Gliner et al., 2001).

Als we de betrouwbaarheid willen verhogen naar $\alpha = 0.9$ of hoger, dan kunnen we dat op twee manieren bereiken. De eerste manier is door het aantal beoordelaars uit te breiden. Als we meer beoordelaars combineren in de totale score, dan heffen de meetfouten van die beoordelaars elkaar ook beter op, en dan wordt de totale score dus betrouwbaarder. Met behulp van formule (12.7) kunnen we onderzoeken hoeveel beoordelaars nodig zouden zijn, om de betrouwbaarheid te verbeteren naar $\alpha = 0.90$ of beter. We vullen $\alpha = 0.90$ in en wederom $\bar{r} = 0.75$, en vinden dan een uitkomst van minimaal $k = 3$ beoordelaars. De *toename* in de betrouwbaarheid vakt af naarmate er al meer beoordelaars meedoen: als $k = 2$ dan $\alpha = .84$, als $k = 3$ dan $\alpha = .84 + .06 = .90$, als $k = 6$ dan $\alpha = .90 + .05 = .95$, als $k = 9$ dan $\alpha = .95 + .01 = .96$, enz. Immers, als er al 6 beoordelaars zijn, die elkaars

³In ons voorbeeld zijn er slechts $k = 2$ beoordelaars, dus is er slechts één correlatie, en $\bar{r} = r_{1,2} = 0.75$.

⁴De zgn. 'intra-class correlation coefficient' (ICC) voor k vaste beoordelaars of items is eveneens identiek aan de Cronbach's Alpha.

meetfouten al goed opheffen, dan voegen 3 extra beoordelaars weinig meer toe aan de betrouwbaarheid.

De tweede manier om de betrouwbaarheid te verhogen is om de meetfout te verkleinen. Dat kunnen we proberen, bijvoorbeeld, door de beoordelaars zo goed mogelijk te instrueren over hoe ze de spreekvaardigheid van de studenten dienen te beoordelen. Een beoordelingsprotocol en/of instructie kan de afwijkingen tussen en binnen beoordelaars doen verkleinen. Kleinere afwijkingen betekenen kleinere meetfouten, en dat betekent weer hogere correlaties tussen de beoordelaars. Bij een $\bar{r} = 0.8$ bereiken we al bijna de gewenste betrouwbaarheid, met slechts $k = 2$ beoordelaars.

Een derde manier om de betrouwbaarheid te verhogen vereist een nadere analyse van de afzonderlijke beoordelaars. Om dit uit te leggen, betrekken we nu ook de derde beoordelaar in onze beschouwingen (zie Tabel 12.1). De oordelen van deze derde beoordelaar vertonen echter lage correlaties met die van de eerste en tweede beoordelaar: $r_{1,3} = 0.41$ en $r_{2,3} = 0.09$. Dat leidt ertoe dat de gemiddelde correlatie tussen beoordelaars nu lager is, $\bar{r} = 0.42$. Door deze derde beoordelaar op te nemen, is de betrouwbaarheid niet gestegen maar daarentegen juist gedaald naar $\alpha = \frac{3 \times 0.42}{1 + 2 \times 0.42} = 0.68$. We doen er dus misschien beter aan om de metingen van de derde beoordelaar te negeren. Ook als we de betrouwbaarheid van een tentamen of toets of vragenlijst onderzoeken, kan blijken dat de betrouwbaarheid van de gehele toets *toeneemt* als we sommige “slechte” vragen verwijderen. Blijkbaar hebben die “slechte” vragen een construct gemeten dat verschilt van wat de resterende vragen gemeten hebben.

12.7 Betrouwbaarheid en constructvaliditeit

Als een meting betrouwbaar is, dan is er “iets” betrouwbaar gemeten. Maar let op: dat toont nog niet aan *wat* er gemeten is! Er is wel een relatie tussen de betrouwbaarheid (hoe is gemeten) en de construct-validiteit (wat is gemeten, zie Hoofdstuk 5), maar die twee begrippen zijn niet identiek. Een voldoende betrouwbaarheid is een noodzakelijke, maar geen voldoende voorwaarde voor validiteit. Anders gezegd: een toets die niet betrouwbaar is kan ook niet valide zijn (want deze toets meet ook ruis), maar een toets die wel betrouwbaar is hoeft nog niet valide te zijn. Misschien meet de gebruikte toets wel heel betrouwbaar een ander construct dan wat de bedoeling was.

Een instrument is construct-valide als het gemeten concept overeenkomt met het bedoelde concept of construct. In voorbeeld 12.3: de vragenlijst is valide als score uit de vragenlijst overeenkomt met de kwaliteit van leven (wat dat dan ook moge zijn) van de afasie-patiënten. Pas nadat aangetoond is dat een instrument betrouwbaar is, heeft het zin om over de constructvaliditeit van een meting te spreken. De betrouwbaarheid is een noodzakelijke maar niet voldoende voorwaarde voor constructvaliditeit. Een onbetrouwbaar instrument

kan dus niet valide zijn, maar een betrouwbaar instrument hoeft niet noodzakelijk valide te zijn.

Om de schrijfvaardigheid te meten, laten we de leerlingen een opstel schrijven.

We tellen het aantal letters e in elk opstel. Dat is een zeer betrouwbare meting: verschillende beoordelaars komen tot hetzelfde aantal e 's (beoordelaars zijn homogeen) en dezelfde beoordelaar levert bij hetzelfde opstel ook steeds dezelfde uitkomst (beoordelaars zijn stabiel). Het grote bezwaar hier is dat het aantal e 's in een opstel niet of niet noodzakelijk overeenkomt met het concept schrijfvaardigheid. Een leerling die meer e 's in zijn opstel verwerkt is niet noodzakelijk een betere schrijver.

Onderzoekers weten weliswaar dat betrouwbaarheid een noodzakelijke maar niet voldoende voorwaarde is voor de validiteit. Maar toch springen ze niet altijd even zorgvuldig om met die begrippen. In vele onderzoeken wordt er stilzwijgend van uit gegaan dat als de betrouwbaarheid voldoende is, de validiteit dan ook gewaarborgd is. Ook in voorbeeld 12.3 wordt het onderscheid niet duidelijk gemaakt, en bespreken de onderzoekers de construct-validiteit van hun nieuwe vragenlijst niet expliciet.

12.8 SPSS

Voor een betrouwbaarheidsanalyse van de $k = 3$ oordelen over spreekvaardigheid in Tabel 12.1:

Analyze > Scale > Reliability Analysis...

Selecteer de variabelen die geacht worden hetzelfde construct te meten; hier zijn dat de drie beoordelaars. We beschouwen deze $k = 3$ beoordelaars als “items” die de eigenschap “spreekvaardigheid” meten van 10 studenten. Sleep deze variabelen naar het Variable(s) paneel.

Vul als Scale label in een aanduiding van het construct, bijv.

Spreekvaardigheid.

Kies als Method: **Alpha** voor Cronbach's Alpha (zie formule (12.7))

Kies **Statistics...**, vink aan: **Descriptives for Item**, **Scale**, **Scale if item deleted**, **Inter-Item Correlations**, **Summaries Means**, **Variances**, en bevestig met **Continue** en daarna nogmaals met **OK**.

De uitvoer bevat Cronbach's Alpha, de gevraagde inter-item-correlaties (vooral hoog tussen beoordelaars 1 en 2), en (in tabel Item-Total Statistics) de betrouwbaarheid indien we een bepaalde beoordelaar zouden verwijderen.

Deze laatste uitvoer leert ons dat beoordelaars 1 en 2 van groter belang zijn dan beoordelaar 3. Als we beoordelaar 1 of 2 zouden verwijderen dan stort de betrouwbaarheid in, maar als we beoordelaar 3 zouden verwijderen dan neemt de betrouwbaarheid zelfs toe (van 0.68 naar 0.84). Vermoedelijk heeft deze beoordelaar een ander construct beoordeeld dan de anderen.

12.9 R

Voor een betrouwbaarheidsanalyse van de $k = 3$ oordelen over spreekvaardigheid in Tabel 12.1:

```
beoordelaars <- read.table(file="data/beoordelaars.txt", header=TRUE)
if (require(psych)) { # voor psych::alpha
  alpha( beoordelaars[,2:4] ) # kolommen 2 t/m 4
}

##
## Reliability analysis
## Call: alpha(x = beoordelaars[, 2:4])
##
##   raw_alpha std.alpha G6(smc) average_r S/N ase mean sd median_r
##      0.68      0.68    0.74      0.41 2.1 0.17  72 4.6    0.41
##
## lower alpha upper      95% confidence boundaries
## 0.35 0.68 1.01
##
## Reliability if an item is dropped:
##   raw_alpha std.alpha G6(smc) average_r S/N alpha se var.r med.r
## B1      0.15      0.16  0.088      0.088 0.19  0.497  NA 0.088
## B2      0.58      0.58  0.410      0.410 1.39  0.264  NA 0.410
## B3      0.84      0.85  0.745      0.745 5.84  0.095  NA 0.745
##
## Item statistics
##      n raw.r std.r r.cor r.drop mean sd
## B1 10  0.93  0.92  0.91  0.81  71 5.6
## B2 10  0.84  0.78  0.72  0.53  74 7.0
## B3 10  0.56  0.64  0.38  0.25  72 4.7
```

Deze uitvoer bevat Cronbach's Alpha (raw_alpha 0.68), en de betrouwbaarheid indien we een bepaalde beoordelaar zouden verwijderen. Als we beoordelaar 3 zouden verwijderen dan neemt de betrouwbaarheid zelfs toe (van 0.68 naar 0.84). Over alle drie de beoordelaars is average_r=0.41.

Correlaties tussen de k beoordelaars of items worden niet expliciet meegeleverd (al zijn ze wel af te leiden uit bovenstaande uitvoer), dus vragen we die nog op:

```
cor( beoordelaars[ ,c("B1","B2","B3") ] ) # expliciete kolomnamen

##           B1           B2           B3
## B1 1.0000000 0.74494845 0.40979738
## B2 0.7449484 1.00000000 0.08845909
## B3 0.4097974 0.08845909 1.00000000
```


Appendix A


Willekeurige getallen

Table A.1: Onderstaande tabel bevat 200 willekeurige getallen tussen 0 en 9999.

| | | | | | | | | | |
|------|------|------|------|------|------|------|------|------|------|
| 2836 | 264 | 6789 | 1483 | 3459 | 9200 | 4996 | 3761 | 699 | 5622 |
| 1943 | 6034 | 8838 | 1349 | 8750 | 3181 | 8799 | 4525 | 6536 | 5111 |
| 7259 | 8030 | 5709 | 8334 | 3526 | 2768 | 6296 | 8335 | 6350 | 6192 |
| 570 | 8266 | 9050 | 7771 | 3 | 7983 | 1871 | 3927 | 5549 | 1487 |
| 1241 | 2273 | 505 | 8816 | 4786 | 533 | 9347 | 888 | 3728 | 4135 |
| 6688 | 9456 | 2880 | 4616 | 7698 | 2955 | 9597 | 9188 | 8932 | 5605 |
| 1325 | 1294 | 8001 | 1814 | 5020 | 9470 | 8702 | 4083 | 6452 | 2863 |
| 6196 | 5085 | 9961 | 5306 | 1660 | 1809 | 8405 | 2019 | 2710 | 1368 |
| 1577 | 5112 | 874 | 6909 | 4126 | 8473 | 2065 | 1511 | 4778 | 4440 |
| 5778 | 1207 | 3337 | 1888 | 1420 | 6917 | 4160 | 2682 | 5263 | 5926 |
| 6635 | 1887 | 8836 | 2940 | 2404 | 7017 | 3119 | 3699 | 2529 | 8663 |
| 6813 | 5759 | 3314 | 6929 | 5238 | 6008 | 5900 | 8485 | 5938 | 5642 |
| 5208 | 2391 | 8324 | 6888 | 9449 | 2577 | 7859 | 176 | 1650 | 8389 |
| 5446 | 4412 | 9857 | 9535 | 2794 | 7883 | 4119 | 6439 | 8082 | 7918 |
| 2984 | 2126 | 9506 | 2188 | 9762 | 9775 | 4213 | 7624 | 4520 | 1086 |
| 371 | 4559 | 12 | 718 | 8403 | 8150 | 6533 | 3741 | 6279 | 8546 |
| 4669 | 1053 | 3343 | 4889 | 9088 | 9188 | 8093 | 9496 | 8806 | 923 |
| 4070 | 3408 | 8102 | 3012 | 9706 | 771 | 8296 | 3094 | 148 | 7244 |
| 4867 | 6267 | 1225 | 6539 | 7958 | 7217 | 7833 | 728 | 1610 | 5284 |
| 4665 | 1912 | 5320 | 8563 | 1365 | 3834 | 1818 | 7791 | 7704 | 2460 |

Appendix B

Standaard-normale kansverdeling



De hieronder gegeven kritieke grenswaarde Z^* heeft een overschrijdingskans p onder H_0 , d.w.z. $P(Z \geq Z^* | H_0) = p$ (blauwe oppervlakte), en heeft kans B op een waarde tussen $(-Z^*, +Z^*)$. De Z -verdeling is symmetrisch rond $Z = 0$, dus $P(Z < -Z^*) = P(Z > Z^*)$.

De eerste tabel geeft de kritieke grenswaarden Z^* voor veel gebruikte overschrijdingskansen p en betrouwbaarheidsintervallen B :

| p | 0.2 | 0.1 | 0.05 | 0.025 | 0.01 | 0.005 | 0.0025 | 0.001 |
|-------|--------|-------|-------|-------|-------|-------|--------|-------|
| B | 60% | 80% | 90% | 95% | 98% | 99% | 99.5% | 99.8% |
| Z^* | 0.8416 | 1.282 | 1.645 | 1.960 | 2.326 | 2.576 | 2.807 | 3.090 |

De tweede tabel geeft overschrijdingskansen p en betrouwbaarheidsintervallen B voor afgeronde kritieke grenswaarden Z^* :

| | | | | | | | |
|----|--------|--------|--------|--------|--------|--------|--------|
| p | 0.3085 | 0.1587 | 0.0668 | 0.0228 | 0.0062 | 0.0013 | 0.0002 |
| B | 38.29% | 68.27% | 86.64% | 95.45% | 98.76% | 99.73% | 99.95% |
| Z* | 0.5 | 1 | 1.5 | 2 | 2.5 | 3 | 3.5 |

Bibliography

(2015). Alex Foundation.

American Psychological Association (2010). *Publication Manual of the American Psychological Association*. American Psychological Association, Washington, D.C., 6th edition.

Ayres, J., Hopf, T., and Will, A. (2000). Are reductions in CA an experimental artifact? A Solomon four-group answer. *Communication Quarterly*, 48(1):19–26.

Bhargava, S. and Pathania, V. (2013). Driving under the (cellular) influence. *American Economic Journal: Economic Policy*, 5(3):92–125.

Boswall, J. (z.j.). Alex, the talking parrot.

Cochran, W. (1977). *Sampling Techniques*. Wiley, New York, 3e edition.

Cortina, J. M. (1993). What is coefficient alpha? An examination of theory and applications. *Journal of Applied Psychology*, 78(1):98–104.

Cumming, G. (2012). *Understanding The New Statistics*. Routledge, New York.

De Groot, A. (1961). *Methodologie: Grondslagen van onderzoek en denken in de gedragswetenschappen*. Mouton, 's-Gravenhage.

De Jong, N. H., Groenhout, R., Schoonen, R., and Hulstijn, J. H. (2015). Second language fluency: Speaking style or proficiency? Correcting measures of second language fluency for first language behavior. *Applied Psycholinguistics*, 36(2):223–243.

Deutsch, D. (2006). The enigma of absolute pitch. *Acoustics Today*, 2:11–19.

Dingemanse, M., Torreira, F., and Enfield, N. (2013). Is “huh?” a universal word? conversational infrastructure and the convergent evolution of linguistic items. *PLOS One*, 8(11):e78273.

Donald, D. (1983). The use and value of illustrations as contextual information for readers at different progress and developmental levels. *British Journal of Educational Psychology*, 53(2):175–185.

- Drake, C. and Ben El Heni, J. (2003). Synchronizing with music: Intercultural differences. *Annals of the New York Academy of Sciences*, 999(1):429–437.
- Ferguson, G. A. and Takane, Y. (1989). *Statistical Analysis in Psychology and Education*. McGraw-Hill, New York, 6e edition.
- Gelman, A. and Hill, J. (2007). *Data Analysis Using Regression and Multi-level/Hierarchical Models*. Cambridge University Press, Cambridge.
- Gliner, J. A., Morgan, G. A., and Harmon, R. J. (2001). Measurement reliability. *Journal of the American Academy of Child and Adolescent Psychiatry*, 40(4):486–488.
- Henrich, J., Heine, S. J., and Norenzayan, A. (2010). The weirdest people in the world? *Behavioral and Brain Sciences*, 33(2-3):61–83.
- Houtkoop-Steenstra, H. (1991). Hoe een gesloten vraag toch open kan zijn. *Tijdschrift voor Taalbeheersing*, 13(3):185–196.
- Hume, D. (1739). *A Treatise on Human Nature*.
- Johnson, E. K. and Zamuner, T. (2010). *Using infant and toddler testing methods in language acquisition research*, chapter 4, pages 73–93. John Benjamins, Amsterdam.
- Karp, J. A. and Brockington, D. (2005). Social desirability and response validity: A comparative analysis of overreporting voter turnout in five countries. *Journal of Politics*, 67(3):825–840.
- Kerlinger, F. N. and Lee, H. B. (2000). *Foundations of Behavioral Research*. Harcourt College Publishers, Fort Worth, 4th edition.
- Koring, L., Mak, P., and Reuland, E. (2012). The time course of argument re-activation revealed: Using the visual world paradigm. *Cognition*, 123(3):361–379.
- Lata-Caneda, M., Piñeiro-Temprano, M., García-Fraga, I., García-Armesto, I., Barrueco-Egido, J., and Mejjide-Failde, R. (2009). Spanish adaptation of the stroke and aphasia quality of life scale-39 (SAQOL-39). *European Journal of Physical and Rehabilitation Medicine*, 45(3):379–384.
- Lev-Ari, S. and Keysar, B. (2010). Why don't we believe non-native speakers? The influence of accent on credibility. *Journal of Experimental Social Psychology*, 46(6):1093–1096.
- Levin, I. P. (1999). *Relating Statistics and Experimental Design: An introduction*. Sage University Papers Series on Quantitative Applications in the Social Sciences; 07-125. Sage, Thousand Oaks, CA.
- Luyckx, K., Kloots, H., Coussé, E., and Gillis, S. (2007). *Klankfrequenties in het Nederlands*. Academia Press.

- Morton, A. (2003). *A Guide through the Theory of Knowledge*. Blackwell, Malden, MA, 3e edition.
- Office of Research Integrity (2012). Responsible conduct of research training.
- Pfungst, O. (1907). *Das Pferd des Herrn von Osten (Der kluge Hans): Ein Beitrag zur experimentellen Tier- und Menschen-Psychologie*. J. A. Barth, Leipzig.
- Plomp, R. and Mimpen, A. M. (1979). Improving the reliability of testing the speech reception threshold for sentences. *International Journal of Audiology*, 18(1):43–52.
- Popper, K. (1935). *Logik der Forschung. Zur Erkenntnistheorie der modernen Naturwissenschaft*. Julius Springer, Wien.
- Popper, K. (1959). *The logic of scientific discovery*. Routledge, London.
- Popper, K. (1963). *Conjectures and Refutations: The Growth of Scientific Knowledge*. Routledge and Kegan Paul, London.
- Quené, H. (2010). *How to design and analyze language acquisition studies*, pages 269–287. Benjamins, Amsterdam.
- Quené, H., Semin, G. R., and Foroni, F. (2012). Audible smiles and frowns affect speech comprehension. *Speech Communication*, 54(7):917–922.
- Quené, H. (2008). Multilevel modeling of between-speaker and within-speaker variation in spontaneous speech tempo. *Journal of the Acoustical Society of America*, 123(2):1104–1113.
- Retraction Watch (2018). The “regression to the mean project:” what researchers should know about a mistake many make. Technical report.
- Richardson, E., DiBenedetto, B., Christ, A., Press, M., and Winsberg, B. G. (1978). An assessment of two methods for remediating reading deficiencies. *Reading Improvement*, 15(2):82.
- Rijlaarsdam, G. (1986). *Effecten van leerlingrespons op aspecten van stelvaardigheid*. PhD thesis.
- Rosenthal, R. and Rosnow, R. L. (2008). *Essentials of Behavioral Research: Methods and Data Analysis*. McGraw Hill, Boston, 3e edition.
- Rosén, E., Stigson, H., and Sander, U. (2011). Literature review of pedestrian fatality risk as a function of car impact speed. *Accident Analysis and Prevention*, 43(1):25–33.
- Sanders, E. (2011). *Eerste Hulp bij e-Onderzoek voor studenten in de geesteswetenschappen: Slimmer zoeken, slimmer documenteren*. Early Dutch Books Online.

- Schuurman, W. and De Kluiver, H. (2001). *Kop of munt: Kansrekening in het dagelijks leven*. Bert Bakker, Amsterdam.
- Shadish, W. R., Cook, T. D., and Campbell, D. T. (2002). *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Wadsworth, Belmont, CA.
- SWOV (2012). De relatie tussen snelheid en ongevallen.
- Thompson, S. K. (2012). *Sampling*. Wiley series in probability and statistics. John Wiley, Hoboken, NJ, 3e edition.
- Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley, Reading, MA.
- Universiteitsbibliotheek, Vrije Universiteit Amsterdam (2015). Webcursus informatievaardigheden - algemeen - niveau b.
- Van den Berg, M., Amuzu, E. K., Essizewa, K., Yevudey, E., and Tagba, K. (2017). Crosslinguistic effects in adjectivization strategies in Suriname, Ghana and Togo. In Cutler, C., Vrzić, Z., and Angermeyer, P., editors, *Language Contact in Africa and the African Diaspora in the Americas: in honor of John V. Singler*, pages 343–362. Benjamins, s.l.
- Van den Bergh, H. and Meuffels, B. (1993). Schrijfvaardigheid. In Braet, A. and Van de Gein, J., editors, *Taalbeheersing als tekstwetenschap: terreinen en trends*. ICG, Dordrecht.
- Verhoeven, J., De Pauw, G., and Kloots, H. (2004). Speech rate in a pluricentric language: A comparison between Dutch in Belgium and the Netherlands. *Language and Speech*, 47(3):297–308.
- VSNU (2018). Nederlandse gedragscode wetenschappelijke integriteit. Technical report, VSNU.
- Watzlawick, P. (1977). *Is ‘werkelijk’ waar? Spraakverwarring, zinsbegoocheling en onvoorstelbare werkelijkheid*. Van Loghum Slaterus, Deventer.
- Weisstein, E. W. (2015). Pascal’s formula.
- Wijffels, J., van den Bergh, H., and van Dillen, S. (1992). Het sturend effect van vragen met voorbeeldantwoorden. *Tijdschrift voor Taalbeheersing*, 14(2):136–147.
- Wilcox, R. R. (2012). *Introduction to Robust Estimation and Hypothesis Testing*. Elsevier, Burlington, 3rd edition.
- Xie, Y. (2020). *bookdown: Authoring Books and Technical Documents with R Markdown*. R package version 0.18.